



UNIVERSIDAD DE COSTA RICA

Escuela de Matemáticas

Estadística Actuarial I (CA0303)

Bitácora #3

Prof: Maikol Solís

Estudiantes:

Anthony Flores Rojas (C32975)

Andrey González Bastos (C33329)

Randal Picado Bermúdez (C36024)

Leonardo Vega Aragón (C38313)

Fecha: 10/06/2026

Contenido

Preparación	1
Audiencia del proyecto	1
Rastro de decisiones	1
Respuesta a retroalimentación	1
Log de contribuciones	1
Parte de planificación	2
Análisis de modelación	2
Propuesta metodológica	2
Construcción de fichas de resultados	10
Ficha de resultado 1	10
Ficha de resultado 2	11
Ficha de resultado 3	11
Ficha de resultado 4	11
Ficha de resultado 5	12
Ficha de resultado 6	12
Ficha de resultado 7	12
Ficha de resultado 8	13
Ordenamiento de los elementos de reporte	13
Elementos primarios y secundarios	13
Ordenamiento por secciones	14
La imagen que cuenta la historia	14
Arco narrativo del proyecto	15
Parte de escritura	16
Parte de reflexión	17
Diario de aprendizaje	18
Registro del uso de IA	19

Preparación

Audiencia del proyecto

«Esta semana, le diría a [audiencia] que...» Pendiente

Rastro de decisiones

Respuesta a retroalimentación

Log de contribuciones

Integrante	Sección / Tarea
Anthony Flores Rojas (C32975)	■
Andrey González Bastos (C33329)	■
Randal Picado Bermúdez (C36024)	■
Leonardo Vega Aragón (C38313)	■

Table 1: Log de contribuciones — Bitácora #3

Parte de planificación

Análisis de modelación

En esta parte del trabajo todo se basó en mejorar el código hecho hasta el momento, el mismo se puede ver en el git, más específicamente en la carpeta código.

Propuesta metodológica

1.2 Propuesta Metodológica

Pregunta de investigación

¿En qué medida los patrones estructurales de las contraseñas del dataset RockYou - su composición de caracteres, longitud y distribución de dígitos - determinan su nivel de entropía y evidencian que los usuarios no eligen contraseñas de forma aleatoria?

Tokenización CL100K sobre las contraseñas

Motivación

El tokenizador CL100K usado por GPT-4 transforma cada texto en un vector de embeddings de dimensión alta. Cuando se calcula la norma del vector de tokenización de una contraseña, el resultado es un número real que contiene una distribución de dígitos en cada posición. Si los dígitos presentes en estas normas se desvían de la distribución de Benford, existe evidencia de que los usuarios eligen contraseñas con patrones sistemáticos que el modelo-tokenizador captura de manera predecible, lo que implica vulnerabilidad en la representación interna. Se utiliza la tokenización, ya que es una transformación relativamente “natural” del lenguaje humano a dígitos, dado que el tokenizador CL100K fue entrenado sobre datos reales de uso humano según los análisis publicados por OpenAI, lo que permite detectar si los patrones de elección de contraseñas se preservan en la representación interna del modelo.

Tokenización CL100K y norma elegida

Sea c una contraseña del conjunto de datos $\mathcal{C}$. El tokenizador CL100K la transforma en un vector de embeddings:

$$\text{CL100K}(c) = \mathbf{v}_c = (v_1, v_2, \dots, v_d) \in \mathbb{R}^d, \quad (1.1)$$

donde d es la dimensión del embedding (típicamente $d \approx 100,000$ para CL100K).

Se elige la norma de valor absoluto del vector

$$\|\mathbf{v}_c\|_1 = \sum_{i=1}^d |v_i| \in \mathbb{R}_{\geq 0}. \quad (1.2)$$

Esta norma fue elegida simplemente por su interpretación directa como la suma total de las magnitudes de las componentes del vector de tokenización, lo que permite extraer la distribución de dígitos en cada posición del número resultante.

Para cada $\|\mathbf{v}_c\|_1$, se extrae el dígito en la posición n

$$D_n(\|\mathbf{v}_c\|_1) = \left\lfloor \frac{\|\mathbf{v}_c\|_1}{10^{n-1}} \right\rfloor \bmod 10, \quad n \in \{1, 2, \dots, N_{\max}\}, \quad (1.3)$$

donde $N_{\max}$ es el número de dígitos de $\|\mathbf{v}_c\|_1$.

Prueba de Kolmogorov-Smirnov contra la distribución de Benford

Motivación

La Ley de Benford establece que en conjuntos de datos numéricos de origen “natural”, el dígito d ocupa la primera posición con una frecuencia predecible (Caputi Zunini, 2019). Si los dígitos presentes en contraseñas reales se desvían de esa distribución, existe evidencia de que los usuarios eligen números con sesgos sistemáticos, lo que implica predecibilidad y, en consecuencia, vulnerabilidad. Se elige la prueba KS (y no una chi-cuadrado) porque compara funciones de distribución acumulada completas sin requerir agrupar celdas; con muestras en el orden de millones, la chi-cuadrado infla el estadístico por el tamaño de n sin aportar información sobre la forma de la desviación (Chandola, Banerjee, & Kumar, 2009; Chandy, Schifano, Yan, & Zhang, 2025).

Distribución teórica de Benford generalizada

Sea $(D_n \in \{1, \dots, 9\})$ el dígito en la posición (n) -ésima, entonces la PDF de Benford para $(n=1)$ es

$$\mathbb{P}(\{D_1 = d\}) = \log_{10} \left(1 + \frac{1}{d} \right) \quad (1.4)$$

Para posiciones $n \geq 2$, la fórmula generalizada integra sobre todos los prefijos de longitud $n - 1$, siendo esta

$$\mathbb{P}(\{D_n = d\}) = \sum_{k=10^{n-2}}^{10^{n-1}-1} \log_{10} \left(1 + \frac{1}{10k + d} \right), \quad d \in \{0, 1, \dots, 9\} \quad (1.5)$$

Estadístico KS

Sea $F_n(x)$ la función de distribución acumulada empírica de los dígitos en la posición p y $F_0(x)$ la CDF teórica de Benford. El estadístico Kolmogorov-Smirnov es

$$D_n = \sup_x |F_n(x) - F_0(x)| \quad (1.6)$$

Distribución límite y valor crítico

Kolmogorov (1933) demostró que, bajo H_0 simple (distribución teórica completamente especificada sin parámetros estimados), el estadístico escalado converge en distribución

$$\sqrt{n} D_n \xrightarrow{d} K, \quad n \rightarrow \infty \quad (1.7)$$

donde K es la **distribución de Kolmogorov**, cuya CDF admite la representación en serie

$$P(K \leq t) = 1 - 2 \sum_{j=1}^{\infty} (-1)^{j-1} e^{-2j^2 t^2} \quad (1.8)$$

Para valores de t no demasiado pequeños, el primer término domina y la aproximación de un término es suficiente

$$P(K > t) \approx 2e^{-2t^2} \quad (1.9)$$

El cuantil crítico t_α se obtiene igualando la expresión anterior a α y despejando

$$2e^{-2t_\alpha^2} = \alpha \implies t_\alpha = \sqrt{-\frac{1}{2} \ln(\frac{\alpha}{2})} \quad (1.10)$$

Para $\alpha = 0,05$ (el alpha escogido)

$$t_{0,05} = \sqrt{-\frac{1}{2} \ln(0,025)} = \sqrt{\frac{3,6889}{2}} = \sqrt{1,8444} \approx 1,3581 \quad (1.11)$$

Dado que la distribución límite es la de $\sqrt{n} D_n$, el valor crítico sobre el estadístico muestral es

$$D_\alpha = \frac{t_\alpha}{\sqrt{n}} \implies D_{0,05} = \frac{1,36}{\sqrt{n}} \quad (1.12)$$

Se rechaza H_0 (los dígitos siguen Benford) cuando $D_n > D_\alpha$. Dado que $n \sim 10^6$, el umbral D_α es extremadamente pequeño, por lo que se complementa el resultado con la desviación absoluta media (MAD)

$$\text{MAD} = \frac{1}{|\mathcal{D}|} \sum_{d \in \mathcal{D}} |\mathbb{P}_{\text{emp}}(d) - \mathbb{P}_{\text{Benford}}(d)| \quad (1.13)$$

donde $\mathcal{D}$ es el conjunto de dígitos válidos para la posición dada. Los umbrales de conformidad son $\text{MAD} < 0,006$ (muy cercana), $0,006$ – $0,012$ (aceptable), $0,012$ – $0,015$ (marginal)

y $> 0,015$ (no conformidad) (Negrini, 2012).

Conexión con la pregunta de investigación

Si KS rechaza H_0 y MAD indica no conformidad, los dígitos de las contraseñas presentan sesgos sistemáticos respecto a una distribución numéricamente “natural”.

Análisis de distribución de máscaras de contraseña

Motivación

Las contraseñas humanas no son cadenas aleatorias, los usuarios exhiben patrones estructurales sistemáticos al elegirlos. Para capturar esa estructura sin depender del contenido semántico de cada contraseña, se utiliza una representación de máscara, que abstrae cada carácter a su tipo. Formalmente, dado el alfabeto de tipos $\Sigma = \{L, U, D, S\}$ (minúsculas, mayúsculas, dígitos, caracteres especiales), la máscara de una contraseña $P = c_1 c_2 \dots c_n$ es

$$M(P) = \tau(c_1) \tau(c_2) \dots \tau(c_n), \quad \tau(c) = \begin{cases} L & c \in \mathcal{L} \\ U & c \in \mathcal{U} \\ D & c \in \mathcal{D} \\ S & c \in \mathcal{S} \end{cases} \quad (1.14)$$

Se elige esta representación y no, por ejemplo, n -gramas de caracteres, porque permite cuantificar la predecibilidad estructural independientemente del vocabulario léxico. Si pocas máscaras concentran la mayor parte de las contraseñas, el espacio de búsqueda efectivo es mucho menor que el espacio teórico, lo que constituye evidencia directa de vulnerabilidad sistemática.

Patrones comprimidos

Para reducir el espacio de máscaras sin perder información sobre la composición, se aplica una codificación de longitud de racha (*run-length encoding*) sobre $M(P)$. Sea $M(P) = t_1^{r_1} t_2^{r_2} \dots t_k^{r_k}$ la descomposición en rachas consecutivas del mismo tipo, entonces el patrón comprimido es

$$R(P) = t_1 r_1 \ t_2 r_2 \ \dots \ t_k r_k \quad (1.15)$$

Por ejemplo, la máscara LLLLLLDD se comprime a L6D2. Esta representación agrupa contraseñas con la misma composición por bloques, lo que facilita el análisis de patrones frecuentes en el dataset. La distribución de patrones comprimidos se analiza por frecuencia absoluta f_j y proporción relativa $\hat{p}_j = f_j/N$, donde N es el total de contraseñas.

Conexión con la pregunta de investigación

Si la distribución de máscaras está fuertemente concentrada, se confirma que los usuarios eligen contraseñas con patrones estructurales predecibles. Esto responde la pregunta de

investigación en su dimensión composicional: no solo los dígitos siguen sesgos (KS vs. Benford), sino que la estructura completa de la contraseña es predecible antes de conocer un solo carácter.

Entropía de Shannon y de densidad de contraseñas individuales

Motivación

A diferencia de los análisis de distribución a nivel de dataset, la entropía de una contraseña individual cuantifica la incertidumbre interna de su composición, cuán mezclados están los tipos de carácter que la conforman. Se elige la entropía de Shannon (Khan & Wunder, 2024) sobre la distribución de tipos dentro de la contraseña porque es una medida establecida de incertidumbre que no requiere conocer el vocabulario léxico del usuario, es calculable en tiempo $O(|P|)$, y es interpretable directamente como bits de información. Frente a métricas de fuerza basadas en combinatoria ($\log_2 |\mathcal{K}|^{|P|}$), que solo dependen del espacio de caracteres y la longitud, la entropía de Shannon captura además la diversidad de tipos usados dentro de la contraseña.

Definición

Entropía de Shannon

Sea P una contraseña y sea p_t la proporción del tipo $t \in \Sigma$ en P . La entropía de Shannon de P es

$$H_S(P) = - \sum_{t \in \Sigma} p_t \log_2 p_t \quad (1.16)$$

Entropía de densidad

Complementariamente, se define la entropía de densidad como la entropía de Shannon normalizada por la longitud de la contraseña

$$H_D(P) = \frac{H_S(P)}{|P|} \quad (1.17)$$

H_D penaliza las contraseñas largas pero uniformes (e.g., `aaaaaaaaaa` tiene $H_S = 0$ independientemente de la longitud) y premia aquellas con alta diversidad por carácter. Esta métrica está relacionada con la *Expectation entropy* propuesta por Khan & Wunder (2024), que escala la información de composición por el espacio máximo posible del alfabeto; ambas buscan capturar la fortaleza de la contraseña en una escala normalizada.

Conexión con la pregunta de investigación

Las estructuras internas repetitivas dentro de las contraseñas son penalizadas por ambas métricas de entropía: H_S captura la falta de diversidad entre tipos de carácter, mientras que H_D la penaliza adicionalmente en función de la longitud. Contraseñas con entropías bajas presentan menor incertidumbre interna y, por lo tanto, mayor predecibilidad desde la

perspectiva del atacante. Este resultado se complementa con la prueba de Kruskal-Wallis, que permite determinar si la estructura de la máscara discrimina significativamente el nivel de entropía observado.

Prueba de Kruskal-Wallis sobre entropías por grupo

Motivación

Se busca determinar si la estructura de la máscara (longitud y tipo dominante de caracteres) discrimina el nivel de entropía. Se elige Kruskal-Wallis (KW) en lugar de ANOVA de un factor porque

- Las distribuciones de entropía por grupo no son normales (asimétricas, con colas largas), como se verifica en el análisis descriptivo.
- KW es una prueba no paramétrica de rangos que no asume homocedasticidad ni normalidad dentro de los grupos.

Entropía de Shannon de una máscara

La entropía media de la máscara m se define como en la ecuación~(1.16), donde $\Sigma = \{L, U, D, S\}$ es el alfabeto de tipos de carácter (minúsculas, mayúsculas, dígitos, símbolos) y p_c es la proporción del tipo c en m .

Estadístico de Kruskal-Wallis

Dadas k muestras independientes de tamaños $n_1, \dots, n_k$ con $N = \sum_{i=1}^k n_i$ observaciones totales, el estadístico es

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1) \quad (1.18)$$

donde R_i es la suma de rangos del grupo i sobre el ranking global. Bajo H_0 (todas las distribuciones son iguales), $H \sim \chi_{k-1}^2$ para muestras grandes.

Ponderación por frecuencia

Como cada máscara m_j tiene una frecuencia f_j (número de contraseñas reales que la usan), se expande la muestra repitiendo cada observación con su frecuencia real:

$$\tilde{n}_j = f_j \quad (1.19)$$

Para garantizar la reproducibilidad del proyecto, la implementación incluye un parámetro de tope C configurable

$$\tilde{n}_j = \min(f_j, C) \quad (1.20)$$

En este trabajo se fija $C = 10\,000\,000$, valor que excede la frecuencia máxima observada en el dataset RockYou ($f_{\text{máx}} = L6$ con 3 996 634 observaciones), por lo que el tope es inactivo

y se cumple $\tilde{n}_j = f_j$ para toda máscara m_j . El vector de rangos reproduce así fielmente la distribución real del dataset.

Agrupaciones evaluadas

Se aplica KW bajo tres criterios de agrupación

1. Longitud de máscara: grupos $g \in \{1, 2, \dots, L_{\text{máx}}\}$ donde $L_{\text{máx}}$ es la longitud máxima observada.
2. Tipo dominante: Solo L, Solo D, Solo U, Solo S, Mixta.
3. Rango de entropía: bajo ($H < 2,4464$, por debajo del percentil 25), medio ($2,4464 \leq H < 2,9477$, entre los percentiles 25 y 75) y alto ($H \geq 2,9477$, por encima del percentil 75). Este agrupamiento es descriptivo, no inferencial, pues la variable de agrupación coincide con la variable de respuesta.

Conexión con la pregunta de investigación

Si KW rechaza H_0 en los criterios de longitud y tipo dominante, se confirma que la estructura de la máscara predice significativamente la entropía. Esto implica que conocer el patrón de una contraseña reduce la incertidumbre sobre su espacio de búsqueda, respondiendo la pregunta en su dimensión estructural.

Correlación de Spearman entre longitud y entropía

Motivación

KW indica si los grupos difieren, pero no cuantifica la dirección ni la fuerza de la relación entre longitud y entropía. Se elige el coeficiente de Spearman (y no Pearson) porque

- La relación puede ser monótona pero no lineal: la entropía puede estabilizarse a partir de cierta longitud.
- Spearman es robusto ante outliers y no asume normalidad bivariada.
- Es equivalente a Pearson aplicado sobre los rangos, lo que lo hace válido para datos ordinales y distribuciones sesgadas.

Coeficiente de Spearman

Sea $\{(\ell_j, h_j)\}_{j=1}^n$ el conjunto de pares (longitud de máscara, entropía media). El coeficiente de correlación de Spearman se calcula sobre los rangos $\{(r_j^\ell, r_j^h)\}$

$$\rho_s = 1 - \frac{6 \sum_{j=1}^n d_j^2}{n(n^2 - 1)}, \quad d_j = r_j^\ell - r_j^h \quad (1.21)$$

O, equivalentemente, como el coeficiente de Pearson de los rangos

$$\rho_s = \frac{\sum_{j=1}^n (r_j^\ell - \bar{r}^\ell)(r_j^h - \bar{r}^h)}{\sqrt{\sum_{j=1}^n (r_j^\ell - \bar{r}^\ell)^2} \sqrt{\sum_{j=1}^n (r_j^h - \bar{r}^h)^2}} \quad (1.22)$$

Variantes de cálculo

Se calculan dos versiones para verificar robustez

$$\rho_{\text{raw}} = \rho_s(\{\ell_j\}, \{h_j\}) \quad (1.23)$$

$$\rho_{\text{pond}} = \rho_s(\{\ell_j^*\}, \{h_j^*\}), \quad \text{donde } |\{j^* : \ell_{j^*} = \ell_j\}| = \min(f_j, C') \quad (1.24)$$

con $C' = 200\,000$. Si $\rho_{\text{raw}} \approx \rho_{\text{pond}}$, la correlación es robusta a la distribución de frecuencias.

Interpretación del tamaño del efecto

$$|\rho_s| \in \begin{cases} [0,7, 1,0] & \text{correlación fuerte} \\ [0,4, 0,7) & \text{correlación moderada} \\ [0,0, 0,4) & \text{correlación débil} \end{cases} \quad (1.25)$$

Conexión con la pregunta de investigación

Un ρ_s alto y positivo confirma que contraseñas más largas son estadísticamente más entrópicas, lo que respalda con evidencia cuantitativa la recomendación de longitud mínima en políticas de seguridad. Complementa KW al ofrecer una medida continua de la relación: no solo se sabe que los grupos difieren, sino cuánto y en qué dirección.

Análisis fallido: Ley de Benford sobre dígitos numéricos de contraseñas

Descripción del intento

Se intentó aplicar la Ley de Benford directamente sobre la distribución de los dígitos numéricos presentes en las contraseñas y sus subcadenas (*chunks*) numéricos, con la hipótesis de que, al tratarse de un conjunto masivo de datos generado por comportamiento humano, los primeros dígitos seguirían la distribución logarítmica característica de Benford.

Por qué no funcionó

La aplicación resultó inválida por razones tanto empíricas como teóricas. La distribución de caracteres numéricos en datasets de contraseñas no cumple las condiciones de aplicabilidad

de la Ley de Benford por varias razones estructurales:

- **Patrones de fechas:** Una fracción significativa de los componentes numéricos corresponde a años (ej. 1990, 2003), meses y días, cuya distribución de primeros dígitos está acotada artificialmente (los años modernos comienzan casi todos con 1 o 2, los meses con 0 o 1).
- **Restricciones de longitud:** Las políticas de contraseñas imponen longitudes mínimas y máximas que truncan el espacio numérico disponible, eliminando la variación de varios órdenes de magnitud que Benford requiere para operar.
- **Sesgos cognitivos del usuario:** Los usuarios concentran sus elecciones en números redondos, secuencias simples (123, 000) y años de nacimiento, lo que produce una distribución de primeros dígitos fuertemente no uniforme pero tampoco logarítmica.

Esto fue confirmado tanto mediante la revisión de la literatura especializada como mediante la comparación entre la distribución empírica observada y la distribución teórica de Benford usando el estadístico KS, el cual rechazó H_0 con un valor de D_n muy superior al umbral crítico $D_{0,05} = 1,36/\sqrt{n}$ (Bonneau, 2012; Chandy, Schifano, Yan, & Zhang, 2025).

Lección metodológica

Este análisis fallido dejó una lección importante: no siempre se llega al resultado esperado, y la idea intuitiva de una hipótesis no es suficiente para garantizar su validez empírica. Antes de comprometer recursos en la implementación de un método, es necesario estudiar en profundidad las condiciones de aplicabilidad del mismo, explorar la distribución real de los datos y revisar la literatura para identificar restricciones estructurales que puedan invalidar el enfoque desde el inicio. En este caso, una revisión más cuidadosa de los supuestos de Benford habría anticipado que un dataset de contraseñas, por su naturaleza acotada y culturalmente sesgada, no constituye el tipo de magnitudes de origen “natural” para las que la ley fue concebida.

Construcción de fichas de resultados

% ——— FICHA 1 ———

Ficha de resultado 1

Nivel descriptivo

Titular:

Nombre del hallazgo/resultado:

Resumen en una oración:

Método o análisis que lo produjo:

Evidencia:

Nivel analítico

Conexión con la pregunta de investigación:

Contraste con la literatura:

Lo que NO explica este resultado:
Implicación para el siguiente paso:
% ———- FICHA 2 ———-

Ficha de resultado 2

Nivel descriptivo

Titular:
Nombre del hallazgo/resultado:
Resumen en una oración:
Método o análisis que lo produjo:
Evidencia:

Nivel analítico

Conexión con la pregunta de investigación:
Contraste con la literatura:
Lo que NO explica este resultado:
Implicación para el siguiente paso:
% ———- FICHA 3 ———-

Ficha de resultado 3

Nivel descriptivo

Titular:
Nombre del hallazgo/resultado:
Resumen en una oración:
Método o análisis que lo produjo:
Evidencia:

Nivel analítico

Conexión con la pregunta de investigación:
Contraste con la literatura:
Lo que NO explica este resultado:
Implicación para el siguiente paso:
% ———- FICHA 4 ———-

Ficha de resultado 4

Nivel descriptivo

Titular:
Nombre del hallazgo/resultado:
Resumen en una oración:
Método o análisis que lo produjo:
Evidencia:

Nivel analítico

Conexión con la pregunta de investigación:
Contraste con la literatura:

Lo que NO explica este resultado:
Implicación para el siguiente paso:
% ———- FICHA 5 ———-

Ficha de resultado 5

Nivel descriptivo

Titular:
Nombre del hallazgo/resultado:
Resumen en una oración:
Método o análisis que lo produjo:
Evidencia:

Nivel analítico

Conexión con la pregunta de investigación:
Contraste con la literatura:
Lo que NO explica este resultado:
Implicación para el siguiente paso:
% ———- FICHA 6 ———-

Ficha de resultado 6

Nivel descriptivo

Titular:
Nombre del hallazgo/resultado:
Resumen en una oración:
Método o análisis que lo produjo:
Evidencia:

Nivel analítico

Conexión con la pregunta de investigación:
Contraste con la literatura:
Lo que NO explica este resultado:
Implicación para el siguiente paso:
% ———- FICHA 7 ———-

Ficha de resultado 7

Nivel descriptivo

Titular:
Nombre del hallazgo/resultado:
Resumen en una oración:
Método o análisis que lo produjo:
Evidencia:

Nivel analítico

Conexión con la pregunta de investigación:
Contraste con la literatura:

Lo que NO explica este resultado:
Implicación para el siguiente paso:
% ———- FICHA 8 ———-

Ficha de resultado 8

Nivel descriptivo

Titular:

Nombre del hallazgo/resultado:

Resumen en una oración:

Método o análisis que lo produjo:

Evidencia:

Nivel analítico

Conexión con la pregunta de investigación:

Contraste con la literatura:

Lo que NO explica este resultado:

Implicación para el siguiente paso:

Ordenamiento de los elementos de reporte

Elementos primarios y secundarios

Primarios	Secundarios
1. Entropía de Shannon como medida de aleatoriedad	1. Ley de Zipf en contraseñas (Wang et al., 2017)
2. Distribución de dígitos por posición (tokenización CL100K)	2. Modelos de Markov para contraseñas (Ma et al., 2014)
3. Desviación respecto a la Ley de Benford (posiciones 1 y 2)	3. Redes neuronales para predicción de contraseñas (Olsen, 2018)
4. Estructura de máscaras y su relación con entropía (KW)	4. Análisis fallido: Benford directo sobre dígitos sin tokenizar
5. Longitud como predictor de entropía (Spearman)	5. Bigramas de transición entre tipos de caracteres
6. Patrones posicionales: consonante-vocal, dígitos al final	

Table 1.2: Elementos de reporte

Ordenamiento por secciones

Sección	Temas a tratar
Introducción	1. Predecibilidad de contraseñas humanas — Keszthelyi (Primario) 2. Entropía como medida de seguridad — Bonneau (Primario) 3. Ley de Benford y datos naturales — Caputi (Primario) 4. Ley de Zipf en contraseñas — Wang et al. (Secundario)
Metodología	1. Dataset RockYou y preprocesamiento (Primario) 2. Tokenización CL100K y extracción de dígitos (Primario) 3. Prueba KS contra Benford por posición (Primario) 4. Máscaras de contraseña y entropía de Shannon (Primario) 5. Kruskal-Wallis por longitud y tipo dominante (Primario) 6. Correlación de Spearman longitud-entropía (Primario) 7. Modelos de Markov como contexto comparativo (Secundario)
Resultados	1. Posiciones 1 y 2 se desvían de Benford; posiciones 3+ coinciden por uniformidad (Primario) 2. Distribución uniforme de dígitos desde posición 3 (Primario) 3. Tipo de máscara determina nivel de entropía — KW (Primario) 4. Longitud predice entropía — Spearman (Primario) 5. Patrón consonante-vocal y dígitos al final (Primario) 6. Bigramas de transición entre tipos (Secundario)

Table 1.4: Orden de escritura del reporte

La imagen que cuenta la historia

Arco narrativo del proyecto

«El modelo reveló que _____, lo que significa que _____.»

Parte de escritura

Parte de reflexión

% Revisen y actualicen: objetivos, pregunta de investigación y demás elementos % de la UVE con toda la información recopilada hasta ahora.

Diario de aprendizaje

% 3 a 5 oraciones respondiendo: % ¿Qué saben ahora que no sabían al entregar la Bitácora #2? % Enfóquense en el proceso (¿qué fue difícil?, ¿qué salió diferente a lo planeado?), % no en los resultados técnicos.

Registro del uso de IA

% Documenten cada uso de IA con el formato de la Bitácora #1: % Herramienta / Prompt / Respuesta de la IA / Evaluación / Modificaciones / Aprendizaje

Herramienta:

Prompt:

Respuesta de la IA:

Evaluación:

Modificaciones:

Aprendizaje: