



UNIVERSIDAD DE COSTA RICA

Escuela de Matemáticas

Estadística Actuarial I (CA0303)

Bitácora #3

Prof: Maikol Solís

Estudiantes:

Anthony Flores Rojas (C32975)

Andrey González Bastos (C33329)

Randal Picado Bermúdez (C36024)

Leonardo Vega Aragón (C38313)

Fecha: 10/06/2026

Contenido

Preparación	1
Audiencia del proyecto	1
Rastro de decisiones	1
Respuesta a retroalimentación	1
Log de contribuciones	2
Parte de planificación	3
Análisis de modelación	3
Propuesta metodológica	3
Construcción de fichas de resultados	11
Ordenamiento de los elementos de reporte	24
Elementos primarios y secundarios	24
Ordenamiento por secciones	25
La imagen que cuenta la historia	26
Arco narrativo del proyecto	27
Parte de escritura	28
Parte de reflexión	46
4.0.1. V de Gowin	47
4.0.2. Conceptos Básicos	47
4.0.3. Teorías y Principios	48
4.0.4. Metodología	48
Diario de aprendizaje	50
Registro del uso de IA	51
5.0.1. Conceptos Básicos	51

Preparación

Audiencia del proyecto

Esta semana, le diría a nuestra audiencia que aplicar una tokenización con el modelo cl100k, permitió seguir mejor las distribuciones de Benford en los dígitos, solo que se cumple de la posición 3 en adelante, aún falta acomodar los datos de forma que se cumplan también en las primeras dos, este resultado se detalla más adelante.

Rastro de decisiones

No se descartó ninguna metodología, en su lugar se implementó la idea del prodfesor de tokenizar las contraseñas para poder hacer un mejor trabajo con las distribuciones de Benford de sus dígitos y con el test KS, para no perder la información de la parte de letras de las contraseñas.

Respuesta a retroalimentación

En la pasada bitácora los puntos que se nos bajaron fueron en ortografía, por lo cual para esta bitácora se tomó muchísimo más cuidado con este aspecto.

Log de contribuciones

Integrante	Tarea
Anthony Flores Rojas (C32975)	■ Parte 1.1 Depuración del código, colaboración con 1.2, diario de aprendizaje, colaboración fichas de literatura.
Andrey González Bastos (C33329)	■ 1.3 Fichas de resultados, colaboración fichas de literatura, colaboración con 1.2.
Randal Picado Bermúdez (C36024)	■ 1.4 Ordenamiento de los elementos de reporte, 1,5 La imagen que cuenta la historia, 2 Arco narrativo, colaboración con fichas de literatura.
Leonardo Vega Aragón (C38313)	■ 3 Parte de escritura, 4 Parte de reflexión, colaboración con fichas de literatura.

Table 1: Log de contribuciones — Bitácora #3

Parte de planificación

Análisis de modelación

En esta parte del trabajo todo se basó en mejorar el código hecho hasta el momento, el mismo se puede ver en el git, más específicamente en la carpeta código (03_modelacion.py).

Propuesta metodológica

1.2 Propuesta Metodológica

Pregunta de investigación

¿En qué medida los patrones estructurales de las contraseñas del dataset RockYou - su composición de caracteres, longitud y distribución de dígitos - determinan su nivel de entropía y evidencian que los usuarios no eligen contraseñas de forma aleatoria?

Tokenización CL100K sobre las contraseñas

Motivación

El tokenizador CL100K usado por GPT-4 transforma cada texto en un vector de embeddings de dimensión alta. Cuando se calcula la norma del vector de tokenización de una contraseña, el resultado es un número real que contiene una distribución de dígitos en cada posición. Si los dígitos presentes en estas normas se desvían de la distribución de Benford, existe evidencia de que los usuarios eligen contraseñas con patrones sistemáticos que el modelo-tokenizador captura de manera predecible, lo que implica vulnerabilidad en la representación interna. Se utiliza la tokenización, ya que es una transformación relativamente “natural” del lenguaje humano a dígitos, dado que el tokenizador CL100K fue entrenado sobre datos reales de uso humano según los análisis publicados por OpenAI, lo que permite detectar si los patrones de elección de contraseñas se preservan en la representación interna del modelo.

Tokenización CL100K y norma elegida

Sea c una contraseña del conjunto de datos $\mathcal{C}$. El tokenizador CL100K la transforma en un vector de embeddings:

$$\text{CL100K}(c) = \mathbf{v}_c = (v_1, v_2, \dots, v_d) \in \mathbb{R}^d, \quad (1.1)$$

donde d es la dimensión del embedding (típicamente $d \approx 100,000$ para CL100K).

Se elige la norma de valor absoluto del vector

$$\|\mathbf{v}_c\|_1 = \sum_{i=1}^d |v_i| \in \mathbb{R}_{\geq 0}. \quad (1.2)$$

Esta norma fue elegida simplemente por su interpretación directa como la suma total de las magnitudes de las componentes del vector de tokenización, lo que permite extraer la distribución de dígitos en cada posición del número resultante.

Para cada $\|\mathbf{v}_c\|_1$, se extrae el dígito en la posición n

$$D_n(\|\mathbf{v}_c\|_1) = \left\lfloor \frac{\|\mathbf{v}_c\|_1}{10^{n-1}} \right\rfloor \bmod 10, \quad n \in \{1, 2, \dots, N_{\max}\}, \quad (1.3)$$

donde $N_{\max}$ es el número de dígitos de $\|\mathbf{v}_c\|_1$.

Prueba de Kolmogorov-Smirnov contra la distribución de Benford

Motivación

La Ley de Benford establece que en conjuntos de datos numéricos de origen “natural”, el dígito d ocupa la primera posición con una frecuencia predecible (Caputi Zunini, 2019). Si los dígitos presentes en contraseñas reales se desvían de esa distribución, existe evidencia de que los usuarios eligen números con sesgos sistemáticos, lo que implica predecibilidad y, en consecuencia, vulnerabilidad. Se elige la prueba KS (y no una chi-cuadrado) porque compara funciones de distribución acumulada completas sin requerir agrupar celdas; con muestras en el orden de millones, la chi-cuadrado infla el estadístico por el tamaño de n sin aportar información sobre la forma de la desviación (Chandola, Banerjee, & Kumar, 2009; Chandy, Schifano, Yan, & Zhang, 2025).

Distribución teórica de Benford generalizada

Sea $(D_n \in \{1, \dots, 9\})$ el dígito en la posición (n) -ésima, entonces la PDF de Benford para $(n=1)$ es

$$\mathbb{P}(\{D_1 = d\}) = \log_{10} \left(1 + \frac{1}{d} \right) \quad (1.4)$$

Para posiciones $n \geq 2$, la fórmula generalizada integra sobre todos los prefijos de longitud $n - 1$, siendo esta

$$\mathbb{P}(\{D_n = d\}) = \sum_{k=10^{n-2}}^{10^{n-1}-1} \log_{10} \left(1 + \frac{1}{10k + d} \right), \quad d \in \{0, 1, \dots, 9\} \quad (1.5)$$

Estadístico KS

Sea $F_n(x)$ la función de distribución acumulada empírica de los dígitos en la posición p y $F_0(x)$ la CDF teórica de Benford. El estadístico Kolmogorov-Smirnov es

$$D_n = \sup_x |F_n(x) - F_0(x)| \quad (1.6)$$

Distribución límite y valor crítico

Kolmogorov (1933) demostró que, bajo H_0 simple (distribución teórica completamente especificada sin parámetros estimados), el estadístico escalado converge en distribución

$$\sqrt{n} D_n \xrightarrow{d} K, \quad n \rightarrow \infty \quad (1.7)$$

donde K es la **distribución de Kolmogorov**, cuya CDF admite la representación en serie

$$P(K \leq t) = 1 - 2 \sum_{j=1}^{\infty} (-1)^{j-1} e^{-2j^2 t^2} \quad (1.8)$$

Para valores de t no demasiado pequeños, el primer término domina y la aproximación de un término es suficiente

$$P(K > t) \approx 2e^{-2t^2} \quad (1.9)$$

El cuantil crítico t_α se obtiene igualando la expresión anterior a α y despejando

$$2e^{-2t_\alpha^2} = \alpha \implies t_\alpha = \sqrt{-\frac{1}{2} \ln(\frac{\alpha}{2})} \quad (1.10)$$

Para $\alpha = 0,05$ (el alpha escogido)

$$t_{0,05} = \sqrt{-\frac{1}{2} \ln(0,025)} = \sqrt{\frac{3,6889}{2}} = \sqrt{1,8444} \approx 1,3581 \quad (1.11)$$

Dado que la distribución límite es la de $\sqrt{n} D_n$, el valor crítico sobre el estadístico muestral es

$$D_\alpha = \frac{t_\alpha}{\sqrt{n}} \implies D_{0,05} = \frac{1,36}{\sqrt{n}} \quad (1.12)$$

Se rechaza H_0 (los dígitos siguen Benford) cuando $D_n > D_\alpha$. Dado que $n \sim 10^6$, el umbral D_α es extremadamente pequeño, por lo que se complementa el resultado con la desviación absoluta media (MAD)

$$\text{MAD} = \frac{1}{|\mathcal{D}|} \sum_{d \in \mathcal{D}} |\mathbb{P}_{\text{emp}}(d) - \mathbb{P}_{\text{Benford}}(d)| \quad (1.13)$$

donde $\mathcal{D}$ es el conjunto de dígitos válidos para la posición dada. Los umbrales de conformidad son $\text{MAD} < 0,006$ (muy cercana), $0,006$ – $0,012$ (aceptable), $0,012$ – $0,015$ (marginal)

y $> 0,015$ (no conformidad) (Negrini, 2012).

Conexión con la pregunta de investigación

Si KS rechaza H_0 y MAD indica no conformidad, los dígitos de las contraseñas presentan sesgos sistemáticos respecto a una distribución numéricamente “natural”.

Análisis de distribución de máscaras de contraseña

Motivación

Las contraseñas humanas no son cadenas aleatorias, los usuarios exhiben patrones estructurales sistemáticos al elegirlos. Para capturar esa estructura sin depender del contenido semántico de cada contraseña, se utiliza una representación de máscara, que abstrae cada carácter a su tipo. Formalmente, dado el alfabeto de tipos $\Sigma = \{L, U, D, S\}$ (minúsculas, mayúsculas, dígitos, caracteres especiales), la máscara de una contraseña $P = c_1 c_2 \dots c_n$ es

$$M(P) = \tau(c_1) \tau(c_2) \dots \tau(c_n), \quad \tau(c) = \begin{cases} L & c \in \mathcal{L} \\ U & c \in \mathcal{U} \\ D & c \in \mathcal{D} \\ S & c \in \mathcal{S} \end{cases} \quad (1.14)$$

Se elige esta representación y no, por ejemplo, n -gramas de caracteres, porque permite cuantificar la predecibilidad estructural independientemente del vocabulario léxico. Si pocas máscaras concentran la mayor parte de las contraseñas, el espacio de búsqueda efectivo es mucho menor que el espacio teórico, lo que constituye evidencia directa de vulnerabilidad sistemática.

Patrones comprimidos

Para reducir el espacio de máscaras sin perder información sobre la composición, se aplica una codificación de longitud de racha (*run-length encoding*) sobre $M(P)$. Sea $M(P) = t_1^{r_1} t_2^{r_2} \dots t_k^{r_k}$ la descomposición en rachas consecutivas del mismo tipo, entonces el patrón comprimido es

$$R(P) = t_1 r_1 \ t_2 r_2 \ \dots \ t_k r_k \quad (1.15)$$

Por ejemplo, la máscara LLLLLLDD se comprime a L6D2. Esta representación agrupa contraseñas con la misma composición por bloques, lo que facilita el análisis de patrones frecuentes en el dataset. La distribución de patrones comprimidos se analiza por frecuencia absoluta f_j y proporción relativa $\hat{p}_j = f_j/N$, donde N es el total de contraseñas.

Conexión con la pregunta de investigación

Si la distribución de máscaras está fuertemente concentrada, se confirma que los usuarios eligen contraseñas con patrones estructurales predecibles. Esto responde la pregunta de

investigación en su dimensión composicional: no solo los dígitos siguen sesgos (KS vs. Benford), sino que la estructura completa de la contraseña es predecible antes de conocer un solo carácter.

Entropía de Shannon y de densidad de contraseñas individuales

Motivación

A diferencia de los análisis de distribución a nivel de dataset, la entropía de una contraseña individual cuantifica la incertidumbre interna de su composición, cuán mezclados están los tipos de carácter que la conforman. Se elige la entropía de Shannon (Khan & Wunder, 2024) sobre la distribución de tipos dentro de la contraseña porque es una medida establecida de incertidumbre que no requiere conocer el vocabulario léxico del usuario, es calculable en tiempo $O(|P|)$, y es interpretable directamente como bits de información. Frente a métricas de fuerza basadas en combinatoria ($\log_2 |\mathcal{K}|^{|P|}$), que solo dependen del espacio de caracteres y la longitud, la entropía de Shannon captura además la diversidad de tipos usados dentro de la contraseña.

Definición

Entropía de Shannon

Sea P una contraseña y sea p_t la proporción del tipo $t \in \Sigma$ en P . La entropía de Shannon de P es

$$H_S(P) = - \sum_{t \in \Sigma} p_t \log_2 p_t \quad (1.16)$$

Entropía de densidad

Complementariamente, se define la entropía de densidad como la entropía de Shannon normalizada por la longitud de la contraseña

$$H_D(P) = \frac{H_S(P)}{|P|} \quad (1.17)$$

H_D penaliza las contraseñas largas pero uniformes (e.g., `aaaaaaaaaa` tiene $H_S = 0$ independientemente de la longitud) y premia aquellas con alta diversidad por carácter. Esta métrica está relacionada con la *Expectation entropy* propuesta por Khan & Wunder (2024), que escala la información de composición por el espacio máximo posible del alfabeto; ambas buscan capturar la fortaleza de la contraseña en una escala normalizada.

Conexión con la pregunta de investigación

Las estructuras internas repetitivas dentro de las contraseñas son penalizadas por ambas métricas de entropía: H_S captura la falta de diversidad entre tipos de carácter, mientras que H_D la penaliza adicionalmente en función de la longitud. Contraseñas con entropías bajas presentan menor incertidumbre interna y, por lo tanto, mayor predecibilidad desde la

perspectiva del atacante. Este resultado se complementa con la prueba de Kruskal-Wallis, que permite determinar si la estructura de la máscara discrimina significativamente el nivel de entropía observado.

Prueba de Kruskal-Wallis sobre entropías por grupo

Motivación

Se busca determinar si la estructura de la máscara (longitud y tipo dominante de caracteres) discrimina el nivel de entropía. Se elige Kruskal-Wallis (KW) en lugar de ANOVA de un factor porque

- Las distribuciones de entropía por grupo no son normales (asimétricas, con colas largas), como se verifica en el análisis descriptivo.
- KW es una prueba no paramétrica de rangos que no asume homocedasticidad ni normalidad dentro de los grupos.

Entropía de Shannon de una máscara

La entropía media de la máscara m se define como en la ecuación~(1.16), donde $\Sigma = \{L, U, D, S\}$ es el alfabeto de tipos de carácter (minúsculas, mayúsculas, dígitos, símbolos) y p_c es la proporción del tipo c en m .

Estadístico de Kruskal-Wallis

Dadas k muestras independientes de tamaños $n_1, \dots, n_k$ con $N = \sum_{i=1}^k n_i$ observaciones totales, el estadístico es

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1) \quad (1.18)$$

donde R_i es la suma de rangos del grupo i sobre el ranking global. Bajo H_0 (todas las distribuciones son iguales), $H \sim \chi_{k-1}^2$ para muestras grandes.

Ponderación por frecuencia

Como cada máscara m_j tiene una frecuencia f_j (número de contraseñas reales que la usan), se expande la muestra repitiendo cada observación con su frecuencia real:

$$\tilde{n}_j = f_j \quad (1.19)$$

Para garantizar la reproducibilidad del proyecto, la implementación incluye un parámetro de tope C configurable

$$\tilde{n}_j = \min(f_j, C) \quad (1.20)$$

En este trabajo se fija $C = 10\,000\,000$, valor que excede la frecuencia máxima observada en el dataset RockYou ($f_{\text{máx}} = L6$ con 3 996 634 observaciones), por lo que el tope es inactivo

y se cumple $\tilde{n}_j = f_j$ para toda máscara m_j . El vector de rangos reproduce así fielmente la distribución real del dataset.

Agrupaciones evaluadas

Se aplica KW bajo tres criterios de agrupación

1. Longitud de máscara: grupos $g \in \{1, 2, \dots, L_{\text{máx}}\}$ donde $L_{\text{máx}}$ es la longitud máxima observada.
2. Tipo dominante: Solo L, Solo D, Solo U, Solo S, Mixta.
3. Rango de entropía: bajo ($H < 2,4464$, por debajo del percentil 25), medio ($2,4464 \leq H < 2,9477$, entre los percentiles 25 y 75) y alto ($H \geq 2,9477$, por encima del percentil 75). Este agrupamiento es descriptivo, no inferencial, pues la variable de agrupación coincide con la variable de respuesta.

Conexión con la pregunta de investigación

Si KW rechaza H_0 en los criterios de longitud y tipo dominante, se confirma que la estructura de la máscara predice significativamente la entropía. Esto implica que conocer el patrón de una contraseña reduce la incertidumbre sobre su espacio de búsqueda, respondiendo la pregunta en su dimensión estructural.

Correlación de Spearman entre longitud y entropía

Motivación

KW indica si los grupos difieren, pero no cuantifica la dirección ni la fuerza de la relación entre longitud y entropía. Se elige el coeficiente de Spearman (y no Pearson) porque

- La relación puede ser monótona pero no lineal: la entropía puede estabilizarse a partir de cierta longitud.
- Spearman es robusto ante outliers y no asume normalidad bivariada.
- Es equivalente a Pearson aplicado sobre los rangos, lo que lo hace válido para datos ordinales y distribuciones sesgadas.

Coeficiente de Spearman

Sea $\{(\ell_j, h_j)\}_{j=1}^n$ el conjunto de pares (longitud de máscara, entropía media). El coeficiente de correlación de Spearman se calcula sobre los rangos $\{(r_j^\ell, r_j^h)\}$

$$\rho_s = 1 - \frac{6 \sum_{j=1}^n d_j^2}{n(n^2 - 1)}, \quad d_j = r_j^\ell - r_j^h \quad (1.21)$$

O, equivalentemente, como el coeficiente de Pearson de los rangos

$$\rho_s = \frac{\sum_{j=1}^n (r_j^\ell - \bar{r}^\ell)(r_j^h - \bar{r}^h)}{\sqrt{\sum_{j=1}^n (r_j^\ell - \bar{r}^\ell)^2} \sqrt{\sum_{j=1}^n (r_j^h - \bar{r}^h)^2}} \quad (1.22)$$

Variantes de cálculo

Se calculan dos versiones para verificar robustez

$$\rho_{\text{raw}} = \rho_s(\{\ell_j\}, \{h_j\}) \quad (1.23)$$

$$\rho_{\text{pond}} = \rho_s(\{\ell_j^*\}, \{h_j^*\}), \quad \text{donde } |\{j^* : \ell_{j^*} = \ell_j\}| = \min(f_j, C') \quad (1.24)$$

con $C' = 200\,000$. Si $\rho_{\text{raw}} \approx \rho_{\text{pond}}$, la correlación es robusta a la distribución de frecuencias.

Interpretación del tamaño del efecto

$$|\rho_s| \in \begin{cases} [0,7, 1,0] & \text{correlación fuerte} \\ [0,4, 0,7) & \text{correlación moderada} \\ [0,0, 0,4) & \text{correlación débil} \end{cases} \quad (1.25)$$

Conexión con la pregunta de investigación

Un ρ_s alto y positivo confirma que contraseñas más largas son estadísticamente más entrópicas, lo que respalda con evidencia cuantitativa la recomendación de longitud mínima en políticas de seguridad. Complementa KW al ofrecer una medida continua de la relación: no solo se sabe que los grupos difieren, sino cuánto y en qué dirección.

Análisis fallido: Ley de Benford sobre dígitos numéricos de contraseñas

Descripción del intento

Se intentó aplicar la Ley de Benford directamente sobre la distribución de los dígitos numéricos presentes en las contraseñas y sus subcadenas (*chunks*) numéricos, con la hipótesis de que, al tratarse de un conjunto masivo de datos generado por comportamiento humano, los primeros dígitos seguirían la distribución logarítmica característica de Benford.

Por qué no funcionó

La aplicación resultó inválida por razones tanto empíricas como teóricas. La distribución de caracteres numéricos en datasets de contraseñas no cumple las condiciones de aplicabilidad

de la Ley de Benford por varias razones estructurales:

- **Patrones de fechas:** Una fracción significativa de los componentes numéricos corresponde a años (ej. 1990, 2003), meses y días, cuya distribución de primeros dígitos está acotada artificialmente (los años modernos comienzan casi todos con 1 o 2, los meses con 0 o 1).
- **Restricciones de longitud:** Las políticas de contraseñas imponen longitudes mínimas y máximas que truncan el espacio numérico disponible, eliminando la variación de varios órdenes de magnitud que Benford requiere para operar.
- **Sesgos cognitivos del usuario:** Los usuarios concentran sus elecciones en números redondos, secuencias simples (123, 000) y años de nacimiento, lo que produce una distribución de primeros dígitos fuertemente no uniforme pero tampoco logarítmica.

Esto fue confirmado tanto mediante la revisión de la literatura especializada como mediante la comparación entre la distribución empírica observada y la distribución teórica de Benford usando el estadístico KS, el cual rechazó H_0 con un valor de D_n muy superior al umbral crítico $D_{0,05} = 1,36/\sqrt{n}$ (Bonneau, 2012; Chandy, Schifano, Yan, & Zhang, 2025).

Lección metodológica

Este análisis fallido dejó una lección importante: no siempre se llega al resultado esperado, y la idea intuitiva de una hipótesis no es suficiente para garantizar su validez empírica. Antes de comprometer recursos en la implementación de un método, es necesario estudiar en profundidad las condiciones de aplicabilidad del mismo, explorar la distribución real de los datos y revisar la literatura para identificar restricciones estructurales que puedan invalidar el enfoque desde el inicio. En este caso, una revisión más cuidadosa de los supuestos de Benford habría anticipado que un dataset de contraseñas, por su naturaleza acotada y culturalmente sesgada, no constituye el tipo de magnitudes de origen “natural” para las que la ley fue concebida.

Construcción de fichas de resultados

———— FICHA 1 ————

Nivel descriptivo (¿qué encontraron?)

Titular

No se cumple similitud en las distribuciones con tokenización en la posición 1.

Nombre del hallazgo/resultado

KS y Benford no concuerdan en la primera posición de las contraseñas tokenizadas con cl100k base.

Resumen en una oración

Para la primera posición de la contraseña, se cumple Benford teóricamente pero no lo suficiente para pasar el test KS.

Método o análisis que lo produjo

Se usó la tokenización con base cl100k, para tener mayor control de la parte de letras y de números al mismo tiempo, se le aplicó el test KS y se descubrió que sigue una distribución similar a la Benford teórica, al menos en la posición 1, pero no lo suficiente para pasar el test KS, por lo que se rechaza H_0 .

Evidencia




Figure 1.1: KS y Benford para posición 1 con contraseñas tokenizadas

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre cómo se distribuyen los dígitos en las posiciones, en este caso, la posición 1 en las contraseñas siguen Benford, no lo suficiente para pasar KS, por lo que vemos que las claves no son tan aleatorias como parecen.

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a Benford de María Caputi (2019), sobre el test KS (Chandy, et.al, 2025) que nos ayudó a comprobar la distribución en este caso para la posición 1.

Lo que NO explica este resultado

Este resultado claramente NO explica que todas las posiciones se rijan bajo ley de Benford y que no se cumpla el test KS, este resultado solo nos guía para la posición 1.

Implicación para el siguiente paso

Nos toca averiguar si esto mismo se cumple para las siguientes posiciones en las contraseñas del dataset de RockYou.

———— FICHA 2 ————

Nivel descriptivo (¿qué encontraron?)

Titular

No se cumple similitud en las distribuciones con tokenización en la posición 2.

Nombre del hallazgo/resultado

KS y Benford no concuerdan en la segunda posición de las contraseñas tokenizadas con cl100k base.

Resumen en una oración

Para la segunda posición de la contraseña, no concuerdan KS y Benford.

Método o análisis que lo produjo

Se usó la tokenización con base cl100k, para tener mayor control de la parte de letras y de números al mismo tiempo, se le aplicó el test KS y se descubrió que sigue una distribución similar a la Benford teórica, al menos en la posición 2, pero no lo suficiente para lograr pasar el test KS, por lo cual se rechaza H_0 .

Evidencia

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre cómo se distribuyen los dígitos en las posiciones, en este caso, la posición 2 en las contraseñas siguen Benford, no pasando KS, por lo que vemos que las claves no son tan aleatorias como parecen.




Figure 1.2: KS y Benford para posición 2 con contraseñas tokenizadas

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a Benford de María Caputi (2019), sobre el test KS (Chandy, et.al, 2025) que nos ayudó a comprobar la distribución en este caso para la posición 2.

Lo que NO explica este resultado

Este resultado claramente NO explica que todas las posiciones se rijan bajo ley de Benford y que no se cumpla el test KS, este resultado solo nos guía para la posición 2.

Implicación para el siguiente paso

Nos toca averiguar si esto mismo se cumple para las siguientes posiciones en las contraseñas del dataset de RockYou.

———— FICHA 3 ————

Nivel descriptivo (¿qué encontraron?)

Titular

Se cumple similitud en las distribuciones con tokenización en la posición 3.

Nombre del hallazgo/resultado

Se puede afirmar KS y Benford en la tercera posición de las contraseñas tokenizadas con cl100k base.

Resumen en una oración

Para la tercera posición de la contraseña tokenizada, se sigue Benford.

Método o análisis que lo produjo

Se usó la tokenización con base cl100k base, para tener mayor control de la parte de letras y de números al mismo tiempo, se le aplicó el test KS y se descubrió que se sigue una distribución similar a la Benford teórica, al menos en la posición 3.

Evidencia




Figure 1.3: KS y Benford para posición 3 con contraseñas tokenizadas

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre cómo se distribuyen los dígitos en las posiciones, en este caso, la posición 3 en las contraseñas siguen Benford, comprobado con KS.

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a Benford de María Caputi (2019), sobre el test KS (Chandy, et.al, 2025) que nos ayudó a comprobar la distribución en este caso para la posición 3.

Lo que NO explica este resultado

Este resultado claramente NO explica que todas las posiciones se rijan bajo ley de Benford, este resultado solo nos guía para la posición 3.

Implicación para el siguiente paso

Nos toca averiguar si esto mismo se cumple para las siguientes posiciones en las contraseñas del dataset de RockYou.

———— FICHA 4 ————

Nivel descriptivo (¿qué encontraron?)

Titular

Se cumple similitud en las distribuciones con tokenización en la posición 4.

Nombre del hallazgo/resultado

Se puede afirmar KS y Benford en la cuarta posición de las contraseñas tokenizadas con cl100k base.

Resumen en una oración

Para la cuarta posición de la contraseña tokenizada, se sigue Benford.

Método o análisis que lo produjo

Se usó la tokenización con base cl100k base, para tener mayor control de la parte de letras y de números al mismo tiempo, se le aplicó el test KS y se descubrió que se sigue una distribución similar a la Benford teórica, al menos en la posición 4.

Evidencia

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre cómo se distribuyen los dígitos en las posiciones, en este caso, la posición 4 en las contraseñas tokenizadas siguen Benford, comprobado con KS.




Figure 1.4: KS y Benford para posición 4 con contraseñas tokenizadas

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a Benford de María Caputi (2019), sobre el test KS (Chandy, et.al, 2025) que nos ayudó a comprobar la distribución en este caso para la posición 4.

Lo que NO explica este resultado

Este resultado claramente NO explica que todas las posiciones se rijan bajo ley de Benford, este resultado solo nos guía para la posición 4.

Implicación para el siguiente paso

Nos toca averiguar si esto mismo se cumple para las siguientes posiciones en las contraseñas del dataset de RockYou.

Comparación explícita

Para la posición 3 en adelante, se descubrió que todas las posiciones siguen Benford comprobado con KS, resultado inesperado pues se venía sin poder seguir en las posiciones anteriores (1) y (2) respectivamente. Esto es un resultado curioso, pues esperábamos que en todas las posiciones se cumpliera Benford y no solo a partir de la tercera posición en adelante.

Esto sucede pues aunque la posición 1 y 2 “siguen Benford”, no lo hacen de forma que también se pase el test KS. Esto último es sumamente importante y aquí recae la magia de todo, que no basta con parecer que la siga, sino que se tiene que acoplar también a pasar por test formales para poder efectivamente comprobarlo y no hacerlo simplemente a ojo.

Sin embargo, esta discrepancia hace que se tengan que buscar nuevos métodos de tokenización o de manipulación de los mismos para ver si en algún caso o uso se sigue Benford como se cree según la literatura (en todas las posiciones).

Nivel descriptivo (¿qué encontraron?)

Titular

Las máscaras determinan mucho la entropía.

Nombre del hallazgo/resultado

Distribuciones de la entropía según la máscara que se haya utilizado.

Resumen en una oración

Los cinco tipos de máscara producen distribuciones de entropía completamente diferentes.

Método o análisis que lo produjo

Se usó la prueba de Kruskal-Wallis sobre entropías, se separaron las máscaras de la siguiente forma: Mixta, solo dígitos, solo letras, solo caracteres especiales o solo mayúsculas. Usando para las entropías los siguientes rangos: bajo ($H < 2.4464$), medio ($2.4464 \leq H < 2.9477$), alto ($H \geq 2.9477$). Este agrupamiento es descriptivo, no inferencial, pues la variable de agrupación coincide con la variable de respuesta.

Evidencia




Figure 1.5: Kruskal-Wallis - Entropía por tipo de máscara

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre las entropías (desordenes) en las contraseñas, en este caso ahora sabemos que la entropía varía según cómo esté hecha la contraseña, si es mixta con todo posee una alta entropía como es esperado y si es solo de caracteres especiales pues tiende a tener una menor entropía.

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a la prueba de KW de los autores de APS 240, paper donde se explica como aplicar este test para resultados como el obtenido anteriormente.

Lo que NO explica este resultado

Este resultado no nos arroja la aleatoriedad de las contraseñas o si son naturales, simplemente nos arroja el resultado de diferentes entropías según queramos tener diferentes estructuras de contraseñas.

Implicación para el siguiente paso

Nos toca averiguar si este resultado nos ayuda a determinar la aleatoriedad de las contraseñas que los usuarios escogen.

————- FICHA 6 ————

Nivel descriptivo (¿qué encontraron?)

Titular

Las longitudes de las contraseñas determinan su entropía.

Nombre del hallazgo/resultado

Las máscaras según la longitud de la contraseña determina su entropía.

Resumen en una oración

A mayor longitud de la contraseña, mayor entropía se espera según el test Kruskal-Wallis.

Método o análisis que lo produjo

Se usó la prueba de Kruskal-Wallis sobre entropías, se separaron las máscaras de la siguiente forma: según la longitud de la máscara.

Evidencia




Figure 1.6: Kruskal-Wallis - Entropía por longitud de máscara

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre las entropías (desordenes) en las contraseñas, en este caso ahora sabemos que la entropía es creciente según la longitud, lo cual es un resultado esperado pero se debía comprobar.

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a la prueba de KW de los autores de APS 240, paper donde se explica como aplicar este test para resultados como el obtenido anteriormente. También, se ve como la entropía tiene que ver con la seguridad de las contraseñas, tal como lo planteó Reaz(2024), el cual planteaba que a una mayor entropía, más complicado es de predecir el valor de una observación, en este caso, de una contraseña.

Lo que NO explica este resultado

Este resultado no nos arroja la aleatoriedad de las contraseñas o que tan seguras son, simplemente nos arroja el resultado de diferentes entropías según la longitud de las mismas.

Implicación para el siguiente paso

Nos toca averiguar si este resultado nos ayuda a determinar la aleatoriedad de las contraseñas que los usuarios escogen.

———— FICHA 7 ————

Nivel descriptivo (¿qué encontraron?)

Titular

Las probabilidades de aparecer tienden a ser las mismas en dado momento.

Nombre del hallazgo/resultado

Distribución empírica de dígitos por posición (análisis descriptivo).

Resumen en una oración

Después de la posición 3, las probabilidades de que un dígito salga es casi uniforme.

Método o análisis que lo produjo

Se realizó un análisis descriptivo de los datos de RockYou para poder determinar la distribución empírica de los dígitos por posición.

Evidencia




Figure 1.7: Distribución empírica de dígitos por posición

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre como se distribuyen los dígitos por posición en las contraseñas, esto nos puede dar una pista de como las personas escogen los dígitos según la posición, se ve claramente como el que más varía es la primera posición, por lo que podemos concluir que esa posición es la más vulnerable a cambios según el usuario, la segunda también, después de eso, vemos como los cambios en los dígitos casi se puede asegurar que lleva una distribución uniforme y su probabilidad “de salir” es igual independientemente del dígito escogido. Todo esto nos ayuda a comprender mejor como los usuarios crean sus contraseñas y que tan aleatorias pueden llegar a ser.

Contraste con la literatura

Este hallazgo es propio y característico de la base de datos seleccionada, sin embargo, para la primera posición, se puede inferir como se cumple la ley de Benford y de hecho es un resultado de una ficha anterior, por lo que esto nos alimenta la creencia de que las claves siguen Benford pero hay que comprobarlo, esto ligado a la literatura de Caputi(2019).

Lo que NO explica este resultado

Este resultado no nos arroja la aleatoriedad de las contraseñas o que dígitos se usan más que otros o como las contraseñas son escritas, solo nos denota la probabilidad de obtener cierto dígito en n posición.

Implicación para el siguiente paso

Ahora sigue hacer más análisis exploratorio para ver como podemos acomodar las demás posiciones a la ley de Benford o algo por el estilo.

————- FICHA 8 —————

Nivel descriptivo (¿qué encontraron?)

Titular

Es súper probable pasar de una letra a otra en una contraseña.

Nombre del hallazgo/resultado

Biogramas de transición entre tipos de caracteres.

Resumen en una oración

Según la matriz, es muy probable pasar de una letra a otra, seguido de dígito a dígito.

Método o análisis que lo produjo

Se realizó un conteo y se calculó la probabilidad para cada transición con la muestra total. Se tienen 4x4 contadores que van contando las probabilidades.

Evidencia




Figure 1.8: Biograma de transición entre tipos

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

La matriz anterior nos permite comprender mejor como se van construyendo las contraseñas de parte de los usuarios. Vemos como es sumamente probable pasar de una letra

a otra, también, es muy probable pasar de un dígito a otro, entonces podemos concluir un comportamiento de orden de parte de las contraseñas, donde por ejemplo es sumamente raro saltar de un caracter especial a otro. Esto nos puede ayudar a entender y modelar mejor la aleatoriedad de las contraseñas para así contestar la pregunta de investigación.

Contraste con la literatura

Este hallazgo es propio y característico de la base de datos seleccionada, sin embargo, lo podemos asociar al concepto de entropía estudiado por Reaz(2024) el cual nos plantea que la entropía es como una medida del orden, lo cual vemos que se puede entender con esta matriz ya que se tiende a seguir un orden natural saltando entre el mismo tipo de caracteres.

Lo que NO explica este resultado

Este resultado no dice como se distribuyen las contraseñas, este resultado únicamente nos explica un poco el orden que se sigue al momento de crearlas para nosotros poder entender un poco mejor el concepto de entropía aplicado acá.

Implicación para el siguiente paso

Ahora nos toca medir mejor la entropía con métodos más rigurosos.

Ordenamiento de los elementos de reporte

Elementos primarios y secundarios

Primarios	Secundarios
1. Entropía de Shannon como medida de aleatoriedad	1. Ley de Zipf en contraseñas (Wang et al., 2017)
2. Distribución de dígitos por posición (tokenización CL100K)	2. Modelos de Markov para contraseñas (Ma et al., 2014)
3. Desviación respecto a la Ley de Benford (posiciones 1 y 2)	3. Redes neuronales para predicción de contraseñas (Olsen, 2018)
4. Estructura de máscaras y su relación con entropía (KW)	4. Análisis fallido: Benford directo sobre dígitos sin tokenizar
5. Longitud como predictor de entropía (Spearman)	5. Bigramas de transición entre tipos de caracteres
6. Patrones posicionales: consonante-vocal, dígitos al final	

Table 1.2: Elementos de reporte

Ordenamiento por secciones

Sección	Temas a tratar
Introducción	1. Predecibilidad de contraseñas humanas — Keszthelyi (Primario) 2. Entropía como medida de seguridad — Bonneau (Primario) 3. Ley de Benford y datos naturales — Caputi (Primario) 4. Ley de Zipf en contraseñas — Wang et al. (Secundario)
Metodología	1. Dataset RockYou y preprocesamiento (Primario) 2. Tokenización CL100K y extracción de dígitos (Primario) 3. Prueba KS contra Benford por posición (Primario) 4. Máscaras de contraseña y entropía de Shannon (Primario) 5. Kruskal-Wallis por longitud y tipo dominante (Primario) 6. Correlación de Spearman longitud-entropía (Primario) 7. Modelos de Markov como contexto comparativo (Secundario)
Resultados	1. Posiciones 1 y 2 se desvían de Benford; posiciones 3+ coinciden por uniformidad (Primario) 2. Distribución uniforme de dígitos desde posición 3 (Primario) 3. Tipo de máscara determina nivel de entropía — KW (Primario) 4. Longitud predice entropía — Spearman (Primario) 5. Patrón consonante-vocal y dígitos al final (Primario) 6. Bigramas de transición entre tipos (Secundario)

Table 1.4: Orden de escritura del reporte

La imagen que cuenta la historia

El gráfico elegido como la visualización más poderosa del proyecto es el de KS y Benford para la posición 1 de las contraseñas tokenizadas con CL100K. Se eligió este gráfico porque es el que mejor ilustra la tensión central del proyecto: los usuarios muestran una tendencia decreciente en la elección de dígitos en las primeras posiciones, similar a Benford, pero sin cumplir las proporciones exactas que la ley predice. En la posición 1 se observa que las barras empíricas tienen la forma decreciente característica de Benford, donde el dígito 1 es el más frecuente y la frecuencia va bajando, pero las alturas no coinciden con suficiente precisión como para pasar el test KS. Esto significa que los humanos tienen preferencias propias al elegir dígitos que se acercan pero no llegan a seguir una distribución natural como Benford, lo cual es evidencia de una predictibilidad parcial pero real. A diferencia de las posiciones 3 y 4, donde tanto la distribución empírica como Benford son casi completamente planas y por eso coinciden, la posición 1 muestra una estructura más rica e informativamente más valiosa. Alguien que viera únicamente esta imagen podría concluir que las contraseñas no son completamente aleatorias en sus primeras posiciones, y que existe una tendencia sistemática en cómo los usuarios eligen sus dígitos iniciales. Esa tendencia, aunque no perfectamente benfordiana, es suficiente para distinguir contraseñas humanas de secuencias verdaderamente aleatorias. Desde la Bitácora #2, la comprensión del problema ha evolucionado considerablemente: antes se analizaban los dígitos sin tokenizar, pero ahora con la tokenización CL100K se puede separar el comportamiento por posición y ver que el patrón humano se concentra en las primeras posiciones. A partir de la posición 3, la distribución empírica se vuelve casi uniforme y coincide con lo que Benford predice para esas posiciones, simplemente porque ambas convergen hacia la uniformidad. Este contraste entre posiciones tempranas y tardías es lo que hace al gráfico de posición 1 narrativamente indispensable: es donde la huella humana es más visible y más explotable. El hecho de que el patrón se diluya progresivamente a lo largo de la contraseña abre preguntas importantes sobre en qué posiciones concentrar el análisis para maximizar la detección de predictibilidad. Si este gráfico fuera la portada del artículo, contaría la historia de que las contraseñas humanas llevan una firma estadística en sus primeras posiciones, imperfecta pero detectable, que las distingue de una secuencia verdaderamente aleatoria. Esa firma, identificada mediante tokenización CL100K y la prueba KS, es el aporte central de este proyecto al análisis de seguridad de contraseñas.

Arco narrativo del proyecto

El modelo reveló que las contraseñas del dataset RockYou siguen patrones predecibles en la distribución de sus caracteres por posición y que su nivel de entropía depende tanto de esa distribución como de la longitud de la contraseña, lo que significa que los usuarios no eligen contraseñas de forma aleatoria y que la tokenización CL100K es una herramienta efectiva para traducir esos patrones del lenguaje escrito hacia una representación numérica.

Parte de escritura

Historia de los autores vs nuestra historia

Aquí seguimos la instrucción *Copie todo el bloque de texto que hicieron en la Bitácora 2 o el que usaron como Marco Teórico en el Ante proyecto. Luego copie todos los resúmenes que han hecho de las fichas de resultados de la Bitácora 3*

Tokenization counts: the impact of tokenization on arithmetic in frontier LLMs

Resumen: En el paper se menciona como la tokenización es un proceso de segmentación de una secuencia de bytes de entrada en tokens discretos. A su vez se menciona como este proceso se divide en dos fases: Entrenamiento: en esta se aprende un vocabulario de tokens y estadísticas a partir de un corpus de texto. Segmentación: una función usa ese vocabulario para mapear secuencias de bytes a tokens. Luego, este estudia cómo la elección del esquema de tokenización afecta el razonamiento numérico de los modelos de lenguaje de frontera, siendo cl100k el esquema usado por GPT-3.5 y GPT-4. Los autores observan que, a diferencia de otros modelos que optan por tokenización dígito a dígito, cl100k asigna tokens individuales a números de 1, 2 y 3 dígitos, lo que introduce patrones sistemáticos en cómo el modelo percibe y procesa los números. Para evaluar el efecto de estas diferencias, los autores diseñan tareas aritméticas controladas y comparan el desempeño de distintos modelos bajo diferentes esquemas de tokenización, encontrando que la tokenización de derecha a izquierda, forzada mediante separadores de comas, mejora el rendimiento aritmético de GPT-3.5 y GPT-4. Sus resultados muestran que la tokenización no es un paso neutral del pipeline, sino que puede ser fuente de sesgos útiles o perjudiciales dependiendo del dominio de aplicación, y que cl100k en particular produce representaciones numéricas con una estructura interna predecible y analizable.

Contraste: Mientras que Caputi (2019) estudia la Ley de Benford como herramienta para detectar patrones en distribuciones de dígitos de origen natural, Singh y Strouse muestran que cl100k introduce su propia estructura en la representación numérica del texto, lo que sugiere que los tokens resultantes de tokenizar contraseñas humanas podrían llevar una doble firma: la del comportamiento del usuario y la del esquema de codificación. **Conclusión propia:** Ambos enfoques son complementarios para este proyecto. Entender que cl100k no es neutral nos obliga a interpretar con cuidado los resultados de la prueba KS: si encontramos que los dígitos de los tokens se desvían de Benford, parte de esa desviación podría venir del propio tokenizador y no solo del comportamiento humano, lo cual es una limitación real del análisis que vale la pena reconocer.

A Study of Probabilistic Password Models

Resumen: El artículo realiza un estudio empírico amplio de modelos probabilísticos

para contraseñas utilizando seis bases de datos reales con cerca de 60 millones de contraseñas, y propone como alternativa metodológica a las curvas clásicas de número de intentos los *probability-threshold graphs*, que relacionan umbrales de probabilidad con el porcentaje de contraseñas cubiertas y permiten evaluar conjuntos completos con mucho menor costo computacional. Se inicia definiendo formalmente un modelo probabilístico de contraseñas como una función $p(s)$ sobre el conjunto de cadenas permitidas, y seguidamente se introducen tres métricas de evaluación principales: las *guess-number graphs*, las nuevas curvas de umbral de probabilidad y el *Average Negative Log-Likelihood* (ANLL), interpretado como el área a la izquierda de la curva de probabilidad y estrechamente relacionado con la perplejidad empírica. Luego se estudia un amplio espacio de diseño de modelos, distinguiendo entre modelos de Markov de cadena completa (*whole-string*) y modelos basados en plantillas (*template-based*), junto con decisiones de normalización, orden del modelo, suavizado, tratamiento de escasez de datos, agrupamiento de símbolos y esquemas de *backoff*, además de algoritmos de generación eficiente de conjeturas ordenadas por probabilidad. Finalmente, los resultados experimentales muestran que los modelos de Markov de cadena completa bien construidos, especialmente cuando combinan normalización con símbolo final y *backoff*, superan de forma consistente al modelo PCFGW, en particular más allá del primer millón de intentos, lo que lleva a concluir que estos enfoques ofrecen una representación más eficaz del comportamiento real de elección de contraseñas y una base más sólida para comparar fortaleza y capacidad de cracking.

Contraste: Este autor realizó su investigación de la fortaleza de las contraseñas mediante conceptos del área de probabilidad, mientras que el autor del artículo *A Machine Learning Approach to Predicting Passwords* utiliza un modelo con redes neuronales para estudiar la misma cualidad, sin hacer uso (aparentemente) de conceptos probabilísticos complejos.

Conclusión propia: Pese a que el presente proyecto se piensa realizar con un enfoque parecido al visto en la investigación *A Study of Probabilistic Password Models*, se reconoce que el artículo *A Machine Learning Approach to Predicting Passwords* presenta ideas que podrían complementar el desarrollo del trabajo, como el de desarrollar un modelo que permita generar contraseñas similares a las de un humano. Esto sería de gran utilidad una vez que se haya obtenido distribución que se desea encontrar, pues podría ponerse a prueba con varias bases de datos brindadas por el modelo.

User password repetitive patterns analysis and visualization

Resumen: El artículo estudia si los usuarios reutilizan sistemáticamente subcadenas al crear contraseñas largas y cómo estos patrones de repetición debilitan las políticas actuales de seguridad basadas en longitud y complejidad. Se formalizan varios tipos de patrones repetitivos dentro de una misma contraseña (caracteres individuales, pares y subcadenas de tres a diez caracteres, en orden unidireccional y bidireccional) y se diseñan algoritmos en tiempo polinómico para detectarlos eficientemente sobre grandes conjuntos de datos filtrados de fugas reales como RockYou. Además, se implementa una herramienta web ligera, basada en D3, con cuatro vistas de visualización: gráficos de frecuencia de caracteres (CFC), mapas de calor de repeticiones cortas (SRH), coordenadas paralelas para repeticiones largas (LRPC) y nubes de palabras de subcadenas repetidas (RWC), que permiten a administradores explorar interactivamente repeticiones y filtrar por longitud, tipo de carácter y dirección. Los estudios de caso muestran que las contraseñas de los usuarios exhiben fuertemente repeticiones de caracteres del mismo tipo (dígitos, minúsculas o mayúsculas), que muchas contraseñas largas

se construyen repitiendo subcadenas cortas significativas (p. ej. “love”, “haha”, “1212”) o patrones bidireccionales, y que estas estrategias de memorización hacen que exigir contraseñas más largas no garantice mayor seguridad, proporcionando solo una ilusión de robustez.

Contraste: La conclusión de que las personas tienden a repetir patrones en sus contraseñas (en especial con las contraseñas más largas) podría ser una posible explicación a una de las conclusiones obtenidas en *The Science of Guessing*, específicamente aquella que dictaba que aunque se le motive a una persona a usar contraseñas seguras (bajo los criterios usuales), la vulnerabilidad de dichas contraseñas no varía mucho de la de una persona que no se esfuerza activamente en crear contraseñas seguras.

Conclusión propia: Las conclusiones vistas en *User password repetitive patterns analysis and visualization* resulta de gran relevancia para el presente proyecto, pues muestra que es bastante probable que contraseñas recolectadas de una base de datos dada compartan ciertos patrones ayuden a deducir la probabilidad de que un cierto caracter esté en la i -ésima posición de una contraseña.

Towards a Rigorous Statistical Analysis of Empirical Password Datasets

Resumen: El texto desarrolla un marco estadístico riguroso para acotar, por arriba y por abajo, la curva de adivinación λ_G de un atacante ideal que conoce exactamente la distribución de contraseñas de los usuarios, sin asumir a priori ninguna forma específica para dicha distribución y trabajando solo con muestras i.i.d. de contraseñas filtradas de fugas o recolectadas de forma privada. En lugar de depender de un modelo concreto de cracking (redes neuronales, PCFG, Markov, reglas en JtR/Hashcat) o de la heurística del “mínimo número de intentos”, los autores proponen cotas de alta confianza basadas en: (i) la distribución empírica (que funciona bien mientras G no sea demasiado grande), (ii) técnicas de programación lineal inspiradas en Valiant & Valiant para el régimen G grande, y (iii) esquemas de muestreo y “muestreo híbrido” donde se combina una partición de la muestra con cualquier modelo de cracking existente. Con estos métodos muestran en ocho grandes datasets reales (Yahoo!, RockYou, 000webhost, Neopets, etc.) que la distribución empírica $\hat{\lambda}_G$ aproxima bien la curva real solo cuando $G \leq N$, y que para G grandes tanto $\hat{\lambda}_G$ como ajustes tipo Zipf tienden a sobreestimar de forma sustancial la tasa de éxito del atacante ideal. Sus resultados empíricos indican además que λ_G suele situarse muy por encima de las curvas de los mejores modelos actuales (Markov, PCFG, redes neuronales, JtR, Hashcat), lo que prueba que todavía hay un amplio margen para mejorar la eficiencia de adivinación y, en consecuencia, refuerza la conveniencia de basar las decisiones de política (coste del hash, límites de intentos, reglas de composición) en cotas sobre λ_G en lugar de en un modelo concreto. Finalmente, el trabajo ilustra cómo usar estas cotas para cuantificar beneficios de endurecer el bloqueo de cuentas, ajustar el factor de “key stretching” y evaluar políticas de composición de contraseñas (por ejemplo, mínimas de longitud o políticas basadas en frecuencia estimada mediante count-min sketch).

Contraste: Mientras que el autor de *User password repetitive patterns analysis and visualization* se enfoca en algoritmos de detección de subcadenas y patrones visuales, estos autores priorizan la inferencia de la probabilidad total de quiebre. Los primeros proporcionan la anatomía del dato, mientras que estos entregan el marco de probabilidad para asegurar que el análisis de RockYou sea estadísticamente significativo.

Conclusión propia: Los dos enfoques mencionados en el contraste pueden combinarse para dar lugar a una investigación más completa, pues de esa manera se puede sacar bastante

información de la muestra que a su vez será de gran utilidad para sostener el desarrollo del marco de probabilidad sobre el que se quiere trabajar.

APS 240: Data Analysis and Statistics with R: Chapter 33 Non-parametric tests

Resumen: El texto comienza explicando qué son las pruebas no paramétricas: métodos que hacen suposiciones mucho más débiles sobre la distribución de los datos en comparación con las pruebas paramétricas clásicas. Su principio fundamental consiste en reemplazar los valores originales por su orden o rango, lo que hace que los resultados sean insensibles a la distribución subyacente de los datos. El capítulo desarrolla cuatro pruebas principales. La prueba de rangos con signo de Wilcoxon es el equivalente no paramétrico de la prueba t para una muestra o muestras pareadas; se aplica cuando la distribución de las diferencias no es normal pero sí aproximadamente simétrica. La prueba U de Mann-Whitney equivale a la prueba t para dos muestras independientes y compara las medianas de dos grupos. La prueba de Kruskal-Wallis extiende ese principio a tres o más grupos, siendo el equivalente no paramétrico del ANOVA de una vía. Finalmente, la correlación de rangos de Spearman evalúa la asociación entre dos variables sin requerir normalidad ni una relación lineal estricta, sino solo una relación monótona. Cada prueba se ilustra con ejemplos biológicos concretos y código en R. El capítulo cierra con una reflexión sobre cuándo usar estas pruebas. Su ventaja principal es la flexibilidad ante datos que violan los supuestos paramétricos o que son de escala ordinal. Su desventaja es que son menos potentes que las pruebas paramétricas cuando los datos sí cumplen los supuestos, y menos informativas para análisis complejos. La recomendación final es usar ambos enfoques de manera informada según la naturaleza de los datos.

Contraste: En comparación con el trabajo de Yakir (2013) relacionado a la prueba de Kolmogorov-Smirnov, este documento explica las desventajas de usar las pruebas no paramétricas. Esto es de gran utilidad pues complementa lo investigado previamente acerca del test Kolmogorov-Smirnov.

Conclusión propia: El material expuesto por los autores en este capítulo será de gran utilidad para el desarrollo del presente proyecto, pues es un material muy completo que no solo explica el uso de varias pruebas, sino que expone las formas de utilizarlas en el lenguaje de programación *R* y compara las pruebas unas con otras. Además, menciona las ventajas y desventajas de las pruebas no paramétricas en general, lo que es sumamente enriquecedor para el enfoque de este proyecto en cuestión.

Zipf's Law in Passwords

Resumen: El artículo analiza empíricamente la distribución de contraseñas de usuarios a gran escala y muestra que se ajusta notablemente bien a modelos tipo ley de Zipf. A partir de 14 conjuntos de datos reales con 113,3 millones de contraseñas, los autores proponen dos modelos Zipf-like: PDF-Zipf, que describe la frecuencia de las contraseñas populares y alcanza coeficientes de determinación superiores a 0,97, y CDF-Zipf, que ajusta prácticamente todo el rango de la distribución con desviaciones máximas entre la CDF empírica y la teórica de 0,49 % a 4,59 % (media\$ \$1,85 %). Sobre esta base, introducen una nueva métrica de fuerza de conjuntos de contraseñas derivada de los parámetros Zipf, y muestran mediante experimentos que dicha métrica es estable y aplicable a distintos sitios y políticas, permitiendo comparar con rigor qué tan “seguro” es el universo de contraseñas de un servicio independientemente

del medidor ad hoc que se use en la interfaz. El trabajo discute además implicaciones para el diseño y evaluación de políticas de creación de contraseñas, subrayando que comprender la distribución subyacente (y su carácter Zipfiano) es clave para resolver las inconsistencias entre medidores de fuerza y para prever el impacto de reglas más estrictas sobre la seguridad y la usabilidad.

Contraste: El artículo anterior se dedicó mayormente a estudiar las contraseñas como objetos concretos, sin abundar con mayor detalle en los caracteres o las subcadenas de caracteres que pueden presentar. Esto ofrece un enfoque diferente al presentado en *User password repetitive patterns analysis and visualization*, el cual si estudia las contraseñas como objetos compuestos por subcadenas que tienden a repetirse.

Conclusión propia: Pese a que el artículo abarcó el estudio de las contraseñas de manera diferente a lo que se tiene planteado en la presente investigación (el cual es más parecido al enfoque usado en *User password repetitive patterns analysis and visualization*), se reconoce que introdujo herramientas que podrían ser de gran ayuda para la elaboración del proyecto, como lo son las distribuciones de Zipf. Esto último se justifica pues los resultados obtenidos en *Zipf's Law in Passwords* muestran que dichas distribuciones son capaces de llegar a resultados interesantes en el contexto del problema.

A Machine Learning Approach to Predicting Passwords

Resumen: La tesis explora el uso de modelos de aprendizaje automático para predecir secuencias de contraseñas humanas a partir de filtraciones públicas y compararlos con técnicas estándar de cracking basadas en hashcat. Tras repasar ataques de diccionario, diccionario+reglas, diccionarios masivos y fuerza bruta sobre contraseñas MD5 de XSplit, se muestra que los diccionarios ordenados por frecuencia (rockyou.txt) son muy eficientes en las primeras conjeturas, que combinar reglas casi duplica la tasa de éxito a costa de muchos más intentos, que listas enormes cubren casi todos los hashes y que la fuerza bruta es exhaustiva pero extremadamente ineficiente. El trabajo propone luego una red neuronal con capas convolucionales 1D y densas, entrenada en 150 000 contraseñas de OwnedCore, para estimar la probabilidad del siguiente carácter dada la secuencia previa, logrando una exactitud de validación de alrededor de 41 % en predicción de carácter y permitiendo asignar a cada contraseña una probabilidad interpretable como medida de fortaleza (contraseñas comunes como “oblivion” o “asdf1234” reciben alta probabilidad; cadenas aleatorias como “xy2zx9nm”, probabilidades ínfimas). Mediante muestreo sobre la distribución de salida, la red genera listas de contraseñas plausibles que, usadas como diccionario en hashcat, logran romper alrededor de 1 % de 100 000 hashes con menos de un millón de conjeturas, cifra razonable dado que el diccionario contiene menos de un millón de contraseñas únicas, aunque claramente por debajo del rendimiento de rockyou.txt; aplicar reglas sobre estas contraseñas generadas mejora los resultados pero sigue sin alcanzar a los diccionarios artesanales. El autor concluye que las redes neuronales son útiles para modelar el comportamiento de elección de contraseñas, generar diccionarios especializados y ordenar listas por probabilidad (especialmente relevante con hashes costosos como bcrypt), pero que, en su implementación actual, la generación es lenta, el modelo aún está por detrás de las listas tradicionales en cracking y sería necesario investigar arquitecturas avanzadas (GAN, LSTM) y mejores representaciones para hacerlo competitivo.

Contraste: Tanto el modelo desarrollado por Olsen como el modelo realizado por los autores del trabajo *Zipf's Law in Passwords* se vieron limitados por la capacidad computacional de

los instrumentos con los que estaban realizando sus experimentos. Además, ambos abarcan el problema de maneras muy diferentes, pues Olsen lo hace “a fuerza bruta” mientras que los otros autores utilizan conceptos más relacionados a la probabilidad, como la distribución de Zipf.

Conclusión propia: Pese a que por el momento no se ha planteado el uso de una red neuronal para el proyecto, esta investigación muestra que un modelo como el que realizó el autor combinado con el suficiente poder computacional podría ser de gran ayuda al momento de estar buscando cierta distribución asociada a una base de datos específica.

The science of guessing: analyzing an anonymized corpus of 70 million passwords

Resumen: El artículo presenta un análisis estadístico riguroso del mayor corpus anonimizado de contraseñas estudiado hasta ese momento, correspondiente a casi 70 millones de usuarios de Yahoo!, y lo utiliza para replantear la forma en que se mide la dificultad de adivinación de contraseñas elegidas por humanos. Se inicia criticando métricas tradicionales como la entropía de Shannon y la *guessing entropy*, por no ser apropiadas ni estimables con muestras realistas, y en su lugar introduce métricas de adivinación parcial como λ_β , μ_α y especialmente la nueva α -*guesswork*, pensadas para modelar ataques prácticos con distinta tasa deseada de éxito. Seguidamente, el trabajo propone un mecanismo de recolección que preserva la privacidad, basado en histogramas de contraseñas cifradas con un nonce secreto destruido antes del análisis, lo que permite estudiar subpoblaciones demográficas y de uso sin exponer contraseñas individuales ni facilitar ataques fuera de línea. Luego se aborda el problema del tamaño muestral, mostrando que incluso con decenas de millones de observaciones muchas métricas siguen subestimándose por la gran masa de contraseñas raras, y se adapta un modelo paramétrico de tipo Sichel (mezcla Poisson-generalized inverse Gaussian) para extrapolar la cola de la distribución y estimar con mayor estabilidad curvas de adivinación y factores de trabajo efectivos. Finalmente, al comparar numerosos subgrupos por edad, género, idioma, historial de cambios, uso de servicios y otros atributos, se concluye que la seguridad de las contraseñas varía sorprendentemente poco entre poblaciones: en general ofrecen menos de 10 bits de seguridad frente a ataques *online* y alrededor de 20 bits frente a ataques óptimos *offline*, lo que sugiere que incluso usuarios aparentemente más motivados siguen eligiendo contraseñas débilmente distribuidas y que los diccionarios globales funcionan casi tan bien como los específicos para cada grupo.

Contraste: Tanto este trabajo como el de los autores de *Zipf's Law in Passwords* se enfrentaron al problema de que las contraseñas poco comunes eran capaces de desestabilizar gran parte de los cálculos que se realizaban. Sin embargo, mientras que los autores del otro artículo solo se limitaron a trabajar con contraseñas comunes, los autores de este texto usaron técnicas de lingüística computacional con el fin de solventar, en mayor o menor medida, este problema.

Conclusión propia: Gracias a lo desarrollado en *The science of guessing: analyzing an anonymized corpus of 70 million passwords*, se pudo comprobar que existen maneras de manejar las contraseñas atípicas para que no interrumpan de manera crítica la investigación.

LEY DE BENFORD

Resumen: El artículo presenta de forma sintética la Ley de Benford, que describe cómo, en muchos conjuntos de datos numéricos reales, el primer dígito significativo no se distribuye de manera uniforme, sino según la fórmula $P(D_1 = d) = \log_{10}(1 + \frac{1}{d})$, lo que implica que el

1 aparece alrededor del 30 % de las veces y el 9 menos del 5 %. Se repasan los antecedentes históricos desde las observaciones de Newcomb (1881) y Benford (1938), hasta la popularización de la ley por Nigrini en los años noventa en el contexto de la detección de fraude fiscal. Luego se expone la ley general de Hill para los primeros k dígitos significativos en base 10, se muestra que los dígitos sucesivos son dependientes pero que esa dependencia se atenúa con la posición, y se demuestra que la distribución del n -ésimo dígito tiende a la uniforme cuando $n \rightarrow \infty$ (en particular $P(D_n = 0) \rightarrow 1/10$). En cuanto a aplicaciones, se describen los principales tests estadísticos para verificar si un conjunto de datos sigue la Ley de Benford: el test de bondad de ajuste Chi-cuadrado (potente pero problemático con muestras muy grandes), el *Mean Absolute Deviation* (MAD), diseñado por Nigrini para ser independiente del tamaño muestral y con tablas críticas empíricas, y el “test de los dos últimos dígitos”, basado en la aproximación a la uniformidad de los dígitos finales. Finalmente, se ilustra el uso de estos métodos analizando los resultados del censo uruguayo de 2011 para las 176 localidades con más de 1000 habitantes: el primer dígito pasa el test χ^2 pero no el MAD, mientras que la distribución de los dos últimos dígitos no se aparta de la uniformidad, lo que sugiere que, aunque el ajuste a Benford no es perfecto, no hay evidencia clara de invención sistemática de datos.

Contraste: Por un lado, Olsen en su investigación *A Machine Learning Approach to Predicting Passwords* aplicó la ley de Benford únicamente para el primer dígito, por otro lado Caputi menciona brevemente la existencia de la ley de Benford para los últimos dos dígitos.

Conclusión propia: Si la ley de Benford para el primer dígito resultó útil para la investigación vista en *A Machine Learning Approach to Predicting Passwords*, es posible conjeturar que exista alguna variación de dicha ley (como la ley de Benford los últimos dos dígitos) que, al combinarla con la metodología usada por el autor de la investigación mencionada anteriormente, sea de mayor utilidad para el presente proyecto.

Benford’s Law: Theory and Applications

Resumen: El texto ofrece una visión panorámica y multidisciplinaria de la Ley de Benford, entendida como el fenómeno según el cual en muchos conjuntos de datos reales el primer dígito significativo d aparece con probabilidad $\log_{10}(\frac{d+1}{d})$, por lo que los unos son mucho más frecuentes que los nueves. Se inicia recordando el origen histórico de la ley en las observaciones de Newcomb y Benford sobre el desgaste de las tablas logarítmicas, y seguidamente se explica su formulación en términos del significando, su versión fuerte y su generalización a otras bases numéricas, junto con ideas centrales como la invariancia de escala y la caracterización mediante la distribución uniforme de $\log_B(x)$ mód 1. Luego se presentan los fundamentos matemáticos que sostienen el fenómeno, destacando enfoques basados en teoría de la medida, análisis de Fourier, geometría de distribuciones, cotas explícitas por variación total y procesos de Lévy, con el fin de estudiar tanto cuándo una sucesión o distribución es exactamente Benford como la rapidez con que otras se aproximan a ese comportamiento. Finalmente, la obra reúne una amplia colección de aplicaciones en contabilidad, detección de fraude, elecciones, economía, psicología, ciencias naturales e imágenes médicas y digitales, mostrando que la ley no solo tiene interés teórico, sino que también constituye una herramienta práctica para evaluar calidad de datos, identificar manipulaciones y entender regularidades numéricas en contextos muy diversos.

Contraste: En comparación a lo visto en *A Machine Learning Approach to Predicting Passwords*, donde se buscaba una forma de predecir contraseñas, aquí el interés está en una ley

estadística general que puede aplicarse a diversos tipos de datos, no a un problema de ciberseguridad en particular.

Conclusión propia: La teoría contenida en *Benford's Law: Theory and Applications* permite el entendimiento de una ley estadística general de la estadística, la cual puede ser aplicada a la presente investigación con el fin de obtener una herramienta que permita entender de mejor manera el problema central, y buscar una solución basándose en las metodologías vistas en los otros trabajos analizados en esta sección de Enlaces de Literatura.

Extremes in Random Fields A Theory and its Applications

Resumen: El capítulo presenta un tratamiento no paramétrico de los tests de Kolmogorov–Smirnov y de Peacock, vistos como problemas de extremos en campos aleatorios. Se parte del caso clásico univariado de Kolmogorov–Smirnov, donde el estadístico es la máxima discrepancia entre la función de distribución empírica y la teórica, y se recuerda que, tras transformar los datos vía la cdf, su distribución límite coincide con el máximo del puente browniano y admite una cola explícita, $\Pr(D \geq y) \approx 2e^{-2y^2}$. A continuación se reanaliza este test usando el enfoque del *likelihood ratio identity* y teoremas de localización: se construye un campo aleatorio a partir de las discrepancias, se restringe la maximización a una vecindad de la mediana (donde el gran-desvío es más probable), se aproxima el máximo mediante una malla discreta y se modela localmente el comportamiento como un paseo gaussiano bidireccional con deriva negativa, lo que permite recuperar asintóticamente la misma cola que en el análisis clásico. Posteriormente se extiende el marco al test de Peacock en varias dimensiones, donde la discrepancia se evalúa simultáneamente en los cuatro cuadrantes definidos por cada punto del plano y se toma como estadístico la mayor de esas discrepancias: ya no existe una transformación que reduzca al caso uniforme, pero mediante el mismo aparato de campos aleatorios, tasas de gran-desvío y localización se obtiene una aproximación para el nivel de significancia basada en curvas de probabilidad $F(t) = 1/2$ y en la suma de contribuciones de paseos gaussianos independientes asociados a cada dimensión. Finalmente, se conecta esta teoría con las *scanning statistics* multivariadas, mostrando que el test de Peacock es un caso particular de escaneo de regiones (cuadrantes o rectángulos) en un campo aleatorio, y se discuten extensiones a ventanas rectangulares generales y a núcleos suaves, donde la estructura local se codifica en determinantes de Hessianos o productos de términos unidimensionales, planteando como retos abiertos el tratamiento de formas más irregulares y campos no suaves.

Contraste: Este trabajo contrasta con la mayoría de los vistos en esta sección de análisis de literatura, pues su autor es de la minoría que menciona y explica la utilidad de las pruebas no paramétricas en el contexto de modelación de distribuciones de probabilidad.

Conclusión propia: Usar la teoría vista en *Extremes in Random Fields A Theory and its Applications* para el proyecto podría ser innovador en el estudio de la aleatoriedad de las contraseñas.

About passwords

Resumen: El artículo analiza críticamente varias creencias comunes sobre la seguridad de las contraseñas y sostiene, con argumentos combinatorios y evidencia empírica, que la longitud es un factor mucho más importante que la mera mezcla de mayúsculas, minúsculas, dígitos y símbolos. A partir de filtraciones reales como Hotmail, RockYou, Yahoo! y otros casos masivos, el autor muestra que muchos usuarios siguen eligiendo contraseñas triviales, reutilizadas o basadas en palabras comunes, información personal y patrones previsibles, lo

que vuelve muy eficaces los ataques por diccionario, las variantes avanzadas con sustituciones tipo *leet* y los ataques de fuerza bruta fuera de línea. Seguidamente, se discuten distintos métodos populares de generación de contraseñas, como combinaciones aparentemente aleatorias de caracteres, iniciales de frases, generadores deterministas por sitio y concatenaciones mnemotécnicas de palabras, subrayando que cualquier método conocido o estructuralmente típico puede facilitar el trabajo del atacante si este dispone de información previa o de listas de patrones frecuentes. Luego se presenta un análisis estructural de más de 14 millones de contraseñas únicas de RockYou, donde se observa que predominan las minúsculas, los dígitos y las formas “palabra + números”, mientras que el uso de mayúsculas y caracteres especiales es relativamente escaso; además, se estima que una estrategia de cracking bien diseñada podría romper una fracción considerable de esas contraseñas en muy poco tiempo. Finalmente, el texto propone recomendaciones prácticas para construir contraseñas robustas y memorables, por ejemplo mediante frases largas, combinaciones personales no previsibles o palabras inventadas, y concluye que la seguridad real depende tanto de buenos hábitos del usuario como de funciones hash fuertes, políticas organizacionales adecuadas y educación temprana sobre autenticación y riesgos informáticos.

Contraste: Este texto sugiere fuertemente que el largo de una contraseña influye de manera directamente proporcional en su seguridad, y uno de sus argumentos es que entre más caracteres tiene una contraseña entonces habrían más combinaciones que deberían ser probadas al momento de querer vulnerarla (lo que haría poco probable que un intruso obtenga la respuesta en poco tiempo). Sin embargo, esta posición es contraria a la que ofrecen los autores de *User password repetitive patterns analysis and visualization*, pues estos últimos dejaron claro que aumentar la longitud de una contraseña no necesariamente implica un aumento en la seguridad, pues los humanos tienden a repetir patrones al momento de hacer una secuencia extensa de caracteres.

Conclusión propia: El autor de este texto no consideró patrones de caracteres más allá de los básicos, como “aaaa”. Lo que hizo que sus conclusiones finales fueran medianamente diferentes al de los autores de *User password repetitive patterns analysis and visualization*, pues estos últimos si consideraron patrones en las contraseñas en forma de un conjunto de caracteres complejos, como “love”. Esto último permite deducir que el autor de *About passwords* no aprovechó al máximo la premisa de que los humanos tienden a seguir patrones. Sin embargo, esto último no quita el hecho de que la investigación de Keszthelyi ofrece contenido teórico que podrá ser de ayuda en el desarrollo de la presente investigación, aunque en la parte de metodología si se usará un enfoque más parecido al mostrado en *User password repetitive patterns analysis and visualization*.

Resumen de la Ficha 1 – KS y Ley de Benford en Posición 1 (Tokenización cl100k): Aplicando tokenización con base cl100k y el test de Kolmogórov-Smirnov (KS), se evaluó si la distribución empírica de los dígitos en la primera posición de las contraseñas tokenizadas se ajusta a la Ley de Benford. Los resultados indican que, aunque visualmente la distribución guarda similitud con la teórica de Benford —con mayor frecuencia del dígito 1—, el test KS rechaza H_0 ($D = 0.0985$), lo que significa que la diferencia es estadísticamente significativa y no puede descartarse como aleatoria. Esto implica que las contraseñas no son completamente aleatorias en su primera posición: siguen un patrón parcialmente compatible con Benford, pero no con la rigurosidad formal requerida por el test. Este resultado se apoya en la literatura

de Caputi (2019) sobre la Ley de Benford y en Chandy et al. (2025) sobre el test KS, y motiva la exploración de las posiciones subsiguientes para determinar si el ajuste mejora a medida que avanza la posición.

Resumen de la Ficha 2 – KS y Ley de Benford en Posición 2 (Tokenización cl100k): Con la misma metodología de tokenización cl100k y el test KS, se analizó la segunda posición de las contraseñas tokenizadas. Al igual que en la posición 1, la distribución empírica muestra una forma visualmente similar a la Ley de Benford, pero el test KS rechaza H_0 ($D = 0.0108$), indicando que el ajuste no es suficiente para confirmar estadísticamente el seguimiento de dicha ley. La diferencia con la posición 1 es que el estadístico D es mucho menor, lo que sugiere un mejor ajuste relativo, aunque aún insuficiente. Este resultado consolida la hipótesis de que las primeras posiciones de las contraseñas son las que más se desvían del comportamiento esperado bajo Benford, lo que refuerza que las claves no son completamente aleatorias. Constituye un eslabón clave en la cadena de análisis posicional, orientando la investigación hacia la posición 3 y siguientes para buscar un ajuste formal.

Resumen de la Ficha 3 – KS y Ley de Benford en Posición 3 (Tokenización cl100k): Al aplicar el test KS sobre la tercera posición de las contraseñas tokenizadas con cl100k, se obtuvo un resultado distinto a los anteriores: el test no rechaza H_0 ($D = 0.0003$), lo que indica que la distribución empírica de los dígitos en esta posición sigue la Ley de Benford de manera estadísticamente aceptable. Este es el primer punto de la cadena posicional en el que se confirma formalmente el ajuste a Benford, marcando una ruptura con el comportamiento de las posiciones 1 y 2. El hallazgo es significativo porque demuestra que no basta con la similitud visual para afirmar que una distribución sigue Benford; es imprescindible validarlo con pruebas formales como el test KS. En consonancia con Caputi (2019) y Chandy et al. (2025), este resultado sienta la base para verificar si las posiciones 4 en adelante mantienen el mismo patrón, avanzando hacia una caracterización más completa de la aleatoriedad de las contraseñas.

Resumen de la Ficha 4 – KS y Ley de Benford en Posición 4 (Tokenización cl100k): El análisis de la cuarta posición de las contraseñas tokenizadas con cl100k confirma, nuevamente, que el test KS no rechaza H_0 ($D = 0.0003$), validando que la distribución de dígitos en esta posición se ajusta formalmente a la Ley de Benford. Este resultado es consistente con el hallazgo de la posición 3 y forma parte de un patrón más amplio: se determinó que a partir de la posición 3 en adelante, todas las posiciones siguen Benford de forma confirmada por KS, lo cual resulta inesperado dado que las posiciones 1 y 2 no lograron pasar el test. Esto revela que la naturaleza de los dígitos en posiciones iniciales es cualitativamente diferente a la de las posiciones intermedias y finales, y que no basta con la similitud visual para afirmar el seguimiento de una distribución: la validación formal es imprescindible. La discrepancia plantea la necesidad de explorar nuevas estrategias de tokenización que permitan extender el cumplimiento de Benford a todas las posiciones, en línea con Caputi (2019) y Chandy et al. (2025).

Resumen de la Ficha 5 – Entropía por Tipo de Máscara (Kruskal-Wallis): Se empleó la prueba de Kruskal-Wallis para comparar las distribuciones de entropía de contraseñas clasificadas según el tipo de máscara: mixta, solo dígitos, solo letras, solo caracteres especiales y solo mayúsculas. El test rechazó H_0 con alta significancia ($H = 4,366,419.48, p \approx 0$), evidenciando que los cinco tipos de máscara producen distribuciones de entropía completamente distintas. Las contraseñas mixtas presentan la entropía más alta, mientras que las compues-

tas exclusivamente por caracteres especiales muestran los valores más bajos, contrariamente a lo que podría esperarse intuitivamente. Este agrupamiento es descriptivo y no inferencial, pues la variable de agrupación coincide con la variable de respuesta. El hallazgo enriquece la comprensión del desorden interno en las contraseñas y abre la puerta para determinar si estas diferencias en entropía pueden usarse para cuantificar aleatoriedad real en los pasos siguientes del análisis.

Resumen de la Ficha 6 – Entropía por Longitud de Máscara (Kruskal-Wallis): Se aplicó la prueba de Kruskal-Wallis para comparar las distribuciones de entropía de contraseñas agrupadas según la longitud de su máscara (de 1 a 16 caracteres). El test rechazó la hipótesis nula\$ ($H = 14,084,456.87$, $p = 0$)\$, confirmando que existen diferencias estadísticamente significativas entre grupos. Visualmente, se aprecia una tendencia creciente y clara: a mayor longitud de la contraseña, mayor es la entropía media esperada, resultado intuitivo pero que era necesario comprobar formalmente. Esto refuerza la relación entre longitud y complejidad planteada por Reaz (2024), quien asocia la entropía a la dificultad de predicción de una contraseña. No obstante, este resultado no determina qué tan aleatorias son las contraseñas ni cuáles son seguras en términos absolutos; únicamente establece que la longitud es un predictor significativo de la entropía, lo que orienta los análisis inferenciales siguientes sobre aleatoriedad real.

Resumen de la Ficha 7 – Distribución Empírica de Dígitos por Posición: Se realizó un análisis descriptivo de la distribución empírica de los dígitos (0–9) en las primeras seis posiciones de las contraseñas del dataset RockYou. Se observó que la posición 1 presenta una distribución notablemente sesgada, donde los dígitos más bajos aparecen con mayor frecuencia, lo cual es compatible con la Ley de Benford; la posición 2 también muestra variación, aunque menor. A partir de la posición 3, la distribución se vuelve prácticamente uniforme: todos los dígitos tienen probabilidades de aparición muy similares, independientemente de cuál se elija. Esto sugiere que la primera posición es la más informativa para inferir patrones de creación de contraseñas, mientras que las posiciones posteriores son más predecibles en términos de uniformidad. El resultado no mide aleatoriedad directamente ni indica qué dígitos se usan en mayor volumen, pero construye una base empírica para contrastar con la Ley de Benford (Caputi, 2019) en análisis futuros.

Resumen de la Ficha 8 – Bigramas de Transición entre Tipos de Caracteres: Se construyó una matriz de bigramas para analizar las probabilidades de transición entre tipos de caracteres (letras, dígitos, mayúsculas y caracteres especiales) en las contraseñas del dataset RockYou. Los resultados muestran que la transición de letra a letra es, con diferencia, la más frecuente (66.26 %), seguida de dígito a dígito (23.28 %), lo que evidencia un comportamiento ordenado en la construcción de contraseñas. Transiciones entre tipos distintos, como de carácter especial a otro carácter especial, son prácticamente inexistentes. Este patrón de orden se asocia al concepto de entropía planteado por Reaz (2024), donde la tendencia a permanecer dentro del mismo tipo de carácter refleja baja aleatoriedad entre tipos. Sin embargo, este resultado no describe la distribución general de contraseñas ni sus longitudes, sino únicamente el orden secuencial de sus caracteres, lo cual sienta una base para modelar mejor la entropía en pasos analíticos posteriores.

Ambas historias unificadas

Seguimos la instrucción Lo que van a tener es un bloque de texto con dos historias diferentes: La historia de otros autores vs la historia de ustedes. Expandan, modifiquen, cambien de orden del texto con el fin de que las dos historias se conviertan en una sola. Sigán el orden que establecieron en el paso anterior.

El presente proyecto fue desarrollado con el fin de analizar si las contraseñas de la base de datos *rockyou.txt* seguía la ley de Benford para los primeros 16 dígitos mediante alguna transformación de los datos. Sin embargo, para continuar con el proyecto, fue necesario abarcar varias definiciones, que serán presentadas a continuación.

1. **Ley de Benford:** Según Sarkar (2025), la Ley de Benford establece que los primeros números que se encuentran en una base de datos dada varían su cantidad de apariciones según los dígitos que los conforman. En síntesis, el número uno suele aparecer más frecuentemente, seguido por el dos, luego por el tres y así sucesivamente. Sin embargo, Marrero (2019) expone la limitación de que esta ley solo es válida cuando la muestra de números es variada, abarca diversos órdenes de magnitud, se encuentra libre de condicionamientos y sesgos, y tiene la característica de no ser totalmente aleatoria. Es por esto último que el primer autor mencionó el hecho de que dicha ley permite identificar patrones y anomalías en bases de datos “naturales”, lo que se puede aplicar al momento de detectar algunos tipos de fraude.
2. **Entropía:** Dada una variable aleatoria continua X con una función de densidad p , se define la Entropía de X como:

$$h(X) = \int_{-\infty}^{\infty} p(x) \log(p(x)) dx$$

Análogamente, para una variable aleatoria discreta X con función de masa p , su entropía corresponde a:

$$H(X) = \sum_{i=1}^n p(x_i) \log(p(x_i))$$

Conceptualmente, la entropía mide el nivel de aleatoriedad, desorden o variabilidad en un sistema cerrado. Así, cuanto más grande sea la magnitud asociada a la entropía de una variable aleatoria, habrá más incertidumbre al momento de hacer una predicción con respecto al comportamiento de dicha variable.(Reaz y Wunder, 2024). Los autores Lehoucq, Mayer y Tucker hacen la distinción de que la entropía se utiliza de manera diferente en el contexto de teoría de la información (donde se utilizan variables aleatorias) que en el contexto de la estadística (donde se trabaja con muestras). Así, para este proyecto se hará uso de la entropía en los dos contextos mencionados anteriormente.

Posteriormente, para el aspecto metodológico del proyecto, se hizo uso de varias herramientas (las cuales serán explicadas con detalle en los siguientes párrafos), como lo fueron:

- Tokenización

- Test de Kolmogorov-Smirnov
- Prueba de Kruskal-Wallis

Al principio de la elaboración del proyecto, se quiso investigar acerca de los patrones que siguen las contraseñas a nivel general. Uno de los primeros trabajos que llamaron la atención del grupo fue el trabajo *User password repetitive patterns analysis and visualization*, el cual estudiaba acerca de si los usuarios reutilizan sistemáticamente subcadenas al crear contraseñas largas y cómo estos patrones de repetición debilitan las políticas actuales de seguridad basadas en longitud y complejidad. Se formalizaron varios tipos de patrones repetitivos dentro de una misma contraseña (caracteres individuales, pares y subcadenas de tres a diez caracteres, en orden unidireccional y bidireccional) y se diseñaron algoritmos en tiempo polinómico para detectarlos eficientemente sobre grandes conjuntos de datos filtrados de fugas reales como RockYou. Además, se implementó una herramienta web ligera, basada en D3, con cuatro vistas de visualización: gráficos de frecuencia de caracteres (CFC), mapas de calor de repeticiones cortas (SRH), coordenadas paralelas para repeticiones largas (LRPC) y nubes de palabras de subcadenas repetidas (RWC), que permiten a administradores explorar interactivamente repeticiones y filtrar por longitud, tipo de carácter y dirección. Los estudios de caso muestran que las contraseñas de los usuarios exhiben fuertemente repeticiones de caracteres del mismo tipo (dígitos, minúsculas o mayúsculas), que muchas contraseñas largas se construyen repitiendo subcadenas cortas significativas (p. ej. “love”, “haha”, “1212”) o patrones bidireccionales, y que estas estrategias de memorización hacen que exigir contraseñas más largas no garantice mayor seguridad, proporcionando solo una ilusión de robustez.

Luego, se analizó el trabajo *About Passwords*, que complementaba en gran medida lo visto en el párrafo anterior, pues analizaba críticamente varias creencias comunes sobre la seguridad de las contraseñas y sostiene, con argumentos combinatorios y evidencia empírica, que la longitud es un factor mucho más importante que la mera mezcla de mayúsculas, minúsculas, dígitos y símbolos. A partir de filtraciones reales como Hotmail, RockYou, Yahoo! y otros casos masivos, el autor mostró que muchos usuarios siguen eligiendo contraseñas triviales, reutilizadas o basadas en palabras comunes, información personal y patrones previsibles, lo que vuelve muy eficaces los ataques por diccionario, las variantes avanzadas con sustituciones tipo *leet* y los ataques de fuerza bruta fuera de línea. Seguidamente, se discutieron distintos métodos populares de generación de contraseñas, como combinaciones aparentemente aleatorias de caracteres, iniciales de frases, generadores deterministas por sitio y concatenaciones mnemotécnicas de palabras, subrayando que cualquier método conocido o estructuralmente típico puede facilitar el trabajo del atacante si este dispone de información previa o de listas de patrones frecuentes. Luego se presentó un análisis estructural de más de 14 millones de contraseñas únicas de RockYou, donde se observa que predominan las minúsculas, los dígitos y las formas “palabra + números”, mientras que el uso de mayúsculas y caracteres especiales es relativamente escaso; además, se estima que una estrategia de cracking bien diseñada podría romper una fracción considerable de esas contraseñas en muy poco tiempo. Finalmente, el texto propuso recomendaciones prácticas para construir contraseñas robustas y memorables, por ejemplo mediante frases largas, combinaciones personales no previsibles o palabras inventadas, y concluye que la seguridad real depende tanto de buenos hábitos del usuario como de funciones hash fuertes, políticas organizacionales adecuadas y educación temprana sobre autenticación y riesgos informáticos.

Este texto sugiere fuertemente que el largo de una contraseña influye de manera directamente proporcional en su seguridad, y uno de sus argumentos es que entre más caracteres tiene una contraseña entonces habrían más combinaciones que deberían ser probadas al momento de querer vulnerarla (lo que haría poco probable que un intruso obtenga la respuesta en poco tiempo). Sin embargo, esta posición es contraria a la que ofrecen los autores de *User password repetitive patterns analysis and visualization*, pues estos últimos dejaron claro que aumentar la longitud de una contraseña no necesariamente implica un aumento en la seguridad, pues los humanos tienden a repetir patrones al momento de hacer una secuencia extensa de caracteres.

Para complementar el análisis que el texto anterior hizo del cambio que experimenta la seguridad de una contraseña al cambiar su longitud, se analizó el texto *The science of guessing: analyzing an anonymized corpus of 70 million passwords*, donde el autor presenta un análisis estadístico riguroso del mayor corpus anonimizado de contraseñas estudiado hasta ese momento, correspondiente a casi 70 millones de usuarios de Yahoo!, y lo utiliza para replantear la forma en que se mide la dificultad de adivinación de contraseñas elegidas por humanos. Se inicia criticando métricas tradicionales como la entropía de Shannon y la *guessing entropy*, por no ser apropiadas ni estimables con muestras realistas, y en su lugar introduce métricas de adivinación parcial como λ_β , μ_α y especialmente la nueva α -*guesswork*, pensadas para modelar ataques prácticos con distinta tasa deseada de éxito. Seguidamente, el trabajo propone un mecanismo de recolección que preserva la privacidad, basado en histogramas de contraseñas cifradas con un nonce secreto destruido antes del análisis, lo que permite estudiar subpoblaciones demográficas y de uso sin exponer contraseñas individuales ni facilitar ataques fuera de línea. Luego se aborda el problema del tamaño muestral, mostrando que incluso con decenas de millones de observaciones muchas métricas siguen subestimándose por la gran masa de contraseñas raras, y se adapta un modelo paramétrico de tipo Sichel (mezcla Poisson-generalized inverse Gaussian) para extrapolar la cola de la distribución y estimar con mayor estabilidad curvas de adivinación y factores de trabajo efectivos. Finalmente, al comparar numerosos subgrupos por edad, género, idioma, historial de cambios, uso de servicios y otros atributos, se concluye que la seguridad de las contraseñas varía sorprendentemente poco entre poblaciones: en general ofrecen menos de 10 bits de seguridad frente a ataques *online* y alrededor de 20 bits frente a ataques óptimos *offline*, lo que sugiere que incluso usuarios aparentemente más motivados siguen eligiendo contraseñas débilmente distribuidas y que los diccionarios globales funcionan casi tan bien como los específicos para cada grupo.

Una vez que se estudió la psicología que suelen aplicar las personas al momento de formar una contraseña, era momento de estudiar si realmente existe alguna manera de predecir las contraseñas. Esto debido a que, de ser posible, significaría que las contraseñas realmente contienen patrones que se podría aprovechar para estudiar si, en el fondo, las contraseñas cumplen con la Ley de Benford. Uno de los primeros textos que se analizaron para estudiar esto fue *A study of Probabilistic Password Models* el cual realiza un estudio empírico amplio de modelos probabilísticos para contraseñas utilizando seis bases de datos reales con cerca de 60 millones de contraseñas, y propuso como alternativa metodológica a las curvas clásicas de número de intentos los *probability-threshold graphs*, que relacionan umbrales de probabilidad con el porcentaje de contraseñas cubiertas y permiten evaluar conjuntos completos con mucho menor costo computacional. Inició definiendo formalmente un modelo probabilístico de contraseñas como una función $p(s)$ sobre el conjunto de cadenas permitidas, y seguidamente

se introdujeron tres métricas de evaluación principales: las *guess-number graphs*, las nuevas curvas de umbral de probabilidad y el *Average Negative Log-Likelihood* (ANLL), interpretado como el área a la izquierda de la curva de probabilidad y estrechamente relacionado con la perplejidad empírica. Luego se estudió un amplio espacio de diseño de modelos, distinguiendo entre modelos de Markov de cadena completa (*whole-string*) y modelos basados en plantillas (*template-based*), junto con decisiones de normalización, orden del modelo, suavizado, tratamiento de escasez de datos, agrupamiento de símbolos y esquemas de *backoff*, además de algoritmos de generación eficiente de conjeturas ordenadas por probabilidad. Finalmente, los resultados experimentales mostraron que los modelos de Markov de cadena completa bien contruidos, especialmente cuando combinan normalización con símbolo final y *backoff*, superan de forma consistente al modelo PCFGW, en particular más allá del primer millón de intentos, lo que lleva a concluir que estos enfoques ofrecen una representación más eficaz del comportamiento real de elección de contraseñas y una base más sólida para comparar fortaleza y capacidad de cracking.

El texto anterior se relacionaba en gran medida con el texto *A Machine Learning Approach to Predicting Passwords*, el cual exploraba el uso de modelos de aprendizaje automático para predecir secuencias de contraseñas humanas a partir de filtraciones públicas y compararlos con técnicas estándar de cracking basadas en hashcat. Tras repasar ataques de diccionario, diccionario+reglas, diccionarios masivos y fuerza bruta sobre contraseñas MD5 de XSplit, se mostró que los diccionarios ordenados por frecuencia (rockyou.txt) son muy eficientes en las primeras conjeturas, que combinar reglas casi duplica la tasa de éxito a costa de muchos más intentos, que listas enormes cubren casi todos los hashes y que la fuerza bruta es exhaustiva pero extremadamente ineficiente. El trabajo propuso luego una red neuronal con capas convolucionales 1D y densas, entrenada en 150 000 contraseñas de OwnedCore, para estimar la probabilidad del siguiente carácter dada la secuencia previa, logrando una exactitud de validación de alrededor de 41 % en predicción de carácter y permitiendo asignar a cada contraseña una probabilidad interpretable como medida de fortaleza (contraseñas comunes como “oblivion” o “asdf1234” reciben alta probabilidad; cadenas aleatorias como “xy2zx9nm”, probabilidades ínfimas). Mediante muestreo sobre la distribución de salida, la red genera listas de contraseñas plausibles que, usadas como diccionario en hashcat, logran romper alrededor de 1 % de 100 000 hashes con menos de un millón de conjeturas, cifra razonable dado que el diccionario contiene menos de un millón de contraseñas únicas, aunque claramente por debajo del rendimiento de rockyou.txt; aplicar reglas sobre estas contraseñas generadas mejora los resultados pero sigue sin alcanzar a los diccionarios artesanales. El autor concluyó que las redes neuronales son útiles para modelar el comportamiento de elección de contraseñas, generar diccionarios especializados y ordenar listas por probabilidad (especialmente relevante con hashes costosos como bcrypt), pero que, en su implementación actual, la generación es lenta, el modelo aún está por detrás de las listas tradicionales en cracking y sería necesario investigar arquitecturas avanzadas (GAN, LSTM) y mejores representaciones para hacerlo competitivo.

Por un lado, el autor de *A study of Probabilistic Password Models* realizó su investigación de la fortaleza de las contraseñas mediante conceptos del área de probabilidad. Por el otro lado, el autor del artículo *A Machine Learning Approach to Predicting Passwords* utiliza un modelo con redes neuronales para estudiar la misma cualidad, sin hacer uso (aparentemente) de conceptos probabilísticos complejos.

Siguiendo en esta línea de modelos relacionados al estudio de la predictibilidad de las contraseñas, se estudió el trabajo *Zipf's Law in Passwords*, donde el autor analiza empíricamente la distribución de contraseñas de usuarios a gran escala y muestra que se ajusta notablemente bien a modelos tipo ley de Zipf. A partir de 14 conjuntos de datos reales con 113,3 millones de contraseñas, los autores proponen dos modelos Zipf-like: PDF-Zipf, que describe la frecuencia de las contraseñas populares y alcanza coeficientes de determinación superiores a 0,97, y CDF-Zipf, que ajusta prácticamente todo el rango de la distribución con desviaciones máximas entre la CDF empírica y la teórica de 0,49 % a 4,59 % (media\$ \$1,85 %). Sobre esta base, introducen una nueva métrica de fuerza de conjuntos de contraseñas derivada de los parámetros Zipf, y muestran mediante experimentos que dicha métrica es estable y aplicable a distintos sitios y políticas, permitiendo comparar con rigor qué tan “seguro” es el universo de contraseñas de un servicio independientemente del medidor ad hoc que se use en la interfaz. El trabajo discute además implicaciones para el diseño y evaluación de políticas de creación de contraseñas, subrayando que comprender la distribución subyacente (y su carácter Zipfiano) es clave para resolver las inconsistencias entre medidores de fuerza y para prever el impacto de reglas más estrictas sobre la seguridad y la usabilidad.

Lo anterior fueron las investigaciones que propiamente estudiaban las contraseñas como objetos centrales. Dichos trabajos mostraron que es posible notar patrones en las contraseñas, por lo que era plausible pensar que la ley de Benford se cumpliría de alguna manera en las contraseñas.

Después de un proceso largo de descarte de ideas, el profesor Maikol Solís Chacón sugirió la idea de tokenizar las contraseñas, para construir números asociados a cada contraseña (usando los pesos de los tokens). Esto llevó al presente grupo a investigar acerca del proceso de tokenización y algunas propiedades relacionadas. Así, se analizó el paper *Tokenization counts: the impact of tokenization on arithmetic in frontier LLMs*, en el cual se menciona como la tokenización es un proceso de segmentación de una secuencia de bytes de entrada en tokens discretos. Los autores explicaron que este proceso se divide en dos fases; una fase de entrenamiento donde se aprende un vocabulario de tokens y estadísticas a partir de un corpus de texto, y una fase de segmentación, en la cual una función usa ese vocabulario para mapear secuencias de bytes a tokens. Luego, el paper abarca el cómo la elección del esquema de tokenización afecta el razonamiento numérico de los modelos de lenguaje de frontera, siendo cl100k el esquema usado por GPT-3.5 y GPT-4. Los autores observaron que, a diferencia de otros modelos que optan por tokenización dígito a dígito, cl100k asigna tokens individuales a números de 1, 2 y 3 dígitos, lo que introduce patrones sistemáticos en cómo el modelo percibe y procesa los números. Para evaluar el efecto de estas diferencias, los autores diseñaron tareas aritméticas controladas y comparan el desempeño de distintos modelos bajo diferentes esquemas de tokenización, encontrando que la tokenización de derecha a izquierda, forzada mediante separadores de comas, mejora el rendimiento aritmético de GPT-3.5 y GPT-4. Sus resultados muestran que la tokenización no es un paso neutral del pipeline, sino que puede ser fuente de sesgos útiles o perjudiciales dependiendo del dominio de aplicación, y que cl100k en particular produce representaciones numéricas con una estructura interna predecible y analizable.

A partir de ahí, fue momento de usar las pruebas no paramétricas mencionadas al inicio de esta sección junto con la ley de Benford para los primeros enésimos términos. El primer resultado que se obtuvo fue que, al aplicar tokenización con base cl100k y el test de

Kolmogórov-Smirnov (KS), se evaluó si la distribución empírica de los dígitos en la primera posición de las contraseñas tokenizadas se ajusta a la Ley de Benford. Los resultados indican que, aunque visualmente la distribución guarda similitud con la teórica de Benford —con mayor frecuencia del dígito 1—, el test KS rechaza H_0 ($D = 0.0985$), lo que significa que la diferencia es estadísticamente significativa y no puede descartarse como aleatoria. Esto implica que las contraseñas no son completamente aleatorias en su primera posición: siguen un patrón parcialmente compatible con Benford, pero no con la rigurosidad formal requerida por el test. Este resultado se apoya en la literatura de Caputi (2019) sobre la Ley de Benford y en Chandy et al. (2025) sobre el test KS, y motiva la exploración de las posiciones subsiguientes para determinar si el ajuste mejora a medida que avanza la posición.

En sintonía con anterior, el segundo resultado que se obtuvo (relacionado a los dígitos en la segunda posición), fue que con la misma metodología de tokenización cl100k y el test KS, se llegó a que, al igual que en la posición 1, la distribución empírica muestra una forma visualmente similar a la Ley de Benford, pero el test KS rechaza H_0 ($D = 0.0108$), indicando que el ajuste no es suficiente para confirmar estadísticamente el seguimiento de dicha ley. La diferencia con la posición 1 es que el estadístico D es mucho menor, lo que sugiere un mejor ajuste relativo, aunque aún insuficiente. Este resultado consolida la hipótesis de que las primeras posiciones de las contraseñas son las que más se desvían del comportamiento esperado bajo Benford, lo que refuerza que las claves no son completamente aleatorias. Constituye un eslabón clave en la cadena de análisis posicional, orientando la investigación hacia la posición 3 y siguientes para buscar un ajuste formal.

Al realizar un proceso análogo a los anteriores para el tercer dígito se obtuvo resultados diferentes, y fue que el test no rechazó H_0 ($D = 0.0003$), lo que indica que la distribución empírica de los dígitos en esta posición sigue la Ley de Benford de manera estadísticamente aceptable. Este es el primer punto de la cadena posicional en el que se confirma formalmente el ajuste a Benford, marcando una ruptura con el comportamiento de las posiciones 1 y 2. El hallazgo es significativo porque demuestra que no basta con la similitud visual para afirmar que una distribución sigue Benford; es imprescindible validarlo con pruebas formales como el test KS. En consonancia con Caputi (2019) y Chandy et al. (2025), este resultado sienta la base para verificar si las posiciones 4 en adelante mantienen el mismo patrón, avanzando hacia una caracterización más completa de la aleatoriedad de las contraseñas.

Similar al caso anterior, el análisis de la cuarta posición de las contraseñas tokenizadas con cl100k confirma, nuevamente, que el test KS no rechaza H_0 ($D = 0.0003$), validando que la distribución de dígitos en esta posición se ajusta formalmente a la Ley de Benford. Este resultado es consistente con el hallazgo de la posición 3 y forma parte de un patrón más amplio: se determinó que a partir de la posición 3 en adelante, todas las posiciones siguen Benford de forma confirmada por KS, lo cual resulta inesperado dado que las posiciones 1 y 2 no lograron pasar el test. Esto revela que la naturaleza de los dígitos en posiciones iniciales es cualitativamente diferente a la de las posiciones intermedias y finales, y que no basta con la similitud visual para afirmar el seguimiento de una distribución: la validación formal es imprescindible. La discrepancia plantea la necesidad de explorar nuevas estrategias de tokenización que permitan extender el cumplimiento de Benford a todas las posiciones, en línea con Caputi (2019) y Chandy et al. (2025).

Luego, se hizo un análisis juntando el concepto de entropía con la prueba de Kruskal-Wallis. Así, se compararon las distribuciones de entropía de contraseñas clasificadas según el

tipo de máscara: mixta, solo dígitos, solo letras, solo caracteres especiales y solo mayúsculas. El test rechazó H_0 con alta significancia ($H = 4,366,419,48, p \approx 0$), evidenciando que los cinco tipos de máscara producen distribuciones de entropía completamente distintas. Las contraseñas mixtas presentan la entropía más alta, mientras que las compuestas exclusivamente por caracteres especiales muestran los valores más bajos, contrariamente a lo que podría esperarse intuitivamente. Este agrupamiento es descriptivo y no inferencial, pues la variable de agrupación coincide con la variable de respuesta. El hallazgo enriquece la comprensión del desorden interno en las contraseñas y abre la puerta para determinar si estas diferencias en entropía pueden usarse para cuantificar aleatoriedad real en los pasos siguientes del análisis. Para complementar lo anterior, se hizo lo mismo pero únicamente con la longitud de la máscara. Los resultados de esto último fue que el test rechazó la hipótesis nula ($H = 14,084,456.87, p = 0$), confirmando que existen diferencias estadísticamente significativas entre grupos. Visualmente, se aprecia una tendencia creciente y clara: a mayor longitud de la contraseña, mayor es la entropía media esperada, resultado intuitivo pero que era necesario comprobar formalmente. Esto refuerza la relación entre longitud y complejidad planteada por Reaz (2024), quien asocia la entropía a la dificultad de predicción de una contraseña. No obstante, este resultado no determina qué tan aleatorias son las contraseñas ni cuáles son seguras en términos absolutos; únicamente establece que la longitud es un predictor significativo de la entropía, lo que orienta los análisis inferenciales siguientes sobre aleatoriedad real.

Con el fin de complementar el proyecto mediante un análisis separado de lo narrado anteriormente, se realizó un análisis descriptivo de la distribución empírica de los dígitos (0–9) en las primeras seis posiciones de las contraseñas del dataset RockYou. Se observó que la posición 1 presenta una distribución notablemente sesgada, donde los dígitos más bajos aparecen con mayor frecuencia, lo cual es compatible con la Ley de Benford; la posición 2 también muestra variación, aunque menor. A partir de la posición 3, la distribución se vuelve prácticamente uniforme: todos los dígitos tienen probabilidades de aparición muy similares, independientemente de cuál se elija. Esto sugiere que la primera posición es la más informativa para inferir patrones de creación de contraseñas, mientras que las posiciones posteriores son más predecibles en términos de uniformidad. El resultado no mide aleatoriedad directamente ni indica qué dígitos se usan en mayor volumen, pero construye una base empírica para contrastar con la Ley de Benford (Caputi, 2019) en análisis futuros.

Por último, se construyó una matriz de bigramas para analizar las probabilidades de transición entre tipos de caracteres (letras, dígitos, mayúsculas y caracteres especiales) en las contraseñas del dataset RockYou. Los resultados muestran que la transición de letra a letra es, con diferencia, la más frecuente (66.26 %), seguida de dígito a dígito (23.28 %), lo que evidencia un comportamiento ordenado en la construcción de contraseñas. Transiciones entre tipos distintos, como de carácter especial a otro carácter especial, son prácticamente inexistentes. Este patrón de orden se asocia al concepto de entropía planteado por Reaz (2024), donde la tendencia a permanecer dentro del mismo tipo de carácter refleja baja aleatoriedad entre tipos. Sin embargo, este resultado no describe la distribución general de contraseñas ni sus longitudes, sino únicamente el orden secuencial de sus caracteres, lo cual sienta una base para modelar mejor la entropía en pasos analíticos posteriores.


Parte de reflexión

El cambio más notorio que se dio en la actualización de la Uve de Dowin, fue el cambio de la pregunta de investigación. Esto se debió a que, durante el desarrollo de la presente bitácora, el grupo observó que la base de datos *rockyou.txt* no era la más adecuada para intentar responder la pregunta inicial (esto debido a que la falta de información asociada a cada contraseña provocaba que no se pudieran alcanzar los resultados deseados). Fue por eso que, junto a la supervisión del profesor Maikol Solís Chacón, se decidió cambiar la pregunta de investigación y el objeto de estudio por otras opciones más acordes a la base de datos con la cual se está trabajando.

Además, se hicieron nuevas implementaciones al apartado metodológico, en primer lugar para reflejar el cambio del enfoque del proyecto y en segundo lugar para agregar herramientas que permitan la elaboración de un proyecto más completo con una nueva pruebas no paramétrica.

La sección de conceptos básicos y la de teorías y principios no fue necesario modificarla, pues dichos conceptos siguen siendo relevantes pese al cambio de enfoque del proyecto .

4.0.1. V de Gowin



4.0.2. Conceptos Básicos

1. **Distribución de Probabilidad:** Medio con el que se puede describir la dispersión de los posibles resultados de un experimento estadístico, al mismo tiempo que se le otorga un valor a la probabilidad de que suceda cada resultado.
2. **Contraseña:** Cadena de caracteres que suele ser utilizada durante el un proceso autenticación con el fin de que un dispositivo o plataforma pueda verificar la identidad de un usuario. La combinación de elementos que conforman la contraseña están diseñadas para ser conocidas únicamente por el usuario en cuestión. (Awati, 2025). Para fines del presente proyecto de investigación, se usarán contraseñas que contengan tanto caracteres alfanúmeros (alfabeto inglés o números arábigos) como caracteres especiales.

3. **Bots:** Según Molinaro (2022), se define un bot como “[...] una aplicación de software programada para ejecutar tareas a través de la automatización robótica de procesos”. Para fines de la investigación, no se abundará con mayor detalle el funcionamiento general de un bot, sino que solo se desea analizar y comprender, de manera básica, la forma en la que un bot puede generar contraseñas “aleatorias”, pues esto otorgará ciertos criterios que permitan distinguir las contraseñas generadas por bots de aquellas generadas por humanos.

4.0.3. Teorías y Principios

1. **Ley de Benford:** Según Sarkar (2025), la Ley de Benford establece que los primeros números que se encuentran en una base de datos dada varían su cantidad de apariciones según los dígitos que los conforman. En síntesis, el número uno suele aparecer más frecuentemente, seguido por el dos, luego por el tres y así sucesivamente. Sin embargo, Marrero (2019) expone la limitación de que esta ley solo es válida cuando la muestra de números es variada, abarca diversos órdenes de magnitud, se encuentra libre de condicionamientos y sesgos, y tiene la característica de no ser totalmente aleatoria. Es por esto último que el primer autor mencionó el hecho de que dicha ley permite identificar patrones y anomalías en bases de datos “naturales”, lo que se puede aplicar al momento de detectar algunos tipos de fraude.
2. **Entropía:** Dada una variable aleatoria continua X con una función de densidad p , se define la Entropía de X como:

$$h(X) = \int_{-\infty}^{\infty} p(x) \log(p(x)) dx$$

Análogamente, para una variable aleatoria discreta X con función de masa p , su entropía corresponde a:

$$H(X) = \sum_{i=1}^n p(x_i) \log(p(x_i))$$

Conceptualmente, la entropía mide el nivel de aleatoriedad, desorden o variabilidad en un sistema cerrado. Así, cuanto más grande sea la magnitud asociada a la entropía de una variable aleatoria, habrá más incertidumbre al momento de hacer una predicción con respecto al comportamiento de dicha variable. (Reaz y Wunder, 2024). Los autores Lehoucq, Mayer y Tucker hacen la distinción de que la entropía se utiliza de manera diferente en el contexto de teoría de la información (donde se utilizan variables aleatorias) que en el contexto de la estadística (donde se trabaja con muestras). Así, para este proyecto se hará uso de la entropía en los dos contextos mencionados anteriormente.

4.0.4. Metodología

1. **Registro:** Las contraseñas que serán estudiadas a lo largo del desarrollo del proyecto son las obtenidas del dataset “rockyou.txt”, el cual se liberó en internet después de la

compañía *Rock You* tuviera una brecha de seguridad la cual provocó la exposición de más de 32 millones de contraseñas. (Jindal, 2026).

2. **Transformaciones:** Se le aplicarán diversos filtros al dataset “rockyou.txt” mediante el uso de R con el fin de recopilar la información más relevante para los efectos del proyecto.
3. **Test de Kolmogorov-Smirnov:** El test de Kolmogorov-Smirnov es un test no paramétrico el cual permite medir la distancia entre la función de distribución acumulada obtenida empíricamente y la función de distribución acumulada teórica. (Yakir, 2013). Kisbye (2010) resalta que este test puede aplicarse tanto para distribuciones continuas como distribuciones discretas. La autora destaca que, por un lado, los valores críticos están tabulados para algunas distribuciones continuas con parámetros no especificados (normal, gamma, exponencial, entre otras) mientras que, por otro lado, los valores críticos no están valorados para ninguna distribución discreta.
4. **Tokenización:** Según Singh, Strouse (2024), la tokenización se define como un proceso de segmentación de una secuencia de bytes de entrada en tokens discretos. Este proceso cuenta con una fase de entrenamiento donde se aprende un vocabulario de tokens y estadísticas a partir de un corpus de texto, y con una fase de segmentación, en la cual una función usa ese vocabulario para mapear secuencias de bytes a tokens.
5. **Prueba de Kruskal-Wallis:** De acuerdo a Childs, Hindle y Warren (2021), la prueba Kruskal-Wallis consiste en evaluar las diferencias entre dos (o más) muestras. Para lograr esto, las variables deben ser no nominales, las observaciones de cada grupo deben ser independientes y la distribución de las variables de cada grupo deben ser “similares”. Con respecto a esta última condición, los autores destacan que lo más importante es que las distribuciones sean aproximadamente igual de asimétricas. En síntesis, esta prueba permite encontrar la diferencia entre las medias, medianas o modas entre dos o más grupos. La hipótesis nula en esta prueba es que los grupos tienen la misma mediana.

Diario de aprendizaje

- Conocemos el proceso de tokenización del lenguaje natural hacia vectores numéricos; estos tienen un mayor peso cuando aportan más información al modelo.
- Aprendimos que los primeros dígitos de las contraseñas no siguen la distribución de Benford debido a patrones internos como fechas y otros.
- La búsqueda de literatura nos enseñó que no siempre es fácil comprender la información en ellos, y a veces resulta difícil reducirla a un resumen.

Registro del uso de IA

5.0.1. Conceptos Básicos

Herramienta: Claude (Anthropic) *Prompt:* Prompts iterativos para la generación de menús interactivos dentro de los scripts del proyecto, la generación de gráficos en Python y el guardado de los datos procesados. *Respuesta de la IA:* El código generado se puede encontrar en los scripts del proyecto, particularmente en los archivos de tokenización y análisis descriptivo. *Evaluación:* Cada fragmento de código generado fue revisado y probado por al menos un miembro del equipo, verificando que la lógica fuera correcta y coherente con los objetivos del proyecto. *Modificaciones:* Se realizaron ajustes menores de estilo y correcciones puntuales de lógica tras las pruebas de ejecución. *Aprendizaje:* Se observó que Claude es capaz de generar código funcional y estructurado para tareas de procesamiento de datos, aunque siempre requiere supervisión humana para garantizar que el resultado sea el esperado. *Herramienta:* Claude (Anthropic) *Prompt:* “Corrige los errores gramaticales y de tildes en

el siguiente texto, sin modificar el contenido ni el estilo de redacción.” (Texto adjuntado: sección de Metodologías) *Respuesta de la IA:* El texto corregido fue incorporado directamente en la sección de Metodologías del informe. *Evaluación:* Un miembro del equipo comparó el texto original con el corregido para verificar que no se hubieran alterado el contenido ni la intención de ningún párrafo. *Modificaciones:* Ninguna adicional; las correcciones propuestas fueron aceptadas en su totalidad. *Aprendizaje:* Claude demostró ser una herramienta confiable para la corrección ortográfica y gramatical de textos académicos en español, reduciendo el tiempo dedicado a la revisión manual. *Herramienta:* Perplexity *Prompt:* Búsqueda de

nuevas referencias bibliográficas relevantes para complementar el marco teórico del proyecto, a partir de los temas tratados en el trabajo. *Respuesta de la IA:* Perplexity proporcionó referencias adicionales junto con sus respectivos enlaces URL, los cuales fueron incorporados al archivo .bib del proyecto. *Evaluación:* Cada referencia sugerida fue revisada por al menos un miembro del equipo para verificar su pertinencia y que correspondiera al tema tratado en el trabajo. *Modificaciones:* En algunos casos fue necesario ajustar manualmente el formato de las entradas bibliográficas para que fueran compatibles con el estilo de citación utilizado en el proyecto. *Aprendizaje:* Se comprobó que Perplexity puede ser una herramienta útil para la búsqueda de bibliografía académica, aunque la verificación manual de cada fuente sigue

siendo indispensable para garantizar su calidad y relevancia.