



UNIVERSIDAD DE COSTA RICA

Escuela de Matemáticas

Estadística Actuarial I (CA0303)

Bitácora #3

Prof: Maikol Solís

Estudiantes:

Anthony Flores Rojas (C32975)

Andrey González Bastos (C33329)

Randal Picado Bermúdez (C36024)

Leonardo Vega Aragón (C38313)

Fecha: 10/06/2026

Contenido

Preparación	1
Audiencia del proyecto	1
Rastro de decisiones	1
Respuesta a retroalimentación	1
Log de contribuciones	2
Parte de planificación	3
Análisis de modelación	3
Propuesta metodológica	3
Construcción de fichas de resultados	11
Ordenamiento de los elementos de reporte	24
Elementos primarios y secundarios	24
Ordenamiento por secciones	25
La imagen que cuenta la historia	26
Arco narrativo del proyecto	27
Parte de escritura	28
Parte de reflexión	29
Diario de aprendizaje	30
Registro del uso de IA	31

Preparación

Audiencia del proyecto

Esta semana, le diría a nuestra audiencia que aplicar una tokenización con el modelo cl100k, permitió seguir mejor las distribuciones de Benford en los dígitos, solo que se cumple de la posición 3 en adelante, aún falta acomodar los datos de forma que se cumplan también en las primeras dos, este resultado se detalla más adelante.

Rastro de decisiones

No se descartó ninguna metodología, en su lugar se implementó la idea del prodfesor de tokenizar las contraseñas para poder hacer un mejor trabajo con las distribuciones de Benford de sus dígitos y con el test KS, para no perder la información de la parte de letras de las contraseñas.

Respuesta a retroalimentación

En la pasada bitácora los puntos que se nos bajaron fueron en ortografía, por lo cual para esta bitácora se tomó muchísimo más cuidado con este aspecto.

Log de contribuciones

Integrante	Tarea
Anthony Flores Rojas (C32975)	■ Parte 1.1 Depuración del código, colaboración con 1.2, diario de aprendizaje, colaboración fichas de literatura.
Andrey González Bastos (C33329)	■ 1.3 Fichas de resultados, colaboración fichas de literatura, colaboración con 1.2.
Randal Picado Bermúdez (C36024)	■ 1.4 Ordenamiento de los elementos de reporte, 1,5 La imagen que cuenta la historia, 2 Arco narrativo, colaboración con fichas de literatura.
Leonardo Vega Aragón (C38313)	■ 3 Parte de escritura, 4 Parte de reflexión, colaboración con fichas de literatura.

Table 1: Log de contribuciones — Bitácora #3

Parte de planificación

Análisis de modelación

En esta parte del trabajo todo se basó en mejorar el código hecho hasta el momento, el mismo se puede ver en el git, más específicamente en la carpeta código (03_modelacion.py).

Propuesta metodológica

1.2 Propuesta Metodológica

Pregunta de investigación

¿En qué medida los patrones estructurales de las contraseñas del dataset RockYou - su composición de caracteres, longitud y distribución de dígitos - determinan su nivel de entropía y evidencian que los usuarios no eligen contraseñas de forma aleatoria?

Tokenización CL100K sobre las contraseñas

Motivación

El tokenizador CL100K usado por GPT-4 transforma cada texto en un vector de embeddings de dimensión alta. Cuando se calcula la norma del vector de tokenización de una contraseña, el resultado es un número real que contiene una distribución de dígitos en cada posición. Si los dígitos presentes en estas normas se desvían de la distribución de Benford, existe evidencia de que los usuarios eligen contraseñas con patrones sistemáticos que el modelo-tokenizador captura de manera predecible, lo que implica vulnerabilidad en la representación interna. Se utiliza la tokenización, ya que es una transformación relativamente “natural” del lenguaje humano a dígitos, dado que el tokenizador CL100K fue entrenado sobre datos reales de uso humano según los análisis publicados por OpenAI, lo que permite detectar si los patrones de elección de contraseñas se preservan en la representación interna del modelo.

Tokenización CL100K y norma elegida

Sea c una contraseña del conjunto de datos $\mathcal{C}$. El tokenizador CL100K la transforma en un vector de embeddings:

$$\text{CL100K}(c) = \mathbf{v}_c = (v_1, v_2, \dots, v_d) \in \mathbb{R}^d, \quad (1.1)$$

donde d es la dimensión del embedding (típicamente $d \approx 100,000$ para CL100K).

Se elige la norma de valor absoluto del vector

$$\|\mathbf{v}_c\|_1 = \sum_{i=1}^d |v_i| \in \mathbb{R}_{\geq 0}. \quad (1.2)$$

Esta norma fue elegida simplemente por su interpretación directa como la suma total de las magnitudes de las componentes del vector de tokenización, lo que permite extraer la distribución de dígitos en cada posición del número resultante.

Para cada $\|\mathbf{v}_c\|_1$, se extrae el dígito en la posición n

$$D_n(\|\mathbf{v}_c\|_1) = \left\lfloor \frac{\|\mathbf{v}_c\|_1}{10^{n-1}} \right\rfloor \bmod 10, \quad n \in \{1, 2, \dots, N_{\max}\}, \quad (1.3)$$

donde $N_{\max}$ es el número de dígitos de $\|\mathbf{v}_c\|_1$.

Prueba de Kolmogorov-Smirnov contra la distribución de Benford

Motivación

La Ley de Benford establece que en conjuntos de datos numéricos de origen “natural”, el dígito d ocupa la primera posición con una frecuencia predecible (Caputi Zunini, 2019). Si los dígitos presentes en contraseñas reales se desvían de esa distribución, existe evidencia de que los usuarios eligen números con sesgos sistemáticos, lo que implica predecibilidad y, en consecuencia, vulnerabilidad. Se elige la prueba KS (y no una chi-cuadrado) porque compara funciones de distribución acumulada completas sin requerir agrupar celdas; con muestras en el orden de millones, la chi-cuadrado infla el estadístico por el tamaño de n sin aportar información sobre la forma de la desviación (Chandola, Banerjee, & Kumar, 2009; Chandy, Schifano, Yan, & Zhang, 2025).

Distribución teórica de Benford generalizada

Sea $(D_n \in \{1, \dots, 9\})$ el dígito en la posición (n) -ésima, entonces la PDF de Benford para $(n=1)$ es

$$\mathbb{P}(\{D_1 = d\}) = \log_{10} \left(1 + \frac{1}{d} \right) \quad (1.4)$$

Para posiciones $n \geq 2$, la fórmula generalizada integra sobre todos los prefijos de longitud $n - 1$, siendo esta

$$\mathbb{P}(\{D_n = d\}) = \sum_{k=10^{n-2}}^{10^{n-1}-1} \log_{10} \left(1 + \frac{1}{10k + d} \right), \quad d \in \{0, 1, \dots, 9\} \quad (1.5)$$

Estadístico KS

Sea $F_n(x)$ la función de distribución acumulada empírica de los dígitos en la posición p y $F_0(x)$ la CDF teórica de Benford. El estadístico Kolmogorov-Smirnov es

$$D_n = \sup_x |F_n(x) - F_0(x)| \quad (1.6)$$

Distribución límite y valor crítico

Kolmogorov (1933) demostró que, bajo H_0 simple (distribución teórica completamente especificada sin parámetros estimados), el estadístico escalado converge en distribución

$$\sqrt{n} D_n \xrightarrow{d} K, \quad n \rightarrow \infty \quad (1.7)$$

donde K es la **distribución de Kolmogorov**, cuya CDF admite la representación en serie

$$P(K \leq t) = 1 - 2 \sum_{j=1}^{\infty} (-1)^{j-1} e^{-2j^2 t^2} \quad (1.8)$$

Para valores de t no demasiado pequeños, el primer término domina y la aproximación de un término es suficiente

$$P(K > t) \approx 2e^{-2t^2} \quad (1.9)$$

El cuantil crítico t_α se obtiene igualando la expresión anterior a α y despejando

$$2e^{-2t_\alpha^2} = \alpha \implies t_\alpha = \sqrt{-\frac{1}{2} \ln(\frac{\alpha}{2})} \quad (1.10)$$

Para $\alpha = 0,05$ (el alpha escogido)

$$t_{0,05} = \sqrt{-\frac{1}{2} \ln(0,025)} = \sqrt{\frac{3,6889}{2}} = \sqrt{1,8444} \approx 1,3581 \quad (1.11)$$

Dado que la distribución límite es la de $\sqrt{n} D_n$, el valor crítico sobre el estadístico muestral es

$$D_\alpha = \frac{t_\alpha}{\sqrt{n}} \implies D_{0,05} = \frac{1,36}{\sqrt{n}} \quad (1.12)$$

Se rechaza H_0 (los dígitos siguen Benford) cuando $D_n > D_\alpha$. Dado que $n \sim 10^6$, el umbral D_α es extremadamente pequeño, por lo que se complementa el resultado con la desviación absoluta media (MAD)

$$\text{MAD} = \frac{1}{|\mathcal{D}|} \sum_{d \in \mathcal{D}} |\mathbb{P}_{\text{emp}}(d) - \mathbb{P}_{\text{Benford}}(d)| \quad (1.13)$$

donde $\mathcal{D}$ es el conjunto de dígitos válidos para la posición dada. Los umbrales de conformidad son $\text{MAD} < 0,006$ (muy cercana), $0,006$ – $0,012$ (aceptable), $0,012$ – $0,015$ (marginal)

y $> 0,015$ (no conformidad) (Negrini, 2012).

Conexión con la pregunta de investigación

Si KS rechaza H_0 y MAD indica no conformidad, los dígitos de las contraseñas presentan sesgos sistemáticos respecto a una distribución numéricamente “natural”.

Análisis de distribución de máscaras de contraseña

Motivación

Las contraseñas humanas no son cadenas aleatorias, los usuarios exhiben patrones estructurales sistemáticos al elegirlos. Para capturar esa estructura sin depender del contenido semántico de cada contraseña, se utiliza una representación de máscara, que abstrae cada carácter a su tipo. Formalmente, dado el alfabeto de tipos $\Sigma = \{L, U, D, S\}$ (minúsculas, mayúsculas, dígitos, caracteres especiales), la máscara de una contraseña $P = c_1 c_2 \dots c_n$ es

$$M(P) = \tau(c_1) \tau(c_2) \dots \tau(c_n), \quad \tau(c) = \begin{cases} L & c \in \mathcal{L} \\ U & c \in \mathcal{U} \\ D & c \in \mathcal{D} \\ S & c \in \mathcal{S} \end{cases} \quad (1.14)$$

Se elige esta representación y no, por ejemplo, n -gramas de caracteres, porque permite cuantificar la predecibilidad estructural independientemente del vocabulario léxico. Si pocas máscaras concentran la mayor parte de las contraseñas, el espacio de búsqueda efectivo es mucho menor que el espacio teórico, lo que constituye evidencia directa de vulnerabilidad sistemática.

Patrones comprimidos

Para reducir el espacio de máscaras sin perder información sobre la composición, se aplica una codificación de longitud de racha (*run-length encoding*) sobre $M(P)$. Sea $M(P) = t_1^{r_1} t_2^{r_2} \dots t_k^{r_k}$ la descomposición en rachas consecutivas del mismo tipo, entonces el patrón comprimido es

$$R(P) = t_1 r_1 \ t_2 r_2 \ \dots \ t_k r_k \quad (1.15)$$

Por ejemplo, la máscara LLLLLLDD se comprime a L6D2. Esta representación agrupa contraseñas con la misma composición por bloques, lo que facilita el análisis de patrones frecuentes en el dataset. La distribución de patrones comprimidos se analiza por frecuencia absoluta f_j y proporción relativa $\hat{p}_j = f_j/N$, donde N es el total de contraseñas.

Conexión con la pregunta de investigación

Si la distribución de máscaras está fuertemente concentrada, se confirma que los usuarios eligen contraseñas con patrones estructurales predecibles. Esto responde la pregunta de

investigación en su dimensión composicional: no solo los dígitos siguen sesgos (KS vs. Benford), sino que la estructura completa de la contraseña es predecible antes de conocer un solo carácter.

Entropía de Shannon y de densidad de contraseñas individuales

Motivación

A diferencia de los análisis de distribución a nivel de dataset, la entropía de una contraseña individual cuantifica la incertidumbre interna de su composición, cuán mezclados están los tipos de carácter que la conforman. Se elige la entropía de Shannon (Khan & Wunder, 2024) sobre la distribución de tipos dentro de la contraseña porque es una medida establecida de incertidumbre que no requiere conocer el vocabulario léxico del usuario, es calculable en tiempo $O(|P|)$, y es interpretable directamente como bits de información. Frente a métricas de fuerza basadas en combinatoria ($\log_2 |\mathcal{K}|^{|P|}$), que solo dependen del espacio de caracteres y la longitud, la entropía de Shannon captura además la diversidad de tipos usados dentro de la contraseña.

Definición

Entropía de Shannon

Sea P una contraseña y sea p_t la proporción del tipo $t \in \Sigma$ en P . La entropía de Shannon de P es

$$H_S(P) = - \sum_{t \in \Sigma} p_t \log_2 p_t \quad (1.16)$$

Entropía de densidad

Complementariamente, se define la entropía de densidad como la entropía de Shannon normalizada por la longitud de la contraseña

$$H_D(P) = \frac{H_S(P)}{|P|} \quad (1.17)$$

H_D penaliza las contraseñas largas pero uniformes (e.g., `aaaaaaaaaa` tiene $H_S = 0$ independientemente de la longitud) y premia aquellas con alta diversidad por carácter. Esta métrica está relacionada con la *Expectation entropy* propuesta por Khan & Wunder (2024), que escala la información de composición por el espacio máximo posible del alfabeto; ambas buscan capturar la fortaleza de la contraseña en una escala normalizada.

Conexión con la pregunta de investigación

Las estructuras internas repetitivas dentro de las contraseñas son penalizadas por ambas métricas de entropía: H_S captura la falta de diversidad entre tipos de carácter, mientras que H_D la penaliza adicionalmente en función de la longitud. Contraseñas con entropías bajas presentan menor incertidumbre interna y, por lo tanto, mayor predecibilidad desde la

perspectiva del atacante. Este resultado se complementa con la prueba de Kruskal-Wallis, que permite determinar si la estructura de la máscara discrimina significativamente el nivel de entropía observado.

Prueba de Kruskal-Wallis sobre entropías por grupo

Motivación

Se busca determinar si la estructura de la máscara (longitud y tipo dominante de caracteres) discrimina el nivel de entropía. Se elige Kruskal-Wallis (KW) en lugar de ANOVA de un factor porque

- Las distribuciones de entropía por grupo no son normales (asimétricas, con colas largas), como se verifica en el análisis descriptivo.
- KW es una prueba no paramétrica de rangos que no asume homocedasticidad ni normalidad dentro de los grupos.

Entropía de Shannon de una máscara

La entropía media de la máscara m se define como en la ecuación~(1.16), donde $\Sigma = \{L, U, D, S\}$ es el alfabeto de tipos de carácter (minúsculas, mayúsculas, dígitos, símbolos) y p_c es la proporción del tipo c en m .

Estadístico de Kruskal-Wallis

Dadas k muestras independientes de tamaños $n_1, \dots, n_k$ con $N = \sum_{i=1}^k n_i$ observaciones totales, el estadístico es

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1) \quad (1.18)$$

donde R_i es la suma de rangos del grupo i sobre el ranking global. Bajo H_0 (todas las distribuciones son iguales), $H \sim \chi_{k-1}^2$ para muestras grandes.

Ponderación por frecuencia

Como cada máscara m_j tiene una frecuencia f_j (número de contraseñas reales que la usan), se expande la muestra repitiendo cada observación con su frecuencia real:

$$\tilde{n}_j = f_j \quad (1.19)$$

Para garantizar la reproducibilidad del proyecto, la implementación incluye un parámetro de tope C configurable

$$\tilde{n}_j = \min(f_j, C) \quad (1.20)$$

En este trabajo se fija $C = 10\,000\,000$, valor que excede la frecuencia máxima observada en el dataset RockYou ($f_{\text{máx}} = L6$ con 3 996 634 observaciones), por lo que el tope es inactivo

y se cumple $\tilde{n}_j = f_j$ para toda máscara m_j . El vector de rangos reproduce así fielmente la distribución real del dataset.

Agrupaciones evaluadas

Se aplica KW bajo tres criterios de agrupación

1. Longitud de máscara: grupos $g \in \{1, 2, \dots, L_{\text{máx}}\}$ donde $L_{\text{máx}}$ es la longitud máxima observada.
2. Tipo dominante: Solo L, Solo D, Solo U, Solo S, Mixta.
3. Rango de entropía: bajo ($H < 2,4464$, por debajo del percentil 25), medio ($2,4464 \leq H < 2,9477$, entre los percentiles 25 y 75) y alto ($H \geq 2,9477$, por encima del percentil 75). Este agrupamiento es descriptivo, no inferencial, pues la variable de agrupación coincide con la variable de respuesta.

Conexión con la pregunta de investigación

Si KW rechaza H_0 en los criterios de longitud y tipo dominante, se confirma que la estructura de la máscara predice significativamente la entropía. Esto implica que conocer el patrón de una contraseña reduce la incertidumbre sobre su espacio de búsqueda, respondiendo la pregunta en su dimensión estructural.

Correlación de Spearman entre longitud y entropía

Motivación

KW indica si los grupos difieren, pero no cuantifica la dirección ni la fuerza de la relación entre longitud y entropía. Se elige el coeficiente de Spearman (y no Pearson) porque

- La relación puede ser monótona pero no lineal: la entropía puede estabilizarse a partir de cierta longitud.
- Spearman es robusto ante outliers y no asume normalidad bivariada.
- Es equivalente a Pearson aplicado sobre los rangos, lo que lo hace válido para datos ordinales y distribuciones sesgadas.

Coeficiente de Spearman

Sea $\{(\ell_j, h_j)\}_{j=1}^n$ el conjunto de pares (longitud de máscara, entropía media). El coeficiente de correlación de Spearman se calcula sobre los rangos $\{(r_j^\ell, r_j^h)\}$

$$\rho_s = 1 - \frac{6 \sum_{j=1}^n d_j^2}{n(n^2 - 1)}, \quad d_j = r_j^\ell - r_j^h \quad (1.21)$$

O, equivalentemente, como el coeficiente de Pearson de los rangos

$$\rho_s = \frac{\sum_{j=1}^n (r_j^\ell - \bar{r}^\ell)(r_j^h - \bar{r}^h)}{\sqrt{\sum_{j=1}^n (r_j^\ell - \bar{r}^\ell)^2} \sqrt{\sum_{j=1}^n (r_j^h - \bar{r}^h)^2}} \quad (1.22)$$

Variantes de cálculo

Se calculan dos versiones para verificar robustez

$$\rho_{\text{raw}} = \rho_s(\{\ell_j\}, \{h_j\}) \quad (1.23)$$

$$\rho_{\text{pond}} = \rho_s(\{\ell_j^*\}, \{h_j^*\}), \quad \text{donde } |\{j^* : \ell_{j^*} = \ell_j\}| = \min(f_j, C') \quad (1.24)$$

con $C' = 200\,000$. Si $\rho_{\text{raw}} \approx \rho_{\text{pond}}$, la correlación es robusta a la distribución de frecuencias.

Interpretación del tamaño del efecto

$$|\rho_s| \in \begin{cases} [0,7, 1,0] & \text{correlación fuerte} \\ [0,4, 0,7) & \text{correlación moderada} \\ [0,0, 0,4) & \text{correlación débil} \end{cases} \quad (1.25)$$

Conexión con la pregunta de investigación

Un ρ_s alto y positivo confirma que contraseñas más largas son estadísticamente más entrópicas, lo que respalda con evidencia cuantitativa la recomendación de longitud mínima en políticas de seguridad. Complementa KW al ofrecer una medida continua de la relación: no solo se sabe que los grupos difieren, sino cuánto y en qué dirección.

Análisis fallido: Ley de Benford sobre dígitos numéricos de contraseñas

Descripción del intento

Se intentó aplicar la Ley de Benford directamente sobre la distribución de los dígitos numéricos presentes en las contraseñas y sus subcadenas (*chunks*) numéricos, con la hipótesis de que, al tratarse de un conjunto masivo de datos generado por comportamiento humano, los primeros dígitos seguirían la distribución logarítmica característica de Benford.

Por qué no funcionó

La aplicación resultó inválida por razones tanto empíricas como teóricas. La distribución de caracteres numéricos en datasets de contraseñas no cumple las condiciones de aplicabilidad

de la Ley de Benford por varias razones estructurales:

- **Patrones de fechas:** Una fracción significativa de los componentes numéricos corresponde a años (ej. 1990, 2003), meses y días, cuya distribución de primeros dígitos está acotada artificialmente (los años modernos comienzan casi todos con 1 o 2, los meses con 0 o 1).
- **Restricciones de longitud:** Las políticas de contraseñas imponen longitudes mínimas y máximas que truncan el espacio numérico disponible, eliminando la variación de varios órdenes de magnitud que Benford requiere para operar.
- **Sesgos cognitivos del usuario:** Los usuarios concentran sus elecciones en números redondos, secuencias simples (123, 000) y años de nacimiento, lo que produce una distribución de primeros dígitos fuertemente no uniforme pero tampoco logarítmica.

Esto fue confirmado tanto mediante la revisión de la literatura especializada como mediante la comparación entre la distribución empírica observada y la distribución teórica de Benford usando el estadístico KS, el cual rechazó H_0 con un valor de D_n muy superior al umbral crítico $D_{0,05} = 1,36/\sqrt{n}$ (Bonneau, 2012; Chandy, Schifano, Yan, & Zhang, 2025).

Lección metodológica

Este análisis fallido dejó una lección importante: no siempre se llega al resultado esperado, y la idea intuitiva de una hipótesis no es suficiente para garantizar su validez empírica. Antes de comprometer recursos en la implementación de un método, es necesario estudiar en profundidad las condiciones de aplicabilidad del mismo, explorar la distribución real de los datos y revisar la literatura para identificar restricciones estructurales que puedan invalidar el enfoque desde el inicio. En este caso, una revisión más cuidadosa de los supuestos de Benford habría anticipado que un dataset de contraseñas, por su naturaleza acotada y culturalmente sesgada, no constituye el tipo de magnitudes de origen “natural” para las que la ley fue concebida.

Construcción de fichas de resultados

———— FICHA 1 ————

Nivel descriptivo (¿qué encontraron?)

Titular

No se cumple similitud en las distribuciones con tokenización en la posición 1.

Nombre del hallazgo/resultado

KS y Benford no concuerdan en la primera posición de las contraseñas tokenizadas con cl100k base.

Resumen en una oración

Para la primera posición de la contraseña, se cumple Benford teóricamente pero no lo suficiente para pasar el test KS.

Método o análisis que lo produjo

Se usó la tokenización con base cl100k, para tener mayor control de la parte de letras y de números al mismo tiempo, se le aplicó el test KS y se descubrió que sigue una distribución similar a la Benford teórica, al menos en la posición 1, pero no lo suficiente para pasar el test KS, por lo que se rechaza H_0 .

Evidencia




Figure 1.1: KS y Benford para posición 1 con contraseñas tokenizadas

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre cómo se distribuyen los dígitos en las posiciones, en este caso, la posición 1 en las contraseñas siguen Benford, no lo suficiente para pasar KS, por lo que vemos que las claves no son tan aleatorias como parecen.

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a Benford de María Caputi (2019), sobre el test KS (Chandy, et.al, 2025) que nos ayudó a comprobar la distribución en este caso para la posición 1.

Lo que NO explica este resultado

Este resultado claramente NO explica que todas las posiciones se rijan bajo ley de Benford y que no se cumpla el test KS, este resultado solo nos guía para la posición 1.

Implicación para el siguiente paso

Nos toca averiguar si esto mismo se cumple para las siguientes posiciones en las contraseñas del dataset de RockYou.

————- FICHA 2 —————

Nivel descriptivo (¿qué encontraron?)

Titular

No se cumple similitud en las distribuciones con tokenización en la posición 2.

Nombre del hallazgo/resultado

KS y Benford no concuerdan en la segunda posición de las contraseñas tokenizadas con cl100k base.

Resumen en una oración

Para la segunda posición de la contraseña, no concuerdan KS y Benford.

Método o análisis que lo produjo

Se usó la tokenización con base cl100k, para tener mayor control de la parte de letras y de números al mismo tiempo, se le aplicó el test KS y se descubrió que sigue una distribución similar a la Benford teórica, al menos en la posición 2, pero no lo suficiente para lograr pasar el test KS, por lo cual se rechaza H_0 .

Evidencia

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre cómo se distribuyen los dígitos en las posiciones, en este caso, la posición 2 en las contraseñas siguen Benford, no pasando KS, por lo que vemos que las claves no son tan aleatorias como parecen.




Figure 1.2: KS y Benford para posición 2 con contraseñas tokenizadas

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a Benford de María Caputi (2019), sobre el test KS (Chandy, et.al, 2025) que nos ayudó a comprobar la distribución en este caso para la posición 2.

Lo que NO explica este resultado

Este resultado claramente NO explica que todas las posiciones se rijan bajo ley de Benford y que no se cumpla el test KS, este resultado solo nos guía para la posición 2.

Implicación para el siguiente paso

Nos toca averiguar si esto mismo se cumple para las siguientes posiciones en las contraseñas del dataset de RockYou.

———— FICHA 3 ————

Nivel descriptivo (¿qué encontraron?)

Titular

Se cumple similitud en las distribuciones con tokenización en la posición 3.

Nombre del hallazgo/resultado

Se puede afirmar KS y Benford en la tercera posición de las contraseñas tokenizadas con cl100k base.

Resumen en una oración

Para la tercera posición de la contraseña tokenizada, se sigue Benford.

Método o análisis que lo produjo

Se usó la tokenización con base cl100k base, para tener mayor control de la parte de letras y de números al mismo tiempo, se le aplicó el test KS y se descubrió que se sigue una distribución similar a la Benford teórica, al menos en la posición 3.

Evidencia




Figure 1.3: KS y Benford para posición 3 con contraseñas tokenizadas

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre cómo se distribuyen los dígitos en las posiciones, en este caso, la posición 3 en las contraseñas siguen Benford, comprobado con KS.

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a Benford de María Caputi (2019), sobre el test KS (Chandy, et.al, 2025) que nos ayudó a comprobar la distribución en este caso para la posición 3.

Lo que NO explica este resultado

Este resultado claramente NO explica que todas las posiciones se rijan bajo ley de Benford, este resultado solo nos guía para la posición 3.

Implicación para el siguiente paso

Nos toca averiguar si esto mismo se cumple para las siguientes posiciones en las contraseñas del dataset de RockYou.

————- FICHA 4 ————

Nivel descriptivo (¿qué encontraron?)

Titular

Se cumple similitud en las distribuciones con tokenización en la posición 4.

Nombre del hallazgo/resultado

Se puede afirmar KS y Benford en la cuarta posición de las contraseñas tokenizadas con cl100k base.

Resumen en una oración

Para la cuarta posición de la contraseña tokenizada, se sigue Benford.

Método o análisis que lo produjo

Se usó la tokenización con base cl100k base, para tener mayor control de la parte de letras y de números al mismo tiempo, se le aplicó el test KS y se descubrió que se sigue una distribución similar a la Benford teórica, al menos en la posición 4.

Evidencia

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre cómo se distribuyen los dígitos en las posiciones, en este caso, la posición 4 en las contraseñas tokenizadas siguen Benford, comprobado con KS.




Figure 1.4: KS y Benford para posición 4 con contraseñas tokenizadas

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a Benford de María Caputi (2019), sobre el test KS (Chandy, et.al, 2025) que nos ayudó a comprobar la distribución en este caso para la posición 4.

Lo que NO explica este resultado

Este resultado claramente NO explica que todas las posiciones se rijan bajo ley de Benford, este resultado solo nos guía para la posición 4.

Implicación para el siguiente paso

Nos toca averiguar si esto mismo se cumple para las siguientes posiciones en las contraseñas del dataset de RockYou.

Comparación explícita

Para la posición 3 en adelante, se descubrió que todas las posiciones siguen Benford comprobado con KS, resultado inesperado pues se venía sin poder seguir en las posiciones anteriores (1) y (2) respectivamente. Esto es un resultado curioso, pues esperábamos que en todas las posiciones se cumpliera Benford y no solo a partir de la tercera posición en adelante.

Esto sucede pues aunque la posición 1 y 2 “siguen Benford”, no lo hacen de forma que también se pase el test KS. Esto último es sumamente importante y aquí recae la magia de todo, que no basta con parecer que la siga, sino que se tiene que acoplar también a pasar por test formales para poder efectivamente comprobarlo y no hacerlo simplemente a ojo.

Sin embargo, esta discrepancia hace que se tengan que buscar nuevos métodos de tokenización o de manipulación de los mismos para ver si en algún caso o uso se sigue Benford como se cree según la literatura (en todas las posiciones).

Nivel descriptivo (¿qué encontraron?)

Titular

Las máscaras determinan mucho la entropía.

Nombre del hallazgo/resultado

Distribuciones de la entropía según la máscara que se haya utilizado.

Resumen en una oración

Los cinco tipos de máscara producen distribuciones de entropía completamente diferentes.

Método o análisis que lo produjo

Se usó la prueba de Kruskal-Wallis sobre entropías, se separaron las máscaras de la siguiente forma: Mixta, solo dígitos, solo letras, solo caracteres especiales o solo mayúsculas. Usando para las entropías los siguientes rangos: bajo ($H < 2.4464$), medio ($2.4464 \leq H < 2.9477$), alto ($H \geq 2.9477$). Este agrupamiento es descriptivo, no inferencial, pues la variable de agrupación coincide con la variable de respuesta.

Evidencia




Figure 1.5: Kruskal-Wallis - Entropía por tipo de máscara

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre las entropías (desordenes) en las contraseñas, en este caso ahora sabemos que la entropía varía según cómo esté hecha la contraseña, si es mixta con todo posee una alta entropía como es esperado y si es solo de caracteres especiales pues tiende a tener una menor entropía.

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a la prueba de KW de los autores de APS 240, paper donde se explica como aplicar este test para resultados como el obtenido anteriormente.

Lo que NO explica este resultado

Este resultado no nos arroja la aleatoriedad de las contraseñas o si son naturales, simplemente nos arroja el resultado de diferentes entropías según queramos tener diferentes estructuras de contraseñas.

Implicación para el siguiente paso

Nos toca averiguar si este resultado nos ayuda a determinar la aleatoriedad de las contraseñas que los usuarios escogen.

————- FICHA 6 —————

Nivel descriptivo (¿qué encontraron?)

Titular

Las longitudes de las contraseñas determinan su entropía.

Nombre del hallazgo/resultado

Las máscaras según la longitud de la contraseña determina su entropía.

Resumen en una oración

A mayor longitud de la contraseña, mayor entropía se espera según el test Kruskal-Wallis.

Método o análisis que lo produjo

Se usó la prueba de Kruskal-Wallis sobre entropías, se separaron las máscaras de la siguiente forma: según la longitud de la máscara.

Evidencia




Figure 1.6: Kruskal-Wallis - Entropía por longitud de máscara

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre las entropías (desordenes) en las contraseñas, en este caso ahora sabemos que la entropía es creciente según la longitud, lo cual es un resultado esperado pero se debía comprobar.

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura relacionada a la prueba de KW de los autores de APS 240, paper donde se explica como aplicar este test para resultados como el obtenido anteriormente. También, se ve como la entropía tiene que ver con la seguridad de las contraseñas, tal como lo planteó Reaz(2024), el cual planteaba que a una mayor entropía, más complicado es de predecir el valor de una observación, en este caso, de una contraseña.

Lo que NO explica este resultado

Este resultado no nos arroja la aleatoriedad de las contraseñas o que tan seguras son, simplemente nos arroja el resultado de diferentes entropías según la longitud de las mismas.

Implicación para el siguiente paso

Nos toca averiguar si este resultado nos ayuda a determinar la aleatoriedad de las contraseñas que los usuarios escogen.

———— FICHA 7 ————

Nivel descriptivo (¿qué encontraron?)

Titular

Las probabilidades de aparecer tienden a ser las mismas en dado momento.

Nombre del hallazgo/resultado

Distribución empírica de dígitos por posición (análisis descriptivo).

Resumen en una oración

Después de la posición 3, las probabilidades de que un dígito salga es casi uniforme.

Método o análisis que lo produjo

Se realizó un análisis descriptivo de los datos de RockYou para poder determinar la distribución empírica de los dígitos por posición.

Evidencia




Figure 1.7: Distribución empírica de dígitos por posición

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre como se distribuyen los dígitos por posición en las contraseñas, esto nos puede dar una pista de como las personas escogen los dígitos según la posición, se ve claramente como el que más varía es la primera posición, por lo que podemos concluir que esa posición es la más vulnerable a cambios según el usuario, la segunda también, después de eso, vemos como los cambios en los dígitos casi se puede asegurar que lleva una distribución uniforme y su probabilidad “de salir” es igual independientemente del dígito escogido. Todo esto nos ayuda a comprender mejor como los usuarios crean sus contraseñas y que tan aleatorias pueden llegar a ser.

Contraste con la literatura

Este hallazgo es propio y característico de la base de datos seleccionada, sin embargo, para la primera posición, se puede inferir como se cumple la ley de Benford y de hecho es un resultado de una ficha anterior, por lo que esto nos alimenta la creencia de que las claves siguen Benford pero hay que comprobarlo, esto ligado a la literatura de Caputi(2019).

Lo que NO explica este resultado

Este resultado no nos arroja la aleatoriedad de las contraseñas o que dígitos se usan más que otros o como las contraseñas son escritas, solo nos denota la probabilidad de obtener cierto dígito en n posición.

Implicación para el siguiente paso

Ahora sigue hacer más análisis exploratorio para ver como podemos acomodar las demás posiciones a la ley de Benford o algo por el estilo.

————- FICHA 8 —————

Nivel descriptivo (¿qué encontraron?)

Titular

Es súper probable pasar de una letra a otra en una contraseña.

Nombre del hallazgo/resultado

Biogramas de transición entre tipos de caracteres.

Resumen en una oración

Según la matriz, es muy probable pasar de una letra a otra, seguido de dígito a dígito.

Método o análisis que lo produjo

Se realizó un conteo y se calculó la probabilidad para cada transición con la muestra total. Se tienen 4x4 contadores que van contando las probabilidades.

Evidencia




Figure 1.8: Biograma de transición entre tipos

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

La matriz anterior nos permite comprender mejor como se van construyendo las contraseñas de parte de los usuarios. Vemos como es sumamente probable pasar de una letra

a otra, también, es muy probable pasar de un dígito a otro, entonces podemos concluir un comportamiento de orden de parte de las contraseñas, donde por ejemplo es sumamente raro saltar de un caracter especial a otro. Esto nos puede ayudar a entender y modelar mejor la aleatoriedad de las contraseñas para así contestar la pregunta de investigación.

Contraste con la literatura

Este hallazgo es propio y característico de la base de datos seleccionada, sin embargo, lo podemos asociar al concepto de entropía estudiado por Reaz(2024) el cual nos plantea que la entropía es como una medida del orden, lo cual vemos que se puede entender con esta matriz ya que se tiende a seguir un orden natural saltando entre el mismo tipo de caracteres.

Lo que NO explica este resultado

Este resultado no dice como se distribuyen las contraseñas, este resultado únicamente nos explica un poco el orden que se sigue al momento de crearlas para nosotros poder entender un poco mejor el concepto de entropía aplicado acá.

Implicación para el siguiente paso

Ahora nos toca medir mejor la entropía con métodos más rigurosos.

Ordenamiento de los elementos de reporte

Elementos primarios y secundarios

Primarios	Secundarios
1. Entropía de Shannon como medida de aleatoriedad	1. Ley de Zipf en contraseñas (Wang et al., 2017)
2. Distribución de dígitos por posición (tokenización CL100K)	2. Modelos de Markov para contraseñas (Ma et al., 2014)
3. Desviación respecto a la Ley de Benford (posiciones 1 y 2)	3. Redes neuronales para predicción de contraseñas (Olsen, 2018)
4. Estructura de máscaras y su relación con entropía (KW)	4. Análisis fallido: Benford directo sobre dígitos sin tokenizar
5. Longitud como predictor de entropía (Spearman)	5. Bigramas de transición entre tipos de caracteres
6. Patrones posicionales: consonante-vocal, dígitos al final	

Table 1.2: Elementos de reporte

Ordenamiento por secciones

Sección	Temas a tratar
Introducción	1. Predecibilidad de contraseñas humanas — Keszthelyi (Primario) 2. Entropía como medida de seguridad — Bonneau (Primario) 3. Ley de Benford y datos naturales — Caputi (Primario) 4. Ley de Zipf en contraseñas — Wang et al. (Secundario)
Metodología	1. Dataset RockYou y preprocesamiento (Primario) 2. Tokenización CL100K y extracción de dígitos (Primario) 3. Prueba KS contra Benford por posición (Primario) 4. Máscaras de contraseña y entropía de Shannon (Primario) 5. Kruskal-Wallis por longitud y tipo dominante (Primario) 6. Correlación de Spearman longitud-entropía (Primario) 7. Modelos de Markov como contexto comparativo (Secundario)
Resultados	1. Posiciones 1 y 2 se desvían de Benford; posiciones 3+ coinciden por uniformidad (Primario) 2. Distribución uniforme de dígitos desde posición 3 (Primario) 3. Tipo de máscara determina nivel de entropía — KW (Primario) 4. Longitud predice entropía — Spearman (Primario) 5. Patrón consonante-vocal y dígitos al final (Primario) 6. Bigramas de transición entre tipos (Secundario)

Table 1.4: Orden de escritura del reporte

La imagen que cuenta la historia

El gráfico elegido como la visualización más poderosa del proyecto es el de KS y Benford para la posición 1 de las contraseñas tokenizadas con CL100K. Se eligió este gráfico porque es el que mejor ilustra la tensión central del proyecto: los usuarios muestran una tendencia decreciente en la elección de dígitos en las primeras posiciones, similar a Benford, pero sin cumplir las proporciones exactas que la ley predice. En la posición 1 se observa que las barras empíricas tienen la forma decreciente característica de Benford, donde el dígito 1 es el más frecuente y la frecuencia va bajando, pero las alturas no coinciden con suficiente precisión como para pasar el test KS. Esto significa que los humanos tienen preferencias propias al elegir dígitos que se acercan pero no llegan a seguir una distribución natural como Benford, lo cual es evidencia de una predictibilidad parcial pero real. A diferencia de las posiciones 3 y 4, donde tanto la distribución empírica como Benford son casi completamente planas y por eso coinciden, la posición 1 muestra una estructura más rica e informativamente más valiosa. Alguien que viera únicamente esta imagen podría concluir que las contraseñas no son completamente aleatorias en sus primeras posiciones, y que existe una tendencia sistemática en cómo los usuarios eligen sus dígitos iniciales. Esa tendencia, aunque no perfectamente benfordiana, es suficiente para distinguir contraseñas humanas de secuencias verdaderamente aleatorias. Desde la Bitácora #2, la comprensión del problema ha evolucionado considerablemente: antes se analizaban los dígitos sin tokenizar, pero ahora con la tokenización CL100K se puede separar el comportamiento por posición y ver que el patrón humano se concentra en las primeras posiciones. A partir de la posición 3, la distribución empírica se vuelve casi uniforme y coincide con lo que Benford predice para esas posiciones, simplemente porque ambas convergen hacia la uniformidad. Este contraste entre posiciones tempranas y tardías es lo que hace al gráfico de posición 1 narrativamente indispensable: es donde la huella humana es más visible y más explotable. El hecho de que el patrón se diluya progresivamente a lo largo de la contraseña abre preguntas importantes sobre en qué posiciones concentrar el análisis para maximizar la detección de predictibilidad. Si este gráfico fuera la portada del artículo, contaría la historia de que las contraseñas humanas llevan una firma estadística en sus primeras posiciones, imperfecta pero detectable, que las distingue de una secuencia verdaderamente aleatoria. Esa firma, identificada mediante tokenización CL100K y la prueba KS, es el aporte central de este proyecto al análisis de seguridad de contraseñas.

Arco narrativo del proyecto

El modelo reveló que las contraseñas del dataset RockYou siguen patrones predecibles en la distribución de sus caracteres por posición y que su nivel de entropía depende tanto de esa distribución como de la longitud de la contraseña, lo que significa que los usuarios no eligen contraseñas de forma aleatoria y que la tokenización CL100K es una herramienta efectiva para traducir esos patrones del lenguaje escrito hacia una representación numérica.

Parte de escritura

Parte de reflexión

% Revisen y actualicen: objetivos, pregunta de investigación y demás elementos % de la UVE con toda la información recopilada hasta ahora.

Diario de aprendizaje

- Conocemos el proceso de tokenización del lenguaje natural hacia vectores numéricos; estos tienen un mayor peso cuando aportan más información al modelo.
- Aprendimos que los primeros dígitos de las contraseñas no siguen la distribución de Benford debido a patrones internos como fechas y otros.
- La búsqueda de literatura nos enseñó que no siempre es fácil comprender la información en ellos, y a veces resulta difícil reducirla a un resumen.

Registro del uso de IA

% Documenten cada uso de IA con el formato de la Bitácora #1: % Herramienta / Prompt / Respuesta de la IA / Evaluación / Modificaciones / Aprendizaje

Herramienta:

Prompt:

Respuesta de la IA:

Evaluación:

Modificaciones:

Aprendizaje: