



UNIVERSIDAD DE COSTA RICA

Escuela de Matemáticas

Estadística Actuarial I (CA0303)

Bitácora #4

Prof: Maikol Solís

Estudiantes:

Anthony Flores Rojas (C32975)

Andrey González Bastos (C33329)

Randal Picado Bermúdez (C36024)

Leonardo Vega Aragón (C38313)

Fecha: 22/06/2026

Contenido

1. Parte de planificación	1
2. Parte de escritura	10
2.1. Escribir, escribir, escribir	10
2.2. Conclusión	20
2.3. Introducción	21
2.4. Resumen	22
2.5. Ordenamiento final	24
2.5.1. Título	24
2.5.2. Resumen	24
2.5.3. Palabras clave	24
2.5.4. Introducción	24
2.5.5. Metodología	25
2.5.6. Resultados	29
2.5.7. Conclusiones	33
2.5.8. Agradecimientos	33
3. Registro de uso de IA	34

Capítulo 1

Parte de planificación

———— FICHA 1 ————

Nivel descriptivo (¿qué encontraron?)

Titular

Los tipos de carácter más frecuentes individualmente tienden a co-ocurrir más con los demás, pero esta relación no es estadísticamente significativa dado el tamaño muestral reducido.

Nombre del hallazgo/resultado

Spearman entre presencia individual y co-ocurrencia media no rechaza H ($\rho = 0.80$, $p = 0.20$).


Resumen en una oración

Aunque L y D, los tipos más presentes individualmente, también presentan la mayor co-ocurrencia media con los demás tipos, la correlación de Spearman no alcanza significancia estadística con solo 4 puntos de datos.

Método o análisis que lo produjo

Para cada uno de los cuatro tipos de carácter (L, U, D, S) se calculó su presencia individual ponderada por frecuencia de contraseña (porcentaje de contraseñas que contienen al menos una vez ese tipo) y su co-ocurrencia media con los otros tres tipos usando el índice de Jaccard ponderado. Se aplicó la correlación de Spearman entre ambas variables sobre los 4 puntos resultantes, uno por tipo.

Evidencia



Spearman: presencia individual vs co-ocurrencia media por tipo de carácter

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

L (80.5 % de presencia) y D (54.0 %) se ubican en el extremo superior del gráfico, mientras U y S se agrupan en el inferior con valores menores al 10 %. Esto sugiere que los tipos dominantes no solo son los más usados individualmente sino también los que más co-ocurren con otros, lo cual apunta a que la complejidad de las contraseñas se concentra en muy pocos tipos y no se distribuye de forma balanceada.

Contraste con la literatura

Esto tiene relación directa con nuestra literatura de pruebas no paramétricas.

Lo que NO explica este resultado

Este resultado no permite concluir estadísticamente que la relación existe en la población, dado que $n=4$ es insuficiente para que la prueba de Spearman tenga poder estadístico real. El p-valor de 0.20 no implica que no haya relación, sino que con 4 puntos es prácticamente imposible rechazar H_0 aunque el patrón sea visualmente fuerte.

Implicación para el siguiente paso

El hallazgo orienta a examinar con mayor detalle la dominancia del binomio L-D como par, que es exactamente lo que se analiza en la segunda correlación.

———— FICHA 2 ————

Nivel descriptivo (¿qué encontraron?)

Titular

El par L-D es un outlier estructural en la co-ocurrencia entre tipos: su Jaccard ponderado (36.75 %) es más de seis veces mayor que el del resto de combinaciones.

Nombre del hallazgo/resultado

Spearman entre presencia media del par y Jaccard ponderado no rechaza H_0 ($\rho = 0.14$, $p = 0.79$), pero el par L-D rompe visualmente el patrón del resto.


Resumen en una oración

No existe una relación monótona general entre cuán presentes son los tipos de un par y cuánto co-ocurren, porque el par L-D domina de forma tan pronunciada que el resto de combinaciones se comporta de manera homogénea e independiente de su presencia media.

Método o análisis que lo produjo

Se calcularon los seis pares posibles entre los cuatro tipos ($C(4,2)$): L-U, L-D, L-S, U-D, U-S, D-S). Para cada par se obtuvo su Jaccard ponderado (frecuencia de contraseñas que contienen ambos tipos dividida entre las que contienen al menos uno, ponderada por frecuencia) y la presencia media del par (promedio de las presencias individuales de los dos tipos). Se aplicó Spearman sobre estos 6 puntos.

Evidencia



Spearman: presencia media del par vs Jaccard ponderado para los 6 pares posibles

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

El Jaccard de L-D (36.75 %) frente al segundo más alto, U-D (5.84 %), revela que la combinación minúsculas más dígitos no es simplemente la más común sino que es cualitativamente distinta al resto. Esto indica que el patrón estructural dominante en RockYou es letras seguidas de números, lo que implica que las contraseñas tienen una predictibilidad estructural alta y no aprovechan la diversidad de los cuatro tipos disponibles.

Contraste con la literatura

Esto tiene relación directa con nuestra literatura sobre pruebas no paramétricas.

Lo que NO explica este resultado

El rho bajo (0.14) y el p-valor alto (0.79) no significan que el Jaccard sea independiente de la presencia en general, sino que la relación no es monótona: U-S tiene Jaccard relativamente alto (5.46 %) pese a que ambos tipos son poco frecuentes individualmente, lo que rompe el patrón esperado. Este resultado no permite generalizar más allá de los cuatro tipos analizados.

Implicación para el siguiente paso

La dominancia del par L-D justifica analizar con mayor énfasis los patrones de transición entre estos dos tipos específicamente, en particular si las contraseñas siguen la estructura bloque-L seguido de bloque-D.

————- FICHA 3 —————

Nivel descriptivo (¿qué encontraron?)

Titular

La matriz de transiciones revela una fuerte simetría estructural en RockYou.

Nombre del hallazgo/resultado

Cantidad de transiciones entre origen y destino (en tipos de datos).


Resumen en una oración

La mayor cantidad de transiciones es de letra a letra.

Método o análisis que lo produjo

Un simple conteo con la matriz de transición.

Evidencia



Conteos observados en transición entre tipos de datos

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre cómo se transicionan los tipos de datos en las contraseñas, descubriendo que hay muchas más transiciones entre letras que de dígito a dígito, esto nos dice que es muy probable pasar de una letra a otra.

Contraste con la literatura

Esto tiene relación directa con la literatura de (Keszthelyi,2013), pues se relaciona con la creación de buenas contraseñas con facilidad de recordación y que sean simples que es la idea básica del autor, con este gráfico, vemos como la gente sigue patrones pasando casi siempre de letra a letra o de dígito a dígito.

Lo que NO explica este resultado

Este resultado claramente NO explica que solo se pasa de letra a letra o de dígito a dígito, solo nos explica un conteo por encima de cuantas veces sucede, no nos dice que solo pasa de esa manera.

Implicación para el siguiente paso

Nos toca averiguar si esto apoya la entropía.

————- FICHA 4 —————

Nivel descriptivo (¿qué encontraron?)

Titular

No hay independencia entre el origen y el destino.

Nombre del hallazgo/resultado

Prueba Chi-Cuadrado sobre la matriz de transiciones.

Resumen en una oración


La prueba chi cuadrado de independencia sobre la matriz de transiciones rechaza la hipótesis nula de independencia entre el tipo origen y destino.

Método o análisis que lo produjo

Se realizó una prueba chi-cuadrado a la matriz de transiciones.

Evidencia

Chi-cuadrado de independencia — transiciones entre tipos
RECHAZA H_0 $p = 0.000000$



Prueba Chi-Cuadrado sobre la matriz de transición

Nivel analítico (¿qué significa?)

Conexión con la pregunta de investigación

Este hallazgo, nos ayuda a contestar nuestra pregunta pues vamos construyendo conocimiento sobre la independencia de los datos, se descubrió que dada la prueba chi-cuadrado, se evita la alternancia entre los tipos de datos.

Contraste con la literatura

Esto tiene relación directa con nuestra ficha de literatura (Keszthelyi, 2013), pues también refuerza que el ser humano tiende a elegir patrones reconocibles y memorizables en el tiempo en lugar de contraseñas aleatorias y complicadas, sustentando la hipótesis de la entropía baja.

Lo que NO explica este resultado

Este resultado claramente NO dice que no se pueda pasar de un tipo de caracter a otro, solo nos dice que se descartó la hipótesis nula de que sean independientes.

Implicación para el siguiente paso

Nos toca averiguar si esto afecta la entropía de las contraseñas, lo cual sospechamos que más bien apoya que la entropía sea menor.

Capítulo 2

Parte de escritura

2.1. Escribir, escribir, escribir

El presente proyecto fue desarrollado con el fin de analizar si las contraseñas de la base de datos *rockyou.txt* seguían la ley de Benford para los primeros 16 dígitos mediante alguna transformación de los datos. Sin embargo, para continuar con el proyecto, fue necesario abarcar varias definiciones, que serán presentadas a continuación.

1. **Ley de Benford:** Según Sarkar (2025), la Ley de Benford establece que los primeros números que se encuentran en una base de datos dada varían su cantidad de apariciones según los dígitos que los conforman. En síntesis, el número uno suele aparecer más frecuentemente, seguido por el dos, luego por el tres y así sucesivamente. Sin embargo, Marrero (2019) expone la limitación de que esta ley solo es válida cuando la muestra de números es variada, abarca diversos órdenes de magnitud, se encuentra libre de condicionamientos y sesgos, y tiene la característica de no ser totalmente aleatoria. Es por esto último que el primer autor mencionó el hecho de que dicha ley permite identificar patrones y anomalías en bases de datos “naturales”, lo que se puede aplicar al momento de detectar algunos tipos de fraude.
2. **Entropía:** Dada una variable aleatoria continua X con una función de densidad p , se define la Entropía de X como:

$$h(X) = \int_{-\infty}^{\infty} p(x) \log(p(x)) dx$$

Análogamente, para una variable aleatoria discreta X con función de masa p , su entropía corresponde a:

$$H(X) = \sum_{i=1}^n p(x_i) \log(p(x_i))$$

Conceptualmente, la entropía mide el nivel de aleatoriedad, desorden o variabilidad en un sistema cerrado. Así, cuanto más grande sea la magnitud asociada a la entropía de una variable aleatoria, habrá más incertidumbre al momento de hacer una predicción con respecto al comportamiento de dicha variable. (Reaz y Wunder, 2024). Los autores

Lehoucq, Mayer y Tucker hacen la distinción de que la entropía se utiliza de manera diferente en el contexto de teoría de la información (donde se utilizan variables aleatorias) que en el contexto de la estadística (donde se trabaja con muestras). Así, para este proyecto se hará uso de la entropía en los dos contextos mencionados anteriormente.

Posteriormente, para el aspecto metodológico del proyecto, se hizo uso de varias herramientas (las cuales serán explicadas con detalle en los siguientes párrafos), como lo fueron:

- Tokenización
- Test de Kolmogorov-Smirnov
- Prueba de Kruskal-Wallis

Al principio de la elaboración del proyecto, se quiso investigar acerca de los patrones que siguen las contraseñas a nivel general. Uno de los primeros trabajos que llamaron la atención del grupo fue el trabajo *User password repetitive patterns analysis and visualization*, el cual estudiaba acerca de si los usuarios reutilizan sistemáticamente subcadenas al crear contraseñas largas y cómo estos patrones de repetición debilitan las políticas actuales de seguridad basadas en longitud y complejidad. Se formalizaron varios tipos de patrones repetitivos dentro de una misma contraseña (caracteres individuales, pares y subcadenas de tres a diez caracteres, en orden unidireccional y bidireccional) y se diseñaron algoritmos en tiempo polinómico para detectarlos eficientemente sobre grandes conjuntos de datos filtrados de fugas reales como RockYou. Además, se implementó una herramienta web ligera, basada en D3, con cuatro vistas de visualización: gráficos de frecuencia de caracteres (CFC), mapas de calor de repeticiones cortas (SRH), coordenadas paralelas para repeticiones largas (LRPC) y nubes de palabras de subcadenas repetidas (RWC), que permiten a administradores explorar interactivamente repeticiones y filtrar por longitud, tipo de carácter y dirección. Los estudios de caso muestran que las contraseñas de los usuarios exhiben fuertemente repeticiones de caracteres del mismo tipo (dígitos, minúsculas o mayúsculas), que muchas contraseñas largas se construyen repitiendo subcadenas cortas significativas (p. ej. “love”, “haha”, “1212”) o patrones bidireccionales, y que estas estrategias de memorización hacen que exigir contraseñas más largas no garantice mayor seguridad, proporcionando solo una ilusión de robustez.

Luego, se analizó el trabajo *About Passwords*, que complementaba en gran medida lo visto en el párrafo anterior, pues analizaba críticamente varias creencias comunes sobre la seguridad de las contraseñas y sostiene, con argumentos combinatorios y evidencia empírica, que la longitud es un factor mucho más importante que la mera mezcla de mayúsculas, minúsculas, dígitos y símbolos. A partir de filtraciones reales como Hotmail, RockYou, Yahoo! y otros casos masivos, el autor mostró que muchos usuarios siguen eligiendo contraseñas triviales, reutilizadas o basadas en palabras comunes, información personal y patrones previsibles, lo que vuelve muy eficaces los ataques por diccionario, las variantes avanzadas con sustituciones tipo *leet* y los ataques de fuerza bruta fuera de línea. Seguidamente, se discutieron distintos métodos populares de generación de contraseñas, como combinaciones aparentemente aleatorias de caracteres, iniciales de frases, generadores deterministas por sitio y concatenaciones mnemotécnicas de palabras, subrayando que cualquier método conocido o estructuralmente típico puede facilitar el trabajo del atacante si este dispone de información previa o de listas

de patrones frecuentes. Luego se presentó un análisis estructural de más de 14 millones de contraseñas únicas de RockYou, donde se observa que predominan las minúsculas, los dígitos y las formas “palabra + números”, mientras que el uso de mayúsculas y caracteres especiales es relativamente escaso; además, se estima que una estrategia de cracking bien diseñada podría romper una fracción considerable de esas contraseñas en muy poco tiempo. Finalmente, el texto propuso recomendaciones prácticas para construir contraseñas robustas y memorables, por ejemplo mediante frases largas, combinaciones personales no previsibles o palabras inventadas, y concluye que la seguridad real depende tanto de buenos hábitos del usuario como de funciones hash fuertes, políticas organizacionales adecuadas y educación temprana sobre autenticación y riesgos informáticos.

Este texto sugiere fuertemente que el largo de una contraseña influye de manera directamente proporcional en su seguridad, y uno de sus argumentos es que entre más caracteres tiene una contraseña entonces habrían más combinaciones que deberían ser probadas al momento de querer vulnerarla (lo que haría poco probable que un intruso obtenga la respuesta en poco tiempo). Sin embargo, esta posición es contraria a la que ofrecen los autores de *User password repetitive patterns analysis and visualization*, pues estos últimos dejaron claro que aumentar la longitud de una contraseña no necesariamente implica un aumento en la seguridad, pues los humanos tienden a repetir patrones al momento de hacer una secuencia extensa de caracteres.

Para complementar el análisis que el texto anterior hizo del cambio que experimenta la seguridad de una contraseña al cambiar su longitud, se analizó el texto *The science of guessing: analyzing an anonymized corpus of 70 million passwords*, donde el autor presenta un análisis estadístico riguroso del mayor corpus anonimizado de contraseñas estudiado hasta ese momento, correspondiente a casi 70 millones de usuarios de Yahoo!, y lo utiliza para replantear la forma en que se mide la dificultad de adivinación de contraseñas elegidas por humanos. Se inicia criticando métricas tradicionales como la entropía de Shannon y la *guessing entropy*, por no ser apropiadas ni estimables con muestras realistas, y en su lugar introduce métricas de adivinación parcial como λ_β , μ_α y especialmente la nueva α -*guesswork*, pensadas para modelar ataques prácticos con distinta tasa deseada de éxito. Seguidamente, el trabajo propone un mecanismo de recolección que preserva la privacidad, basado en histogramas de contraseñas cifradas con un nonce secreto destruido antes del análisis, lo que permite estudiar subpoblaciones demográficas y de uso sin exponer contraseñas individuales ni facilitar ataques fuera de línea. Luego se aborda el problema del tamaño muestral, mostrando que incluso con decenas de millones de observaciones muchas métricas siguen subestimándose por la gran masa de contraseñas raras, y se adapta un modelo paramétrico de tipo Sichel (mezcla Poisson-generalized inverse Gaussian) para extrapolar la cola de la distribución y estimar con mayor estabilidad curvas de adivinación y factores de trabajo efectivos. Finalmente, al comparar numerosos subgrupos por edad, género, idioma, historial de cambios, uso de servicios y otros atributos, se concluye que la seguridad de las contraseñas varía sorprendentemente poco entre poblaciones: en general ofrecen menos de 10 bits de seguridad frente a ataques *online* y alrededor de 20 bits frente a ataques óptimos *offline*, lo que sugiere que incluso usuarios aparentemente más motivados siguen eligiendo contraseñas débilmente distribuidas y que los diccionarios globales funcionan casi tan bien como los específicos para cada grupo.

Una vez que se estudió la psicología que suelen aplicar las personas al momento de formar una contraseña, era momento de estudiar si realmente existe alguna manera de predecir

las contraseñas. Esto debido a que, de ser posible, significaría que las contraseñas realmente contiene patrones que se podría aprovechar para estudiar si, en el fondo, las contraseñas cumplen con la Ley de Benford. Uno de los primeros textos que se analizaron para estudiar esto fue *A study of Probabilistic Password Models* el cual realiza un estudio empírico amplio de modelos probabilísticos para contraseñas utilizando seis bases de datos reales con cerca de 60 millones de contraseñas, y propuso como alternativa metodológica a las curvas clásicas de número de intentos los *probability-threshold graphs*, que relacionan umbrales de probabilidad con el porcentaje de contraseñas cubiertas y permiten evaluar conjuntos completos con mucho menor costo computacional. Inició definiendo formalmente un modelo probabilístico de contraseñas como una función $p(s)$ sobre el conjunto de cadenas permitidas, y seguidamente se introdujeron tres métricas de evaluación principales: las *guess-number graphs*, las nuevas curvas de umbral de probabilidad y el *Average Negative Log-Likelihood* (ANLL), interpretado como el área a la izquierda de la curva de probabilidad y estrechamente relacionado con la perplejidad empírica. Luego se estudió un amplio espacio de diseño de modelos, distinguiendo entre modelos de Markov de cadena completa (*whole-string*) y modelos basados en plantillas (*template-based*), junto con decisiones de normalización, orden del modelo, suavizado, tratamiento de escasez de datos, agrupamiento de símbolos y esquemas de *backoff*, además de algoritmos de generación eficiente de conjeturas ordenadas por probabilidad. Finalmente, los resultados experimentales mostraron que los modelos de Markov de cadena completa bien contruidos, especialmente cuando combinan normalización con símbolo final y *backoff*, superan de forma consistente al modelo PCFGW, en particular más allá del primer millón de intentos, lo que lleva a concluir que estos enfoques ofrecen una representación más eficaz del comportamiento real de elección de contraseñas y una base más sólida para comparar fortaleza y capacidad de cracking.

El texto anterior se relacionaba en gran medida con el texto *A Machine Learning Approach to Predicting Passwords*, el cual exploraba el uso de modelos de aprendizaje automático para predecir secuencias de contraseñas humanas a partir de filtraciones públicas y compararlos con técnicas estándar de cracking basadas en hashcat. Tras repasar ataques de diccionario, diccionario+reglas, diccionarios masivos y fuerza bruta sobre contraseñas MD5 de XSplit, se mostró que los diccionarios ordenados por frecuencia (rockyou.txt) son muy eficientes en las primeras conjeturas, que combinar reglas casi duplica la tasa de éxito a costa de muchos más intentos, que listas enormes cubren casi todos los hashes y que la fuerza bruta es exhaustiva pero extremadamente ineficiente. El trabajo propuso luego una red neuronal con capas convolucionales 1D y densas, entrenada en 150 000 contraseñas de OwnedCore, para estimar la probabilidad del siguiente carácter dada la secuencia previa, logrando una exactitud de validación de alrededor de 41 % en predicción de carácter y permitiendo asignar a cada contraseña una probabilidad interpretable como medida de fortaleza (contraseñas comunes como “oblivion” o “asdf1234” reciben alta probabilidad; cadenas aleatorias como “xy2zx9nm”, probabilidades ínfimas). Mediante muestreo sobre la distribución de salida, la red genera listas de contraseñas plausibles que, usadas como diccionario en hashcat, logran romper alrededor de 1 % de 100 000 hashes con menos de un millón de conjeturas, cifra razonable dado que el diccionario contiene menos de un millón de contraseñas únicas, aunque claramente por debajo del rendimiento de rockyou.txt; aplicar reglas sobre estas contraseñas generadas mejora los resultados pero sigue sin alcanzar a los diccionarios artesanales. El autor concluyó que las redes neuronales son útiles para modelar el comportamiento de elección de contraseñas,

generar diccionarios especializados y ordenar listas por probabilidad (especialmente relevante con hashes costosos como bcrypt), pero que, en su implementación actual, la generación es lenta, el modelo aún está por detrás de las listas tradicionales en cracking y sería necesario investigar arquitecturas avanzadas (GAN, LSTM) y mejores representaciones para hacerlo competitivo.

Por un lado, el autor de *A study of Probabilistic Password Models* realizó su investigación de la fortaleza de las contraseñas mediante conceptos del área de probabilidad. Por el otro lado, el autor del artículo *A Machine Learning Approach to Predicting Passwords* utiliza un modelo con redes neuronales para estudiar la misma cualidad, sin hacer uso (aparentemente) de conceptos probabilísticos complejos.


Siguiendo en esta línea de modelos relacionados al estudio de la predictibilidad de las contraseñas, se estudió el trabajo *Zipf's Law in Passwords*, donde el autor analiza empíricamente la distribución de contraseñas de usuarios a gran escala y muestra que se ajusta notablemente bien a modelos tipo ley de Zipf. A partir de 14 conjuntos de datos reales con 113,3 millones de contraseñas, los autores proponen dos modelos Zipf-like: PDF-Zipf, que describe la frecuencia de las contraseñas populares y alcanza coeficientes de determinación superiores a 0,97, y CDF-Zipf, que ajusta prácticamente todo el rango de la distribución con desviaciones máximas entre la CDF empírica y la teórica de 0,49 % a 4,59 % (media\$ \$1,85 %). Sobre esta base, introducen una nueva métrica de fuerza de conjuntos de contraseñas derivada de los parámetros Zipf, y muestran mediante experimentos que dicha métrica es estable y aplicable a distintos sitios y políticas, permitiendo comparar con rigor qué tan “seguro” es el universo de contraseñas de un servicio independientemente del medidor ad hoc que se use en la interfaz. El trabajo discute además implicaciones para el diseño y evaluación de políticas de creación de contraseñas, subrayando que comprender la distribución subyacente (y su carácter Zipfiano) es clave para resolver las inconsistencias entre medidores de fuerza y para prever el impacto de reglas más estrictas sobre la seguridad y la usabilidad.

Lo anterior fueron las investigaciones que propiamente estudiaban las contraseñas como objetos centrales. Dichos trabajos mostraron que es posible notar patrones en las contraseñas, por lo que era plausible pensar que la ley de Benford se cumpliría de alguna manera en las contraseñas.

Después de un proceso largo de descarte de ideas, el profesor Maikol Solís Chacón sugirió la idea de tokenizar las contraseñas, para construir números asociados a cada contraseña (usando los pesos de los tokens). Esto llevó al presente grupo a investigar acerca del proceso de tokenización y algunas propiedades relacionadas. Así, se analizó el paper *Tokenization counts: the impact of tokenization on arithmetic in frontier LLMs*, en el cual se menciona como la tokenización es un proceso de segmentación de una secuencia de bytes de entrada en tokens discretos. Los autores explicaron que este proceso se divide en dos fases; una fase de entrenamiento donde se aprende un vocabulario de tokens y estadísticas a partir de un corpus de texto, y una fase de segmentación, en la cual una función usa ese vocabulario para mapear secuencias de bytes a tokens. Luego, el paper abarca el cómo la elección del esquema de tokenización afecta el razonamiento numérico de los modelos de lenguaje de frontera, siendo cl100k el esquema usado por GPT-3.5 y GPT-4. Los autores observaron que, a diferencia de otros modelos que optan por tokenización dígito a dígito, cl100k asigna tokens individuales a números de 1, 2 y 3 dígitos, lo que introduce patrones sistemáticos en cómo el modelo percibe y procesa los números. Para evaluar el efecto de estas diferencias, los autores

diseñaron tareas aritméticas controladas y comparan el desempeño de distintos modelos bajo diferentes esquemas de tokenización, encontrando que la tokenización de derecha a izquierda, forzada mediante separadores de comas, mejora el rendimiento aritmético de GPT-3.5 y GPT-4. Sus resultados muestran que la tokenización no es un paso neutral del pipeline, sino que puede ser fuente de sesgos útiles o perjudiciales dependiendo del dominio de aplicación, y que cl100k en particular produce representaciones numéricas con una estructura interna predecible y analizable.


A partir de ahí, fue momento de usar las pruebas no paramétricas mencionadas al inicio de esta sección. Los primeros resultados se obtuvieron mediante el uso del test Kolmogórov-Smirnov (KS). Dicho test, según Yakir (2013), permite calcular que tanto error existe entre la función de distribución acumulada basada en lo que muestran las observaciones y la distribución teórica. De esta manera, se evaluó si la distribución empírica de los dígitos en la primera posición de las contraseñas tokenizadas se ajusta a la Ley de Benford. Los resultados indican que, aunque visualmente la distribución guarda similitud con la teórica de Benford —con mayor frecuencia del dígito 1—, el test KS rechaza H_0 ($D = 0.0985$), lo que significa que la diferencia es estadísticamente significativa y no puede descartarse como aleatoria, como se muestra en la siguiente figura.



KS y Benford para posición 1 con contraseñas tokenizadas

Esto implica que las contraseñas no son completamente aleatorias en su primera posición: siguen un patrón parcialmente compatible con Benford, pero no con la rigurosidad formal requerida por el test. Este resultado se apoya en la literatura de Caputi (2019) sobre la Ley de Benford y en Chandy et al. (2025) sobre el test KS, y motiva la exploración de las posiciones subsiguientes para determinar si el ajuste mejora a medida que avanza la posición.


En sintonía con anterior, el segundo resultado que se obtuvo (relacionado a los dígitos en la segunda posición), fue que con la misma metodología de tokenización cl100k y el test KS, se llegó a que, al igual que en la posición 1, la distribución empírica muestra una forma visualmente similar a la Ley de Benford, pero el test KS rechaza H_0 ($D = 0.0108$), indicando que el ajuste no es suficiente para confirmar estadísticamente el seguimiento de dicha ley, como se muestra en la siguiente figura.



KS y Benford para posición 2 con contraseñas tokenizadas

La diferencia con la posición 1 es que el estadístico D es mucho menor, lo que sugiere un mejor ajuste relativo, aunque aún insuficiente. Este resultado consolida la hipótesis de que las primeras posiciones de las contraseñas son las que más se desvían del comportamiento esperado bajo Benford, lo que refuerza que las claves no son completamente aleatorias. Constituye un eslabón clave en la cadena de análisis posicional, orientando la investigación hacia la posición 3 y siguientes para buscar un ajuste formal.

Al realizar un proceso análogo a los anteriores para el tercer dígito se obtuvo resultados diferentes, y fue que el test no rechazó H_0 ($D = 0.0003$), lo que indica que la distribución empírica de los dígitos en esta posición sigue la Ley de Benford de manera estadísticamente aceptable, como bien muestra la siguiente figura.




KS y Benford para posición 3 con contraseñas tokenizadas

Este es el primer punto de la cadena posicional en el que se confirma formalmente el ajuste a Benford, marcando una ruptura con el comportamiento de las posiciones 1 y 2. El hallazgo es significativo porque demuestra que no basta con la similitud visual para afirmar que una distribución sigue Benford; es imprescindible validarlo con pruebas formales como

el test KS. En consonancia con Caputi (2019) y Chandy et al. (2025), este resultado sienta la base para verificar si las posiciones 4 en adelante mantienen el mismo patrón, avanzando hacia una caracterización más completa de la aleatoriedad de las contraseñas.


Similar al caso anterior, el análisis de la cuarta posición de las contraseñas tokenizadas con cl100k confirma, nuevamente, que el test KS no rechaza H_0 ($D = 0.0003$), validando que la distribución de dígitos en esta posición se ajusta formalmente a la Ley de Benford. Esto último se puede mostrar en el gráfico siguiente.



KS y Benford para posición 4 con contraseñas tokenizadas


Este resultado es consistente con el hallazgo de la posición 3 y forma parte de un patrón más amplio: se determinó que a partir de la posición 3 en adelante, todas las posiciones siguen Benford de forma confirmada por KS, lo cual resulta inesperado dado que las posiciones 1 y 2 no lograron pasar el test. Esto revela que la naturaleza de los dígitos en posiciones iniciales es cualitativamente diferente a la de las posiciones intermedias y finales, y que no basta con la similitud visual para afirmar el seguimiento de una distribución: la validación formal es imprescindible. La discrepancia plantea la necesidad de explorar nuevas estrategias de tokenización que permitan extender el cumplimiento de Benford a todas las posiciones, en línea con Caputi (2019) y Chandy et al. (2025).

Luego, para el siguiente resultado se hizo uso de la prueba de Kruskal-Wallis. De acuerdo a Childs, Hindle y Warren (2021), esta prueba consiste en evaluar las diferencias entre dos (o más) muestras. Para lograr esto, las variables deben ser no nominales, las observaciones de cada grupo deben ser independientes y la distribución de las variables de cada grupo deben ser “similares”. Gracias a esta prueba se puede ver si existen diferencias significativas entre las distribuciones de varias muestras independientes. Usando lo anterior junto con el concepto de entropía, fue que se compararon las distribuciones de entropía de contraseñas clasificadas según el tipo de máscara: mixta, solo dígitos, solo letras, solo caracteres especiales y solo mayúsculas. El test rechazó H_0 con alta significancia ($H = 4,366,419,48, p \approx 0$), evidenciando que los cinco tipos de máscara producen distribuciones de entropía completamente distintas. El siguiente gráfico permite visualizar esto último.



Kruskal-Wallis - Entropía por tipo de máscara


Las contraseñas mixtas presentan la entropía más alta, mientras que las compuestas exclusivamente por caracteres especiales muestran los valores más bajos, contrariamente a lo que podría esperarse intuitivamente. Este agrupamiento es descriptivo y no inferencial, pues la variable de agrupación coincide con la variable de respuesta. El hallazgo enriquece la comprensión del desorden interno en las contraseñas y abre la puerta para determinar si estas diferencias en entropía pueden usarse para cuantificar aleatoriedad real en los pasos siguientes del análisis. Para complementar lo anterior, se hizo lo mismo pero únicamente con la longitud de la máscara. Los resultados de esto último fue que el test rechazó la hipótesis nula ($H = 14,084,456,87, p \approx 0$), confirmando que existen diferencias estadísticamente significativas entre grupos, como se muestra en el siguiente gráfico.



Kruskal-Wallis - Entropía por longitud de máscara

Visualmente, se aprecia una tendencia creciente y clara: a mayor longitud de la contraseña, mayor es la entropía media esperada, resultado intuitivo pero que era necesario comprobar formalmente. Esto refuerza la relación entre longitud y complejidad planteada por Reaz (2024), quien asocia la entropía a la dificultad de predicción de una contraseña. No obstante, este resultado no determina qué tan aleatorias son las contraseñas ni cuáles son seguras en términos absolutos; únicamente establece que la longitud es un predictor significativo de la entropía, lo que orienta los análisis inferenciales siguientes sobre aleatoriedad real.


Con el fin de complementar el proyecto mediante un análisis separado de lo narrado anteriormente, se realizó un análisis descriptivo de la distribución empírica de los dígitos (0–9) en las primeras seis posiciones de las contraseñas del dataset RockYou. Se observó que la posición 1 presenta una distribución notablemente sesgada, donde los dígitos más bajos aparecen con mayor frecuencia, lo cual es compatible con la Ley de Benford; la posición 2 también muestra variación, aunque menor. A partir de la posición 3, la distribución se vuelve prácticamente uniforme: todos los dígitos tienen probabilidades de aparición muy similares, independientemente de cuál se elija. Lo anterior se ve reflejado en la siguiente figura.



Distribución empírica de dígitos por posición

Esto sugiere que la primera posición es la más informativa para inferir patrones de creación de contraseñas, mientras que las posiciones posteriores son más predecibles en términos de uniformidad. El resultado no mide aleatoriedad directamente ni indica qué dígitos se usan en mayor volumen, pero construye una base empírica para contrastar con la Ley de Benford (Caputi, 2019) en análisis futuros.

Por último, se construyó una matriz de bigramas para analizar las probabilidades de transición entre tipos de caracteres (letras, dígitos, mayúsculas y caracteres especiales) en las contraseñas del dataset RockYou. Los resultados muestran que la transición de letra a letra es, con diferencia, la más frecuente (66.26 %), seguida de dígito a dígito (23.28 %), lo que evidencia un comportamiento ordenado en la construcción de contraseñas, como se puede ver en el siguiente gráfico.



Biograma de transición entre tipos

Esto permitió observar que las transiciones entre tipos distintos, como de carácter especial a otro carácter especial, son prácticamente inexistentes. Este patrón de orden se asocia al concepto de entropía planteado por Reaz (2024), donde la tendencia a permanecer dentro del mismo tipo de carácter refleja baja aleatoriedad entre tipos. Sin embargo, este resultado no describe la distribución general de contraseñas ni sus longitudes, sino únicamente el orden secuencial de sus caracteres, lo cual sienta una base para modelar mejor la entropía en pasos analíticos posteriores.

2.2. Conclusión

La presente investigación buscó responder en qué medida los patrones estructurales de las contraseñas de RockYou, su composición de caracteres, longitud y distribución de dígitos, determinan su entropía y evidencian que los usuarios no las eligen al azar. Esta pregunta sustituyó a la de la Bitácora #2, centrada solo en Benford, pues rockyou.txt carecía de metadatos de usuario. Acompañados del profesor Maikol Solís se reorientó el proyecto hacia un enfoque estructural y entrópico, sin abandonar Benford, sino aplicándolo sobre la suma de los vectores de tokenización cl100k de cada contraseña.

Se esperaba hallar sesgos sistemáticos detectables estadísticamente, y los resultados coincidieron solo en parte el test KS rechazó Benford en las posiciones 1 y 2 de esa suma tokenizada, pero no a partir de la posición 3, donde lo empírico y lo teórico convergen a la uniformidad; Kruskal-Wallis confirmó que máscara y longitud determinan la entropía de Shannon, y la matriz de bigramas mostró orden en la transición entre tipos de carácter. La metodología, combinando tokenización, pruebas no paramétricas y entropía, resolvió la pregunta desde varios ángulos, aunque no sin tropiezos: aplicar Benford directamente sobre los dígitos sin tokenizar fracasó por las fechas, las longitudes acotadas y los sesgos cognitivos de los usuarios, lo que obligó a replantear el enfoque hacia la suma tokenizada. Para trabajos futuros se recomienda probar otras normas o esquemas de tokenización que extiendan el ajuste a Benford a todas las posiciones y complementar los hallazgos con modelos de Markov o redes generativas.

Finalmente, este trabajo llena un vacío poco explorado: ni los estudios de Benford (Caputi, 2019; Nigrini, 2012) ni los de seguridad de contraseñas (Bonneau, 2012; Wang et al., 2017) habían combinado la tokenización de los modelos de lenguaje con pruebas estadísticas formales para medir la predecibilidad de contraseñas, lo que vuelve esta investigación un puente metodológico novedoso entre ambas tradiciones.

2.3. Introducción

El desarrollo de la tecnología y las bases de datos electrónicas han llegado a cambiar el juego de la información. Cada día se les confían más datos personales y sensibles a distintos softwares, ya sea la aplicación bancaria que se usa para realizar una transacción, o tal vez la aplicación de salud que se utilice para medir el estado de la misma, ambas usan datos sumamente sensibles y privados acerca de las personas, su estilo de vida, sus gustos, etc. Con este desarrollo inminente, las contraseñas han redefinido su importancia en el diario vivir de las personas, antes, cuando se pensaba en una contraseña, se pensaba en una caja fuerte de algún banco que se abría si se digitaba correctamente una sucesión de números que solo los altos mandos conocían, sin embargo, hoy en día, las contraseñas en los entornos digitales representan la seguridad de miles de millones de datos sensibles de millones de usuarios alrededor del mundo, que en caso de filtrarse o saberse, causaría un caos a nivel global. En la investigación, se usará el sonado caso de la filtración de RockYou, un hackeo que se realizó en el año 2009, del cual se obtuvo un dataset lo suficientemente robusto de contraseñas para poder realizar análisis y estudios posteriores. Sabiendo todo lo anterior, resulta fundamental y oportuno, estudiar a detalle la composición de las contraseñas y como los usuarios tienden a elegir estas mismas. Saber la naturaleza de las contraseñas resulta beneficioso para así poder detectar anomalías en bases de datos de contraseñas, así como posibles ataques a los sistemas informáticos de instituciones por ejemplo bancarias, que, de vulnerarse su información, puede causar un desastre económico a nivel nacional o global, dependiendo del alcance de la entidad. En específico, el tema de la presente investigación se trata de indagar sobre la aleatoriedad de las contraseñas, con la pregunta de investigación planteada por el grupo, ¿En qué medida los patrones estructurales de las contraseñas del dataset RockYou —su composición de caracteres, longitud y distribución de dígitos— determinan su nivel de entropía y evidencian que los usuarios no eligen contraseñas de forma aleatoria?, se pretende descubrir si los humanos

toman en cuenta la aleatoriedad o solo se basan en patrones muy conocidos y fáciles de recordar, vulnerando así su seguridad. Es bien conocido que el ser humano tiende a seguir patrones y escapa constantemente de la incertidumbre, es por esto que se puede llegar a medir la aleatoriedad de las contraseñas mediante el concepto de entropía. La entropía, entendida como una medida de aleatoriedad e impredecibilidad, permite cuantificar qué tan difícil es para un atacante adivinar o descifrar una contraseña determinada. Una contraseña con alta entropía implica una mayor cantidad de combinaciones posibles, lo que la hace significativamente más resistente ante ataques de fuerza bruta o de diccionario. Sin embargo, la pregunta que surge de forma natural es si los usuarios, al momento de crear sus contraseñas, realmente priorizan esta aleatoriedad, o si, por el contrario, siguen patrones predecibles dictados por la comodidad y la memoria. Para robustecer el análisis y darle un mayor rigor estadístico, la investigación incorpora herramientas que van más allá de la estadística descriptiva convencional. Por un lado, se aplicará la Ley de Benford, un principio matemático que establece la distribución esperada del primer dígito significativo en conjuntos de datos numéricos de origen natural o no manipulado. Por otro lado, se recurrirá a pruebas de bondad de ajuste como la prueba de Kolmogorov-Smirnov y la prueba de Kruskal-Wallis, las cuales permitirán evaluar si la distribución de las contraseñas sigue o se aleja significativamente de lo que cabría esperar bajo un modelo de aleatoriedad pura. La combinación de estos enfoques ofrece una perspectiva tanto descriptiva como inferencial, permitiendo no solo caracterizar los patrones presentes en el dataset, sino también validar estadísticamente la hipótesis de que los usuarios, lejos de actuar al azar, siguen tendencias estructurales profundamente arraigadas al momento de construir sus contraseñas. Adicionalmente, el análisis incorpora un enfoque proveniente del procesamiento de lenguaje natural mediante la tokenización cl100k, el esquema de codificación utilizado por modelos de lenguaje de gran escala como GPT-4. Este proceso consiste en descomponer las contraseñas en unidades mínimas de significado llamadas tokens, esto para poder simplificar el análisis de las contraseñas por la combinación de letras y caracteres.

2.4. Resumen

Antecedentes: Las contraseñas constituyen el principal mecanismo de autenticación en sistemas digitales; sin embargo, los usuarios suelen construirlas mediante patrones y estructuras predecibles que pueden reducir su seguridad. Esta investigación tuvo como objetivo determinar en qué medida la composición de caracteres, la longitud y la distribución de dígitos de las contraseñas del dataset RockYou influyen en su entropía y evidencian comportamientos no aleatorios.

Métodos: Se analizó el dataset RockYou mediante tokenización CL100K y el cálculo de una representación numérica asociada a cada contraseña. Posteriormente, se evaluó el ajuste a la Ley de Benford mediante la prueba de Kolmogorov-Smirnov (KS), tokenización se calculó la entropía de Shannon y se aplicó la prueba de Kruskal-Wallis para comparar niveles de entropía según el tipo de máscara y la longitud de las contraseñas. Además, se utilizó una prueba chi-cuadrado de independencia sobre una matriz de transiciones entre tipos de caracteres.

Resultados: La prueba KS mostró que las posiciones 1 y 2 se desvían significativamente de la distribución teórica de Benford ($D = 0.0985$ y $D = 0.0108$), a partir de la posición 3

no se rechazó el ajuste a dicha ley ($D = 0.0003$). Asimismo, la prueba de Kruskal-Wallis confirmó diferencias significativas en la entropía según el tipo de máscara ($H = 4\,366\,419.48$, $p = 0$) y la longitud de la contraseña ($H = 14\,084\,456.87$, $p = 0$). Finalmente, la prueba chi-cuadrado rechazó la hipótesis de independencia entre el tipo de carácter de origen y destino, evidenciando patrones estructurales en la construcción de contraseñas.

Conclusiones: Los resultados indican que las contraseñas humanas poseen una estructura estadística identificable y parcialmente predecible. La composición de caracteres, la longitud y los patrones de transición influyen significativamente en la entropía observada, evidenciando que los usuarios no seleccionan contraseñas de forma completamente aleatoria.

2.5. Ordenamiento final

2.5.1. Título

Análisis de la entropía y el cumplimiento de la Ley de Benford en contraseñas del dataset RockYou.txt mediante la tokenización de sus sub-cadenas.

2.5.2. Resumen

Antecedentes: Las contraseñas constituyen el principal mecanismo de autenticación en sistemas digitales; sin embargo, los usuarios suelen construirlas mediante patrones y estructuras predecibles que pueden reducir su seguridad. Esta investigación tuvo como objetivo determinar en qué medida la composición de caracteres, la longitud y la distribución de dígitos de las contraseñas del dataset RockYou influyen en su entropía y evidencian comportamientos no aleatorios.

Métodos: Se analizó el dataset RockYou mediante tokenización CL100K y el cálculo de una representación numérica asociada a cada contraseña. Posteriormente, se evaluó el ajuste a la Ley de Benford mediante la prueba de Kolmogorov-Smirnov (KS), tokenización se calculó la entropía de Shannon y se aplicó la prueba de Kruskal-Wallis para comparar niveles de entropía según el tipo de máscara y la longitud de las contraseñas. Además, se utilizó una prueba chi-cuadrado de independencia sobre una matriz de transiciones entre tipos de caracteres.

Resultados: La prueba KS mostró que las posiciones 1 y 2 se desvían significativamente de la distribución teórica de Benford ($D = 0.0985$ y $D = 0.0108$), a partir de la posición 3 no se rechazó el ajuste a dicha ley ($D = 0.0003$). Asimismo, la prueba de Kruskal-Wallis confirmó diferencias significativas en la entropía según el tipo de máscara ($H = 4\,366\,419.48$, $p = 0$) y la longitud de la contraseña ($H = 14\,084\,456.87$, $p = 0$). Finalmente, la prueba chi-cuadrado rechazó la hipótesis de independencia entre el tipo de carácter de origen y destino, evidenciando patrones estructurales en la construcción de contraseñas.

Conclusiones: Los resultados indican que las contraseñas humanas poseen una estructura estadística identificable y parcialmente predecible. La composición de caracteres, la longitud y los patrones de transición influyen significativamente en la entropía observada, evidenciando que los usuarios no seleccionan contraseñas de forma completamente aleatoria.

2.5.3. Palabras clave

RockYou.txt, Tokenización, Benford, Entropía, Kolmogorov-Smirnoff.

2.5.4. Introducción

El desarrollo de la tecnología y las bases de datos electrónicas han llegado a cambiar el juego de la información. Cada día se les confían más datos personales y sensibles a distintos softwares, ya sea la aplicación bancaria que se usa para realizar una transacción, o tal vez la aplicación de salud que se utilice para medir el estado de la misma, ambas usan datos sumamente sensibles y privados acerca de las personas, su estilo de vida, sus gustos, etc.

En la investigación, se usará el sonado caso de la filtración de RockYou, un hackeo que se realizó en el año 2009, del cual se obtuvo un dataset lo suficientemente robusto de contraseñas para poder realizar análisis y estudios posteriores. Sabiendo todo lo anterior, resulta fundamental y oportuno, estudiar a detalle la composición de las contraseñas y como los usuarios tienden a elegir estas mismas. Saber la naturaleza de las contraseñas resulta beneficioso para así poder detectar anomalías en bases de datos de contraseñas, así como posibles ataques a los sistemas informáticos de instituciones por ejemplo bancarias, que, de vulnerarse su información, puede causar un desastre económico a nivel nacional o global, dependiendo del alcance de la entidad.

En específico, el tema de la presente investigación se trata de indagar sobre la aleatoriedad de las contraseñas, con la pregunta de investigación planteada por el grupo, ¿En qué medida los patrones estructurales de las contraseñas del dataset RockYou —su composición de caracteres, longitud y distribución de dígitos— determinan su nivel de entropía y evidencian que los usuarios no eligen contraseñas de forma aleatoria?, se pretende descubrir si los humanos toman en cuenta la aleatoriedad o solo se basan en patrones muy conocidos y fáciles de recordar, vulnerando así su seguridad.

Para robustecer el análisis y darle un mayor rigor estadístico, la investigación incorpora herramientas que van más allá de la estadística descriptiva convencional. Por un lado, se aplicará la Ley de Benford, un principio matemático que establece la distribución esperada del primer dígito significativo en conjuntos de datos numéricos de origen natural o no manipulado. Por otro lado, se recurrirá a pruebas de bondad de ajuste como la prueba de Kolmogorov-Smirnov y la prueba de Kruskal-Wallis, las cuales permitirán evaluar si la distribución de las contraseñas sigue o se aleja significativamente de lo que cabría esperar bajo un modelo de aleatoriedad pura.

2.5.5. Metodología

2.5.5.1. Explicación de los datos y descripción

Los datos se filtraron en diciembre de 2009 debido a una vulnerabilidad de la seguridad de las bases de datos de la compañía RockYou, esta misma permitió que un hacker recolectara la creación de contraseñas de finales de la década de 2000. El origen de los mismos es California, Estados Unidos, pero el impacto fue global al afectar a millones de usuarios internacionales de redes sociales como Facebook y MySpace que utilizaban widgets y aplicaciones sociales dentro de estas propias redes sociales.

Consiste en 32,603,388 registros de usuarios que fueron extraídos directamente de la base de datos de RockYou tras el hackeo. De estos solo se usa la lista más utilizada en ciberseguridad (rockyou.txt), que contiene 14,344,386 contraseñas únicas tras eliminar duplicados y limpiar caracteres no válidos.

Sea c una contraseña del conjunto de datos $\mathcal{C}$. El tokenizador CL100K la transforma en un vector de embeddings:

$$\text{CL100K}(c) = \mathbf{v}_c = (v_1, v_2, \dots, v_d) \in \mathbb{R}^d, \quad (2.1)$$

donde d es la dimensión del embedding (típicamente $d \approx 100,000$ para CL100K).

Se elige la norma de valor absoluto del vector

$$\|\mathbf{v}_c\|_1 = \sum_{i=1}^d |v_i| \in \mathbb{R}_{\geq 0}. \quad (2.2)$$

Esta norma fue elegida simplemente por su interpretación directa como la suma total de las magnitudes de las componentes del vector de tokenización, lo que permite extraer la distribución de dígitos en cada posición del número resultante.

Prueba de Kolmogorov-Smirnov contra la distribución de Benford

La Ley de Benford establece que en conjuntos de datos numéricos de origen “natural”, el dígito d ocupa la primera posición con una frecuencia predecible (Caputi Zunini, 2019). Si los dígitos presentes en contraseñas reales se desvían de esa distribución, existe evidencia de que los usuarios eligen números con sesgos sistemáticos, lo que implica predecibilidad y, en consecuencia, vulnerabilidad. Se elige la prueba KS (y no una chi-cuadrado) porque compara funciones de distribución acumulada completas sin requerir agrupar celdas; con muestras en el orden de millones, la chi-cuadrado infla el estadístico por el tamaño de n sin aportar información sobre la forma de la desviación (Chandola, Banerjee, & Kumar, 2009; Chandy, Schifano, Yan, & Zhang, 2025).

Distribución teórica de Benford generalizada

Sea $(D_n \in \{1, \dots, 9\})$ el dígito en la posición (n) -ésima, entonces la PDF de Benford para $(n=1)$ es

$$\mathbb{P}(\{D_1 = d\}) = \log_{10} \left(1 + \frac{1}{d} \right) \quad (2.3)$$

Para posiciones $n \geq 2$, la fórmula generalizada integra sobre todos los prefijos de longitud $n - 1$, siendo esta

$$\mathbb{P}(\{D_n = d\}) = \sum_{k=10^{n-2}}^{10^{n-1}-1} \log_{10} \left(1 + \frac{1}{10k + d} \right), \quad d \in \{0, 1, \dots, 9\} \quad (2.4)$$

Estadístico KS

Sea $F_n(x)$ la función de distribución acumulada empírica de los dígitos en la posición p y $F_0(x)$ la CDF teórica de Benford. El estadístico Kolmogorov-Smirnov es

$$D_n = \sup_x |F_n(x) - F_0(x)| \quad (2.5)$$

Se rechaza H_0 (los dígitos siguen Benford) cuando $D_n > D_\alpha$. Dado que $n \sim 10^6$, el umbral D_α es extremadamente pequeño, por lo que se complementa el resultado con la desviación absoluta media (MAD)

$$\text{MAD} = \frac{1}{|\mathcal{D}|} \sum_{d \in \mathcal{D}} |\mathbb{P}_{\text{emp}}(d) - \mathbb{P}_{\text{Benford}}(d)| \quad (2.6)$$

donde $\mathcal{D}$ es el conjunto de dígitos válidos para la posición dada. Los umbrales de conformidad son $\text{MAD} < 0,006$ (muy cercana), $0,006\text{--}0,012$ (aceptable), $0,012\text{--}0,015$ (marginal) y $> 0,015$ (no conformidad) (Negrini, 2012).

Análisis de distribución de máscaras de contraseña

Las contraseñas humanas no son cadenas aleatorias, los usuarios exhiben patrones estructurales sistemáticos al elegirlos. Para capturar esa estructura sin depender del contenido semántico de cada contraseña, se utiliza una representación de máscara, que abstrae cada carácter a su tipo. Formalmente, dado el alfabeto de tipos $\Sigma = \{L, U, D, S\}$ (minúsculas, mayúsculas, dígitos, caracteres especiales), la máscara de una contraseña $P = c_1 c_2 \dots c_n$ es

$$M(P) = \tau(c_1) \tau(c_2) \dots \tau(c_n), \quad \tau(c) = \begin{cases} L & c \in \mathcal{L} \\ U & c \in \mathcal{U} \\ D & c \in \mathcal{D} \\ S & c \in \mathcal{S} \end{cases} \quad (2.7)$$

Patrones comprimidos

Para reducir el espacio de máscaras sin perder información sobre la composición, se aplica una codificación de longitud de racha (*run-length encoding*) sobre $M(P)$. Sea $M(P) = t_1^{r_1} t_2^{r_2} \dots t_k^{r_k}$ la descomposición en rachas consecutivas del mismo tipo, entonces el patrón comprimido es

$$R(P) = t_1 r_1 \ t_2 r_2 \ \dots \ t_k r_k \quad (2.8)$$

Por ejemplo, la máscara LLLLLLDD se comprime a L6D2. Esta representación agrupa contraseñas con la misma composición por bloques, lo que facilita el análisis de patrones frecuentes en el dataset. La distribución de patrones comprimidos se analiza por frecuencia absoluta f_j y proporción relativa $\hat{p}_j = f_j/N$, donde N es el total de contraseñas.

Entropía de Shannon

Sea P una contraseña y sea p_t la proporción del tipo $t \in \Sigma$ en P . La entropía de Shannon de P es

$$H_S(P) = - \sum_{t \in \Sigma} p_t \log_2 p_t \quad (2.9)$$

Prueba de Kruskal-Wallis sobre entropías por grupo

Se busca determinar si la estructura de la máscara (longitud y tipo dominante de caracteres) discrimina el nivel de entropía. Se elige Kruskal-Wallis (KW) en lugar de ANOVA de un factor porque

- Las distribuciones de entropía por grupo no son normales (asimétricas, con colas largas), como se verifica en el análisis descriptivo.

- KW es una prueba no paramétrica de rangos que no asume homocedasticidad ni normalidad dentro de los grupos.

Entropía de Shannon de una máscara

La entropía media de la máscara m se define como en la ecuación (2.9), donde $\Sigma = \{L, U, D, S\}$ es el alfabeto de tipos de carácter (minúsculas, mayúsculas, dígitos, símbolos) y p_c es la proporción del tipo c en m .

Estadístico de Kruskal-Wallis

Dadas k muestras independientes de tamaños $n_1, \dots, n_k$ con $N = \sum_{i=1}^k n_i$ observaciones totales, el estadístico es

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1) \quad (2.10)$$

donde R_i es la suma de rangos del grupo i sobre el ranking global. Bajo H_0 (todas las distribuciones son iguales), $H \sim \chi_{k-1}^2$ para muestras grandes.

Ponderación por frecuencia

Como cada máscara m_j tiene una frecuencia f_j (número de contraseñas reales que la usan), se expande la muestra repitiendo cada observación con su frecuencia real:

$$\tilde{n}_j = f_j \quad (2.11)$$

Para garantizar la reproducibilidad del proyecto, la implementación incluye un parámetro de tope C configurable

$$\tilde{n}_j = \min(f_j, C) \quad (2.12)$$

En este trabajo se fija $C = 10\,000\,000$, valor que excede la frecuencia máxima observada en el dataset RockYou ($f_{\text{máx}} = L6$ con 3 996 634 observaciones), por lo que el tope es inactivo y se cumple $\tilde{n}_j = f_j$ para toda máscara m_j . El vector de rangos reproduce así fielmente la distribución real del dataset.


Agrupaciones evaluadas

Se aplica KW bajo tres criterios de agrupación

1. Longitud de máscara: grupos $g \in \{1, 2, \dots, L_{\text{máx}}\}$ donde $L_{\text{máx}}$ es la longitud máxima observada.
2. Tipo dominante: Solo L, Solo D, Solo U, Solo S, Mixta.
3. Rango de entropía: bajo ($H < 2,4464$, por debajo del percentil 25), medio ($2,4464 \leq H < 2,9477$, entre los percentiles 25 y 75) y alto ($H \geq 2,9477$, por encima del percentil 75). Este agrupamiento es descriptivo, no inferencial, pues la variable de agrupación coincide con la variable de respuesta.

2.5.6. Resultados


A partir de ahí, fue momento de usar las pruebas no paramétricas mencionadas al inicio de esta sección. Los primeros resultados se obtuvieron mediante el uso del test Kolmogórov-Smirnov (KS). Dicho test, según Yakir (2013), permite calcular que tanto error existe entre la función de distribución acumulada basada en lo que muestran las observaciones y la distribución teórica. De esta manera, se evaluó si la distribución empírica de los dígitos en la primera posición de las contraseñas tokenizadas se ajusta a la Ley de Benford. Los resultados indican que, aunque visualmente la distribución guarda similitud con la teórica de Benford —con mayor frecuencia del dígito 1—, el test KS rechaza H_0 ($D = 0.0985$), lo que significa que la diferencia es estadísticamente significativa y no puede descartarse como aleatoria, como se muestra en la siguiente figura.



KS y Benford para posición 1 con contraseñas tokenizadas

Esto implica que las contraseñas no son completamente aleatorias en su primera posición: siguen un patrón parcialmente compatible con Benford, pero no con la rigurosidad formal requerida por el test. Este resultado se apoya en la literatura de Caputi (2019) sobre la Ley de Benford y en Chandy et al. (2025) sobre el test KS, y motiva la exploración de las posiciones subsiguientes para determinar si el ajuste mejora a medida que avanza la posición.

En sintonía con lo anterior, el segundo resultado que se obtuvo (relacionado a los dígitos en la segunda posición), fue que con la misma metodología de tokenización cl100k y el test KS, se llegó a que, al igual que en la posición 1, la distribución empírica muestra una forma visualmente similar a la Ley de Benford, pero el test KS rechaza H_0 ($D = 0.0108$), indicando que el ajuste no es suficiente para confirmar estadísticamente el seguimiento de dicha ley, como se muestra en la siguiente figura.




KS y Benford para posición 2 con contraseñas tokenizadas

La diferencia con la posición 1 es que el estadístico D es mucho menor, lo que sugiere un mejor ajuste relativo, aunque aún insuficiente. Este resultado consolida la hipótesis de que

las primeras posiciones de las contraseñas son las que más se desvían del comportamiento esperado bajo Benford, lo que refuerza que las claves no son completamente aleatorias. Constituye un eslabón clave en la cadena de análisis posicional, orientando la investigación hacia la posición 3 y siguientes para buscar un ajuste formal.


Al realizar un proceso análogo a los anteriores para el tercer dígito se obtuvo resultados diferentes, y fue que el test no rechazó H_0 ($D = 0.0003$), lo que indica que la distribución empírica de los dígitos en esta posición sigue la Ley de Benford de manera estadísticamente aceptable, como bien muestra la siguiente figura.



KS y Benford para posición 3 con contraseñas tokenizadas

Este es el primer punto de la cadena posicional en el que se confirma formalmente el ajuste a Benford, marcando una ruptura con el comportamiento de las posiciones 1 y 2. El hallazgo es significativo porque demuestra que no basta con la similitud visual para afirmar que una distribución sigue Benford; es imprescindible validarlo con pruebas formales como el test KS. En consonancia con Caputi (2019) y Chandy et al. (2025), este resultado sienta la base para verificar si las posiciones 4 en adelante mantienen el mismo patrón, avanzando hacia una caracterización más completa de la aleatoriedad de las contraseñas.

Similar al caso anterior, el análisis de la cuarta posición de las contraseñas tokenizadas con cl100k confirma, nuevamente, que el test KS no rechaza H_0 ($D = 0.0003$), validando que la distribución de dígitos en esta posición se ajusta formalmente a la Ley de Benford. Esto último se puede mostrar en el gráfico siguiente.




KS y Benford para posición 4 con contraseñas tokenizadas

Este resultado es consistente con el hallazgo de la posición 3 y forma parte de un patrón más amplio: se determinó que a partir de la posición 3 en adelante, todas las posiciones siguen Benford de forma confirmada por KS, lo cual resulta inesperado dado que las posiciones 1 y 2 no lograron pasar el test. Esto revela que la naturaleza de los dígitos en posiciones iniciales es cualitativamente diferente a la de las posiciones intermedias y finales, y que no basta con la similitud visual para afirmar el seguimiento de una distribución: la validación formal

es imprescindible. La discrepancia plantea la necesidad de explorar nuevas estrategias de tokenización que permitan extender el cumplimiento de Benford a todas las posiciones, en línea con Caputi (2019) y Chandy et al. (2025).


Luego, para el siguiente resultado se hizo uso de la prueba de Kruskal-Wallis. De acuerdo a Childs, Hindle y Warren (2021), esta prueba consiste en evaluar las diferencias entre dos (o más) muestras. Para lograr esto, las variables deben ser no nominales, las observaciones de cada grupo deben ser independientes y la distribución de las variables de cada grupo deben ser “similares”. Gracias a esta prueba se puede ver si existen diferencias significativas entre las distribuciones de varias muestras independientes. Usando lo anterior junto con el concepto de entropía, fue que se compararon las distribuciones de entropía de contraseñas clasificadas según el tipo de máscara: mixta, solo dígitos, solo letras, solo caracteres especiales y solo mayúsculas. El test rechazó H_0 con alta significancia ($H = 4,366,419,48, p \approx 0$), evidenciando que los cinco tipos de máscara producen distribuciones de entropía completamente distintas. El siguiente gráfico permite visualizar esto último.



Kruskal-Wallis - Entropía por tipo de máscara


Las contraseñas mixtas presentan la entropía más alta, mientras que las compuestas exclusivamente por caracteres especiales muestran los valores más bajos, contrariamente a lo que podría esperarse intuitivamente. Este agrupamiento es descriptivo y no inferencial, pues la variable de agrupación coincide con la variable de respuesta. El hallazgo enriquece la comprensión del desorden interno en las contraseñas y abre la puerta para determinar si estas diferencias en entropía pueden usarse para cuantificar aleatoriedad real en los pasos siguientes del análisis. Para complementar lo anterior, se hizo lo mismo pero únicamente con la longitud de la máscara. Los resultados de esto último fue que el test rechazó la hipótesis nula ($H = 14,084,456,87, p \approx 0$), confirmando que existen diferencias estadísticamente significativas entre grupos, como se muestra en el siguiente gráfico.

Visualmente, se aprecia una tendencia creciente y clara: a mayor longitud de la contraseña, mayor es la entropía media esperada, resultado intuitivo pero que era necesario comprobar formalmente. Esto refuerza la relación entre longitud y complejidad planteada por Reaz (2024), quien asocia la entropía a la dificultad de predicción de una contraseña. No obstante, este resultado no determina qué tan aleatorias son las contraseñas ni cuáles son seguras en términos absolutos; únicamente establece que la longitud es un predictor significativo de la entropía, lo que orienta los análisis inferenciales siguientes sobre aleatoriedad real.



Kruskal-Wallis - Entropía por longitud de máscara

Con el fin de complementar el proyecto mediante un análisis separado de lo narrado anteriormente, se realizó un análisis descriptivo de la distribución empírica de los dígitos (0–9) en las primeras seis posiciones de las contraseñas del dataset RockYou. Se observó que la posición 1 presenta una distribución notablemente sesgada, donde los dígitos más bajos aparecen con mayor frecuencia, lo cual es compatible con la Ley de Benford; la posición 2 también muestra variación, aunque menor. A partir de la posición 3, la distribución se vuelve prácticamente uniforme: todos los dígitos tienen probabilidades de aparición muy similares, independientemente de cuál se elija. Lo anterior se ve reflejado en la siguiente figura.




Distribución empírica de dígitos por posición

Esto sugiere que la primera posición es la más informativa para inferir patrones de creación de contraseñas, mientras que las posiciones posteriores son más predecibles en términos de uniformidad. El resultado no mide aleatoriedad directamente ni indica qué dígitos se usan en mayor volumen, pero construye una base empírica para contrastar con la Ley de Benford (Caputi, 2019) en análisis futuros.

Por último, se construyó una matriz de bigramas para analizar las probabilidades de transición entre tipos de caracteres (letras, dígitos, mayúsculas y caracteres especiales) en las contraseñas del dataset RockYou. Los resultados muestran que la transición de letra a letra es, con diferencia, la más frecuente (66.26 %), seguida de dígito a dígito (23.28 %), lo que evidencia un comportamiento ordenado en la construcción de contraseñas, como se puede ver en el siguiente gráfico.

Esto permitió observar que las transiciones entre tipos distintos, como de carácter especial a otro carácter especial, son prácticamente inexistentes. Este patrón de orden se asocia al concepto de entropía planteado por Reaz (2024), donde la tendencia a permanecer dentro



Biograma de transición entre tipos

del mismo tipo de carácter refleja baja aleatoriedad entre tipos. Sin embargo, este resultado no describe la distribución general de contraseñas ni sus longitudes, sino únicamente el orden secuencial de sus caracteres, lo cual sienta una base para modelar mejor la entropía en pasos analíticos posteriores.

2.5.7. Conclusiones

Los resultados indican que las contraseñas humanas poseen una estructura estadística identificable y parcialmente predecible.

La composición de caracteres, la longitud y los patrones de transición influyen significativamente en la entropía observada, evidenciando que los usuarios no seleccionan contraseñas de forma completamente aleatoria.

La prueba KS mostró que las posiciones 1 y 2 se desvían significativamente de la distribución teórica de Benford, mientras que a partir de la posición 3 no se rechaza el ajuste a dicha ley.

Una limitación es que se eligió arbitrariamente el método de tokenización, ya que es imposible con la capacidad computacional actual, decidir cuál modelo es el más eficiente.

Otra limitación es que el dataset brindado por RockYou.txt está limitado a un sector de la población en específico, lo que provocó que la idea inicial del proyecto de buscar predecir contraseñas no se pudiera llevar a cabo, pues en general los resultados no se habrían podido generalizar al resto de la población.

2.5.8. Agradecimientos

Agradecemos profundamente al profesor Maikol Solís Chacón por su acompañamiento durante la realización de este proyecto. Además, a Jeikel Navarro por su retroalimentación constante durante su realización.

Capítulo 3

Registro de uso de IA

Herramienta: Claude (Anthropic) Prompt: Prompts iterativos para la generación de gráficos en Python de las nuevas funciones de análisis (`chi2_independencia_transiciones` y `spearman_coocurrencia_tipos`) y la corrección y finalizaciones de los algoritmos de las mismas funciones Respuesta de la IA: El código generado se incorporó en los scripts del proyecto, particularmente en los módulos de análisis de transiciones y co-ocurrencia. Se añadieron rutinas para graficar los resultados de Chi-cuadrado y Spearman, además de ajustes en la lógica de las funciones para evitar fallos en la conversión de datos y en la construcción de matrices. Evaluación: Cada fragmento de código fue revisado y probado por al menos un miembro del equipo, verificando que los gráficos se generaran correctamente y que los algoritmos devolvieran resultados coherentes con los objetivos del análisis. Modificaciones: Se realizaron correcciones puntuales en la lógica de iteración y en el manejo de valores nulos, además de ajustes menores de estilo en los gráficos para mejorar la legibilidad. Aprendizaje: Se observó que Claude es capaz de generar código funcional y estructurado para tareas de análisis estadístico y visualización, aunque siempre requiere supervisión humana para garantizar que los algoritmos se ejecuten sin errores y que los resultados gráficos sean interpretables y útiles para el proyecto.

Bibliografía

- Awati, R. (2025). ¿Qué es una contraseña? <https://www.computerweekly.com/es/definicion/Que-es-una-contrasena>
- Barabesi, L., Cerioli, A., Cerasa, A., & Perrotta, D. (2025). Robust Inference Under Benford's Law.
- Blocki, J., & Liu, P. (2022). Towards a Rigorous Statistical Analysis of Empirical Password Datasets.
- Bonneau, J. (2012). The Science of Guessing: Analyzing an Anonymized Corpus of 70 Million Passwords. *IEEE Symposium on Security and Privacy*. <https://www.computer.org/csdl/proceedings-article/sp/2012/06234435/12OmNCbU3ar>
- Caputi, M. (2019). Ley de Benford. *Publicaciones Matemáticas del Uruguay*, 17.
- Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly Detection: A Survey. *ACM Computing Surveys*, 41(3), 1-58. <https://dl.acm.org/doi/10.1145/1541880.1541882>
- Chandy, M., Schifano, E., Yan, J., & Zhang, X. (2025). Nonparametric Block Bootstrap Kolmogorov-Smirnov Goodness-of-Fit Test. *arXiv preprint*. <https://arxiv.org/pdf/2511.05733.pdf>
- Childs, D. (n.d.). Non-parametric tests.
- Hayes, A. (2026). Probability Distribution: Definition, Types, and Uses in Investing. <https://www.investopedia.com/terms/p/probabilitydistribution.asp>
- Keszthelyi, A. (2013). About Passwords. *Acta Polytechnica Hungarica*, 10(6).
- Kisbye, P. (2010). Test de Kolmogorov-Smirnov. https://www.famaf.unc.edu.ar/~kisbye/mys/clase17_pr.pdf
- Lehoucq, R., Mayer, J., & Tucker, W. (2022). *Entropy and Its Relationship with Statistics* (Technical Report). United States Department of Energy, National Technology & Engineering Solutions of Sandia.
- Ma, J., Yang, W., Luo, M., & Li, N. (2014). A Study of Probabilistic Password Models. *IEEE Symposium on Security and Privacy*. <https://dl.acm.org/doi/10.1109/SP.2014.50>
- Marrero. (2019). Ley de Benford: La fuerza de uno. <https://www.ull.es/portal/cienciaull/ley-de-benford-la-fuerza-de-uno/>
- Miller, S. (2015). *Benford's Law: Theory and Applications*. Princeton University Press.
- Molinaro, D. (2022). ¿Qué es un bot? <https://www.avast.com/es-es/c-what-is-a-bot>
- Nigrini, M. J. (2012). *Benford's Law: Applications for Forensic Accounting, Auditing, and Fraud Detection*. John Wiley & Sons. <https://onlinelibrary.wiley.com/doi/book/10.1002/9781119203094>

- Olsen, C. (2018). *A Machine Learning Approach to Predicting Passwords* [Tesis doctoral, Technical University of Denmark]. <https://www2.imm.dtu.dk/pubdb/edoc/imm7088.pdf>
- Reaz, K., & Wunder, G. (2024). Expectation Entropy as a Password Strength Metric.
- Sarkar, T. (2025). What Is Benford’s Law and Why Is It Important? <https://builtin.com/data-science/benfords-law>
- Singh, A. K., & Strouse, D. (2024). Tokenization counts: the impact of tokenization on arithmetic in frontier LLMs. *arXiv preprint*. <https://arxiv.org/abs/2402.14903>
- Taylor, S. (2020). Nonparametric Tests. <https://corporatefinanceinstitute.com/resources/data-science/nonparametric-tests/>
- Wang, D., Cheng, H., Wang, P., Huang, X., & Jian, G. (2017). Zipf’s Law in Passwords. *IEEE Transactions on Information Forensics and Security*, 12(11).
- Yakir, B. (2013). Front Matter. En *Extremes in Random Fields* (pp. i-xv). John Wiley & Sons. <https://doi.org/10.1002/9781118720608.fmatter>
- Yang, X., Li, J., Xing, K., Xiao, Z., Duan, M., Han, W., & Xiong, H. (2025). KAPG: Adaptive Password Guessing via Knowledge-Augmented Generation. *arXiv preprint*. <https://arxiv.org/abs/2510.23036>
- Yu, X., & Liao, Q. (2015). User Password Repetitive Patterns Analysis and Visualization. *Emerald Journals*, 24(1).