



UNIVERSIDAD DE COSTA RICA

Escuela de Matemáticas

Estadística Actuarial I (CA0303)

Bitácora #4

Prof: Maikol Solís

Estudiantes:

Anthony Flores Rojas (C32975)

Andrey González Bastos (C33329)

Randal Picado Bermúdez (C36024)

Leonardo Vega Aragón (C38313)

Fecha: 22/06/2026

Contenido

1. Parte de planificación	1
1.1. Fichas de resultados	1
2. Parte de escritura	2
2.1. Escribir, escribir, escribir	2
2.2. Conclusión	2
2.3. Introducción	3
2.4. Resumen	4
2.5. Ordenamiento final	4
3. Revisiones finales	5
4. Registro de uso de IA	6

Capítulo 1

Parte de planificación

1.1. Fichas de resultados

Holi.

Capítulo 2

Parte de escritura

2.1. Escribir, escribir, escribir

Holi.

2.2. Conclusión

La presente investigación buscó responder en qué medida los patrones estructurales de las contraseñas de RockYou, su composición de caracteres, longitud y distribución de dígitos, determinan su entropía y evidencian que los usuarios no las eligen al azar. Esta pregunta sustituyó a la de la Bitácora #2, centrada solo en Benford, pues rockyou.txt carecía de metadatos de usuario. Acompañados del profesor Maikol Solís se reorientó el proyecto hacia un enfoque estructural y entrópico, sin abandonar Benford, sino aplicándolo sobre la suma de los vectores de tokenización cl100k de cada contraseña.

Se esperaba hallar sesgos sistemáticos detectables estadísticamente, y los resultados coincidieron solo en parte el test KS rechazó Benford en las posiciones 1 y 2 de esa suma tokenizada, pero no a partir de la posición 3, donde lo empírico y lo teórico convergen a la uniformidad; Kruskal-Wallis confirmó que máscara y longitud determinan la entropía de Shannon, y la matriz de bigramas mostró orden en la transición entre tipos de carácter. La metodología, combinando tokenización, pruebas no paramétricas y entropía, resolvió la pregunta desde varios ángulos, aunque no sin tropiezos: aplicar Benford directamente sobre los dígitos sin tokenizar fracasó por las fechas, las longitudes acotadas y los sesgos cognitivos de los usuarios, lo que obligó a replantear el enfoque hacia la suma tokenizada. Para trabajos futuros se recomienda probar otras normas o esquemas de tokenización que extiendan el ajuste a Benford a todas las posiciones y complementar los hallazgos con modelos de Markov o redes generativas.

Finalmente, este trabajo llena un vacío poco explorado: ni los estudios de Benford (Caputi, 2019; Nigrini, 2012) ni los de seguridad de contraseñas (Bonneau, 2012; Wang et al., 2017) habían combinado la tokenización de los modelos de lenguaje con pruebas estadísticas formales para medir la predecibilidad de contraseñas, lo que vuelve esta investigación un puente metodológico novedoso entre ambas tradiciones.

2.3. Introducción

El desarrollo de la tecnología y las bases de datos electrónicas han llegado a cambiar el juego de la información. Cada día se les confían más datos personales y sensibles a distintos softwares, ya sea la aplicación bancaria que se usa para realizar una transacción, o tal vez la aplicación de salud que se utilice para medir el estado de la misma, ambas usan datos sumamente sensibles y privados acerca de las personas, su estilo de vida, sus gustos, etc.

Con este desarrollo inminente, las contraseñas han redefinido su importancia en el diario vivir de las personas, antes, cuando se pensaba en una contraseña, se pensaba en una caja fuerte de algún banco que se abría si se digitaba correctamente una sucesión de números que solo los altos mandos conocían, sin embargo, hoy en día, las contraseñas en los entornos digitales representan la seguridad de miles de millones de datos sensibles de millones de usuarios alrededor del mundo, que en caso de filtrarse o saberse, causaría un caos a nivel global.

En la investigación, se usará el sonado caso de la filtración de RockYou, un hackeo que se realizó en el año 2009, del cual se obtuvo un dataset lo suficientemente robusto de contraseñas para poder realizar análisis y estudios posteriores. Sabiendo todo lo anterior, resulta fundamental y oportuno, estudiar a detalle la composición de las contraseñas y como los usuarios tienden a elegir estas mismas. Saber la naturaleza de las contraseñas resulta beneficioso para así poder detectar anomalías en bases de datos de contraseñas, así como posibles ataques a los sistemas informáticos de instituciones por ejemplo bancarias, que, de vulnerarse su información, puede causar un desastre económico a nivel nacional o global, dependiendo del alcance de la entidad. En específico, el tema de la presente investigación se trata de indagar sobre la aleatoriedad de las contraseñas, con la pregunta de investigación planteada por el grupo, ¿En qué medida los patrones estructurales de las contraseñas del dataset RockYou —su composición de caracteres, longitud y distribución de dígitos— determinan su nivel de entropía y evidencian que los usuarios no eligen contraseñas de forma aleatoria?, se pretende descubrir si los humanos toman en cuenta la aleatoriedad o solo se basan en patrones muy conocidos y fáciles de recordar, vulnerando así su seguridad. Es bien conocido que el ser humano tiende a seguir patrones y escapa constantemente de la incertidumbre, es por esto que se puede llegar a medir la aleatoriedad de las contraseñas mediante el concepto de entropía. La entropía, entendida como una medida de aleatoriedad e impredecibilidad, permite cuantificar qué tan difícil es para un atacante adivinar o descifrar una contraseña determinada. Una contraseña con alta entropía implica una mayor cantidad de combinaciones posibles, lo que la hace significativamente más resistente ante ataques de fuerza bruta o de diccionario. Sin embargo, la pregunta que surge de forma natural es si los usuarios, al momento de crear sus contraseñas, realmente priorizan esta aleatoriedad, o si, por el contrario, siguen patrones predecibles dictados por la comodidad y la memoria.

Para robustecer el análisis y darle un mayor rigor estadístico, la investigación incorpora herramientas que van más allá de la estadística descriptiva convencional. Por un lado, se aplicará la Ley de Benford, un principio matemático que establece la distribución esperada del primer dígito significativo en conjuntos de datos numéricos de origen natural o no manipulado. Por otro lado, se recurrirá a pruebas de bondad de ajuste como la prueba de Kolmogorov-Smirnov y la prueba de Kruskal-Wallis, las cuales permitirán evaluar si la distribución de las contraseñas sigue o se aleja significativamente de lo que cabría esperar bajo un modelo de

aleatoriedad pura.

La combinación de estos enfoques ofrece una perspectiva tanto descriptiva como inferencial, permitiendo no solo caracterizar los patrones presentes en el dataset, sino también validar estadísticamente la hipótesis de que los usuarios, lejos de actuar al azar, siguen tendencias estructurales profundamente arraigadas al momento de construir sus contraseñas. Adicionalmente, el análisis incorpora un enfoque proveniente del procesamiento de lenguaje natural mediante la tokenización cl100k, el esquema de codificación utilizado por modelos de lenguaje de gran escala como GPT-4. Este proceso consiste en descomponer las contraseñas en unidades mínimas de significado llamadas tokens, esto para poder simplificar el análisis de las contraseñas por la combinación de letras y caracteres.

2.4. Resumen

2.5. Ordenamiento final

Capítulo 3

Revisiones finales

Capítulo 4

Registro de uso de IA