

Análisis de la entropía y el cumplimiento de Ley de Benford en contraseñas del dataset RockYou.txt mediante la tokenización de sus subcadenas

Anthonny Flores Rojas (C32975)
Andrey González Bastos (C33329)
Randal Picado Bermúdez (C326024)
Leonardo Vega Aragón (C38313)

7 de julio del 2026

Cronograma

- 1 Introducción / Contexto
- 2 Pregunta de investigación y objetivos
- 3 Datos
- 4 Metodología
- 5 Resultados
- 6 Conclusiones y trabajo futuro

Introducción / Contexto


- El desarrollo de la tecnología y las bases de datos electrónicas han llegado a cambiar el juego de la información.
- Resulta fundamental y oportuno, estudiar a detalle la composición de las contraseñas y como los usuarios dejan patrones en ellas.

Pregunta de investigación y objetivos

- ¿En qué medida los patrones estructurales de las contraseñas del dataset Rock-You2009 —su composición de caracteres, longitud y distribución de dígitos— determinan su nivel de entropía y evidencian que los usuarios no eligen contraseñas de forma aleatoria?

- RockYou en 2009.

Figura 1: Distribucion del largo de las contraseñas



Nota. Porcentaje de contraseñas por longitud.

Tokenización

$$\text{CL100K}(c) = \mathbf{v}_c = (v_1, v_2, \dots, v_d) \in \mathbb{R}^d, \quad (1)$$

Benford

$$\mathbb{P}(\{D_n = d\}) = \sum_{k=10^{n-2}}^{10^{n-1}-1} \log_{10} \left(1 + \frac{1}{10k + d} \right), \quad d \in \{0, 1, \dots, 9\} \quad (2)$$

Test Kolmogorov Smirnov

$$D_n = \sup_x |F_n(x) - F_0(x)| \quad (3)$$

Entropía de Shannon

$$H_S(P) = - \sum_{t \in \Sigma} p_t \log_2 p_t \quad (4)$$

Test Kruskal-Wallis

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1) \quad (5)$$


Empleo de máscaras

- Longitud de máscara
- Tipo dominante: Solo L, Solo D, Solo U, Solo S, Mixta.

Probabilidades de transición


$$\mathbb{P}(\{x, y\}) = \frac{k}{L} \quad (6)$$

Figura 2: KS y Benford para posición 1 con contraseñas tokenizadas




Nota. Pruebas KS aplicada para rechazar hipótesis nula en la posición 1.

Figura 3: KS y Benford para posición 3 con contraseñas tokenizadas




Nota. Pruebas KS aplicada para rechazar hipótesis nula en la posición 3.

Figura 4: Prueba Kruskal-Wallis bajo tipo de máscara




Nota. Pruebas KW el tipo de máscara: mixta, solo dígitos, solo letras, solo caracteres especiales y solo mayúsculas.

Figura 5: Prueba Kruskal-Wallis por longitud de la máscara



Nota. Pruebas KW aplicada por la longitud de la máscara únicamente.

Figura 6: Matriz de biogramas de probabilidades según tipo de caracteres



Nota. Matriz de biogramas para analizar las probabilidades de transición entre tipos de caracteres (letras, dígitos, mayúsculas y caracteres especiales).

Conclusiones

- Las contraseñas de RockYou2009 siguen un patrón estructural.
- Conclusiones del análisis.
- Comportamiento futuro de las contraseñas.

¡Muchas gracias!